Instituto Tecnológico Autónomo de México



Modelado probabilístico de melodías: cadenas de Markov ocultas y comparación predictiva

TESIS

QUE PARA OBTENER EL TÍTULO DE

Licenciado en Matemáticas Aplicadas e Ingeniería en Computación

PRESENTA

Adrián Janus Gonzalez Adamuz

Asesora: Airam Blancas Serrat

Ciudad de México, México
Otoño, 2026

"Con fundamento en los artículos 21 y 27 de la Ley Federal de Derecho de Autor y como titular de los derechos moral y patrimonial de la obra titulada "*Modelado probabilístico de melodías: cadenas de Markov ocultas y comparación predictiva*", otorgo de manera gratuita y permanente al Instituto Tecnológico Autónomo de México y a la biblioteca Raúl Baillères Jr., autorización para que fijen la obra en cualquier medio, incluido el electrónico, y la divulguen entre sus usuarios, profesores, estudiantes o terceras personas, sin que pueda percibir por tal divulgación una prestación"

Adrián Janus Gonzalez Adamuz

Otoño, 2026



Abstract

This thesis studies what different probabilistic sequence models reveal when symbolic melodies are represented as ordered pitch-class events. It begins with finite Markov chains, separates observable notes from latent musical contexts through hidden Markov models (HMMs), and then introduces an HMM based on the hierarchical Dirichlet process (HDP-HMM) to avoid treating the number of latent states as known in advance. The theoretical development is paired with computational experiments and with an explicit audit of their reproducibility and interpretive limits.

The final experiment compares a finite HMM, a truncated HDP-HMM, a variable-order Markov model, and a causal transformer on the same next-event prediction task. Canonical-work splits keep arrangements of the same piece together. From a sample of 3,000 PDMX files, 2,933 pieces remained after preprocessing. At the full training fraction, the transformer achieved test perplexity 5.823, compared with 7.356 for the finite HMM, 7.968 for the HDP-HMM, and 8.022 for the variable-order model. This result favors the transformer for the predictive task at the studied scale. It does not establish structural superiority: the completed run did not include reference annotations for phrases, sections, or harmonic functions. The thesis therefore treats prediction, latent-state compactness, computational cost, and musical interpretation as related but distinct criteria.

Resumen

Esta tesis estudia qué puede mostrar cada familia de modelos cuando una melodía simbólica se representa como una sucesión de clases de altura. El desarrollo parte de cadenas de Markov finitas, separa las notas observables de los contextos musicales latentes mediante cadenas de Markov ocultas (HMM) y después introduce un HMM basado en el proceso de Dirichlet jerárquico (HDP-HMM) para no tratar el número de estados como una cantidad conocida de antemano. La exposición teórica se acompaña de experimentos computacionales y de una auditoría explícita de sus límites de reproducibilidad e interpretación.

El experimento final compara un HMM finito, un HDP-HMM truncado, un modelo de Markov de orden variable y un transformador causal sobre la misma tarea de predicción del siguiente evento. Las particiones por obra canónica mantienen juntos los arreglos de una misma pieza. De una muestra de 3000 archivos de PDMX, 2933 piezas permanecieron después del preprocesamiento. En la fracción completa de entrenamiento, el transformador obtuvo una *perplexity* de prueba de 5.823, frente a 7.356 del HMM finito, 7.968 del HDP-HMM y 8.022 del modelo de orden variable. Este resultado favorece al transformador para la tarea predictiva y la escala estudiadas. No establece superioridad estructural: la corrida terminada no contó con anotaciones de referencia para frases, secciones o funciones armónicas. La tesis trata por ello la predicción, la compacidad latente, el costo computacional y la interpretación musical como criterios relacionados, pero distintos.

Índice general

Abstract v

Resumen v

Índice de figuras x

Índice de cuadros xii

1 Diseño computacional del sistema de modelado musical . . 1
1.1 Problema de diseño 1
1.2 Requerimientos del sistema 2
1.3 Restricciones observadas 3
1.4 Estándares y límites de uso 3
1.5 Modelos considerados 4
1.6 Arquitectura implementada 4
1.7 Estrategia y resultado de la comparación 5

2 Preliminares 6
2.1 De la melodía a una secuencia 6
2.2 Dependencia local y cadenas de Markov 8
2.3 De la nota observable al contexto latente 9

3 Cadenas de Markov ocultas y modelado computacional . . 10
3.1 Dos procesos y una misma secuencia 10

3.2 Tres problemas computacionales 12
3.2.1 Evaluación mediante el algoritmo hacia adelante 12
3.2.2 Decodificación mediante Viterbi 13
3.2.3 Aprendizaje mediante Baum-Welch 15
3.3 Una comprobación manual sobre el Preludio en Do mayor 15
3.4 El límite del número fijo de estados 20

4 Cadenas de Markov ocultas infinitas 21
4.1 Del número fijo a una colección abierta de estados 23
4.2 Del modelo infinito a un cálculo finito 25
4.3 De una obra al corpus 27
4.3.1 Resultados sobre un subconjunto clásico 28
4.3.2 Resultados sobre el corpus extendido 32

5 Comparación predictiva entre HMM, HDP-HMM, VOMM y transformador 38
5.1 Una tarea común para modelos diferentes 40
5.2 Cómo se construye la comparación 41
5.2.1 Comprobaciones previas 44
5.3 La corrida completada sobre PDMX 44
5.4 Qué cambia cuando aumenta el corpus 45
5.4.1 Comparación obra por obra 46
5.5 El costo de la mejora predictiva 47
5.6 Lo que la predicción todavía no responde 47

Apéndice A De la distribución de Dirichlet al proceso jerárquico 50
A.1 Sobre el proceso de Dirichlet y los modelos jerárquicos 50

Apéndice B Propiedades del proceso observable en un HMM . 55
B.1 Las observaciones pueden conservar memoria 55
B.2 El proceso conjunto sí es markoviano 56
B.3 Un caso límite 57

Bibliografía 60

Índice de figuras

2.1 Representación esquemática de una octava en el teclado del piano. Las teclas negras completan las doce clases de altura, aunque sólo se rotulan aquí las notas naturales. 7

3.1 Matriz obtenida de la trayectoria inferida para el Preludio en Do mayor. El marco discontinuo identifica el renglón de `E min`, para el cual no se registraron transiciones inferidas. Las celdas sin cifra representan valores registrados como cero. 17
3.2 Matriz construida mediante etiquetado y conteo manual de la partitura del Preludio en Do mayor. Las celdas sin cifra representan valores registrados como cero. 18
3.3 Diferencia absoluta registrada entre la matriz inferida y la referencia manual. Las celdas sin cifra representan diferencias registradas como cero. 19

4.1 Ajuste probabilístico en el subconjunto clásico. Los paneles presentan los mismos seis casos por obra y de manera agregada. 30
4.2 Ganancia de log-verosimilitud y ocupación latente en el subconjunto clásico. El panel izquierdo muestra la diferencia de ajuste y el derecho el número de estados ocupados. 31

4.3 Log-verosimilitud por obra y distribución agregada en el corpus extendido. Las comparaciones se limitan a los 167 casos válidos para ambos modelos. 34
4.4 Ganancia de log-verosimilitud y ocupación latente en el corpus extendido. El número de estados ocupados no constituye una métrica estructural de referencia. 36

5.1 Dos preguntas distintas sobre una misma secuencia musical. La predicción pudo compararse entre las cuatro familias; la descripción estructural requiere todavía una referencia externa. 40

Índice de cuadros

4.1 Comparación entre el HMM finito y el HDP-HMM truncado sobre la obra ancla: el tercer movimiento de la Sonata no. 14 de Beethoven. 28

4.2 Subconjunto clásico limitado utilizado para la comparación documentada entre el HMM finito y el HDP-HMM truncado. 28

4.3 Resumen agregado de la comparación entre el HMM finito y el HDP-HMM truncado sobre el subconjunto clásico limitado. . . . 29

4.4 Comparación por obra en las seis piezas del subconjunto clásico. La ganancia se calcula como la diferencia HDP-HMM truncado − HMM finito. 29

4.5 Composición del corpus extendido utilizado en la comparación multicorpus. 32

4.6 Resumen agregado de la comparación entre el HMM finito y el HDP-HMM truncado sobre el corpus extendido. La mejora se calcula como HDP-HMM truncado − HMM finito. 32

4.7 Ejemplos de resultados por obra en el corpus extendido. Se incluyen cuatro piezas de `MuseTrainer` y cuatro de `SymbTr` con distintas longitudes. 33

5.1 Protocolo ejecutado para la comparación predictiva 43

5.2 *Perplexity* media de prueba por fracción de entrenamiento. Menor es mejor; la última columna compara cada modelo consigo mismo entre los extremos de la curva. 45

5.3 Comparaciones pareadas de NLL por obra en la fracción completa. Los intervalos se obtuvieron mediante *bootstrap* y los valores *p* se ajustaron conjuntamente mediante Holm. 46
5.4 Costo medio observado en la fracción completa. Los tiempos de pared cruzan dispositivos distintos y no constituyen una comparación neutral de hardware. 47

Capítulo 1

Diseño computacional del sistema de modelado musical

La tesis parte de una pregunta matemática, pero su respuesta requiere también un sistema computacional. No basta definir una cadena de Markov oculta: es necesario leer partituras, convertirlas en secuencias comparables, ajustar modelos distintos y conservar evidencia suficiente para saber qué se comparó. Este capítulo presenta esa dimensión de diseño y anticipa las decisiones que organizan los experimentos posteriores.

El sistema construido no intenta elegir un modelo universal para música simbólica. Su propósito es más acotado: mostrar qué obtiene cada familia cuando recibe la misma representación y, al mismo tiempo, separar dos preguntas que con frecuencia se confunden. La primera pregunta es estructural y busca describir contextos latentes dentro de una obra. La segunda es predictiva y pregunta qué probabilidad recibe el siguiente evento musical. Un buen resultado en una de ellas no garantiza un buen resultado en la otra.

1.1 Problema de diseño

Una partitura contiene alturas, duraciones, voces, compases y otras indicaciones. Los modelos de esta tesis, sin embargo, necesitan una secuencia discreta. El primer problema de diseño consiste entonces en decidir qué información se conserva. Para la comparación común se utilizan clases de altura, lo que permite compartir un alfa-

beto entre una cadena de Markov oculta finita (HMM), su extensión mediante un proceso de Dirichlet jerárquico (HDP-HMM), un modelo de Markov de orden variable (VOMM) y un transformador causal. Esta simplificación vuelve posible la comparación, aunque deja fuera registro, duración y parte de la organización métrica.

El segundo problema consiste en mantener iguales las condiciones de evaluación. Si un arreglo de una obra aparece en entrenamiento y otra versión casi idéntica aparece en prueba, el resultado puede sobrestimar la capacidad de generalización. Por ello, las particiones se realizan por obra canónica y mantienen juntas sus variantes. También se audita que cada modelo puntúe exactamente los mismos eventos y que el símbolo de inicio se use como contexto, no como una nota adicional.

El tercer problema aparece al interpretar las salidas. HMM finito y HDP-HMM producen estados latentes; el transformador y el VOMM se incorporan principalmente como modelos predictivos. Comparar sólo la log-verosimilitud negativa por evento, o NLL, permitiría ordenar predicción, pero no descripción musical. El sistema conserva por ello un eje estructural separado, que requiere anotaciones externas antes de atribuir significado a los estados inferidos.

1.2 Requerimientos del sistema

En el plano funcional, el sistema debe leer archivos MusicXML y su variante comprimida MXL, normalizar las secuencias y generar una representación común W3C Music Notation Community Group (2021). Debe ajustar las cuatro familias sobre las mismas divisiones por obra, seleccionar configuraciones mediante validación y producir resultados agregados y por pieza. También debe registrar tiempos, dispositivo, complejidad y cobertura de los eventos evaluados.

La reproducibilidad añade otros requerimientos. Cada corrida debe conservar configuración, semillas, exclusiones y asignaciones de obras. Los cálculos largos necesitan puntos de reanudación para no repetir modelos ya terminados después de una interrupción. Las tablas del manuscrito deben proceder de artefactos versionados o estructurados y no de transcripción manual.

La interpretabilidad impone un requisito distinto. Una trayectoria con pocos estados puede ser compacta y aun así no coincidir con frases, acordes o secciones reconocibles. El sistema debe mantener separadas la ocupación latente, la calidad predictiva

y la correspondencia con anotaciones. En la corrida final sólo las dos primeras dimensiones quedaron disponibles; la evaluación estructural no pudo completarse porque faltó una referencia anotada.

1.3 Restricciones observadas

El corpus disponible es mayor que el que podía procesarse sin límite dentro del calendario experimental. La comparación final utilizó una muestra de 3000 archivos de PDMX Long et al. (2025); después del preprocesamiento quedaron 2933 piezas. Esta escala permitió construir curvas de aprendizaje, pero no equivale a utilizar la colección completa.

El hardware tampoco fue homogéneo. El transformador se ajustó en una unidad de procesamiento gráfico (GPU), mientras que HMM, HDP-HMM y VOMM se ejecutaron en unidades centrales de procesamiento (CPU). En esa configuración, el transformador tardó menos en ajustarse que ambos HMM. El resultado muestra que una arquitectura neuronal no es necesariamente la opción más lenta en tiempo de pared, aunque no permite una comparación neutral entre algoritmos porque los dispositivos son distintos.

La tercera restricción es estructural. El repositorio implementa métricas para fronteras y particiones, pero la corrida no contó con anotaciones musicales de referencia. En consecuencia, la comparación final pudo ordenar predicción y describir costo, pero no determinar qué modelo recupera mejor la organización de una obra.

1.4 Estándares y límites de uso

Los formatos simbólicos deben ser interoperables y conservar suficiente información para rastrear la procedencia de cada secuencia. MusicXML se diseñó como formato abierto de intercambio de partituras entre aplicaciones, y MXL conserva el mismo contenido dentro de un contenedor comprimido W3C Music Notation Community Group (2021). El corpus y las bibliotecas empleadas también están sujetos a condiciones de licenciamiento que deben respetarse al distribuir datos y artefactos.

En este trabajo, la reproducibilidad funciona como un estándar metodológico. No basta conservar el código que define un modelo; también deben registrarse el commit, la configuración, las semillas, el corpus efectivo y las exclusiones. Las pruebas unitarias demuestran contratos del programa, mientras que las conclusiones musi-

cales requieren corridas completas y artefactos revisables.

1.5 Modelos considerados

El HMM finito es la referencia de complejidad latente fijada. Su formulación es explícita y permite examinar matrices de transición, emisiones y trayectorias, pero obliga a seleccionar un número de estados. En la comparación predictiva final eligió siempre el máximo de 48 estados disponible en la rejilla. Por ello, su aparente meseta describe la configuración $K \leq 48$ y no toda la familia de HMM finitos.

El HDP-HMM truncado mantiene el esquema latente y permite que el número de estados ocupados sea menor que el techo computacional. En los experimentos descriptivos del Capítulo 4 obtuvo mayor log-verosimilitud y utilizó menos estados efectivos que el HMM finito sobre las mismas obras. En la evaluación predictiva fuera de muestra del Capítulo 5, en cambio, obtuvo peor NLL. Los dos resultados pueden coexistir porque ajuste sobre una obra, compacidad latente y predicción de obras reservadas son criterios diferentes.

El VOMM utiliza conteos de contextos observables de orden variable. Funciona como un control entre la memoria de primer orden y la atención: permite comprobar cuánto puede mejorar la predicción al extender el contexto sin introducir estados ocultos ni una red neuronal Begleiter, El-Yaniv, and Yona (2004). En la corrida final tuvo el menor tiempo de ajuste, aunque no alcanzó la mejor NLL.

El transformador causal asigna probabilidades al siguiente evento mediante mecanismos de atención aplicados al contexto anterior Vaswani et al. (2017). Esta arquitectura se ha utilizado también para modelar secuencias musicales simbólicas Huang et al. (2019). No produce una trayectoria discreta directamente comparable con los estados del HMM. En la corrida final obtuvo la menor *perplexity* desde la fracción 0.25 y siguió mejorando conforme aumentó el corpus. Este resultado lo favorece para la tarea predictiva estudiada, pero no establece que sus representaciones internas expliquen mejor la estructura musical.

1.6 Arquitectura implementada

La solución separa preparación, modelado y evaluación. Un primer componente lee las partituras, extrae clases de altura y registra exclusiones. Un segundo agrupa variantes por obra canónica y construye entrenamiento, validación y prueba. Un tercer

componente ajusta HMM finito, HDP-HMM, VOMM y transformador bajo una configuración compartida. El último reúne métricas, auditoría, tiempos, comparaciones por obra y puntos de reanudación.

Esta separación resultó necesaria durante la corrida larga. La caché evitó procesar de nuevo los 3000 archivos y los puntos de reanudación permitieron continuar después de una interrupción preventiva por temperatura. La auditoría de cobertura comprobó además que las diferencias de NLL no provinieran de puntuar eventos distintos entre modelos.

1.7 Estrategia y resultado de la comparación

La predicción del siguiente evento constituye la tarea común. Todos los modelos reciben la misma clase de altura observable, las mismas particiones por obra y los mismos reinicios de contexto. La NLL por evento es la métrica principal y la *perplexity* es su transformación exponencial. Los tiempos y las medidas de complejidad se reportan por separado porque no comparten una unidad que permita sumarlos de manera interpretable.

La comparación produjo un resultado condicionado al uso. El transformador fue el mejor predictor en las fracciones medias y grandes del corpus. El HMM finito fue el mejor de los dos modelos latentes en predicción, mientras que el HDP-HMM conservó la representación más compacta en los experimentos descriptivos del Capítulo 4. El VOMM ofreció el ajuste más rápido. Ninguno de estos resultados resuelve la pregunta estructural, que permanece sin evaluación externa.

La conclusión de diseño no es un único orden de modelos. Para anticipar la siguiente clase de altura en la escala estudiada, el transformador resulta preferible. Para examinar una trayectoria explícita de estados, HMM finito y HDP-HMM ofrecen objetos que el transformador no produce directamente, aunque falta validar su significado musical. El sistema permite conservar ambas conclusiones sin tratar predicción, compacidad e interpretación como si fueran la misma cantidad.

Capítulo 2
Preliminares

Una melodía se percibe como una sucesión organizada, no como una colección de notas independientes. Después de escuchar varios eventos se forman expectativas sobre lo que puede ocurrir a continuación, aunque esas expectativas no determinen una única continuación posible. Esta combinación de regularidad e incertidumbre permite plantear una primera pregunta matemática: ¿qué parte de la continuidad melódica puede describirse mediante probabilidades de transición? La relación entre expectativa musical y aprendizaje estadístico ha sido estudiada tanto desde la teoría musical como desde la cognición de la música Temperley (2007); Pearce and Wiggins (2012).

La pregunta necesita una representación antes de necesitar un modelo. Una partitura contiene alturas, duraciones, voces, compases y otros signos, pero una cadena de Markov opera sobre una sucesión de símbolos. Por ello, este capítulo comienza por precisar qué se observa y qué significa avanzar un paso en la secuencia. Después introduce la dependencia markoviana y muestra la limitación que conduce a los estados ocultos.

2.1 De la melodía a una secuencia

En esta tesis, la melodía se estudia a partir de partituras simbólicas. Cada nota seleccionada por el preprocesamiento produce un evento y el índice n indica su posición en ese orden. No se supone que dos índices consecutivos estén separados por

la misma duración física. Esta elección coincide con la comparación experimental del Capítulo 5, donde la tarea común es predecir la siguiente clase de altura. Duración, registro, dinámica y parte de la organización métrica quedan fuera de esa representación y, por tanto, también fuera de las conclusiones que pueden extraerse de ella.

La altura puede conservarse con distinto grado de detalle. Una nota con registro, como C_4, distingue octavas; una clase de altura identifica notas equivalentes módulo octava y representa ambas como C. Para la comparación común se utilizan las doce clases de altura del sistema cromático occidental. La Figura 2.1 muestra una octava del teclado y permite visualizar ese alfabeto antes de identificar las notas homónimas de otros registros.

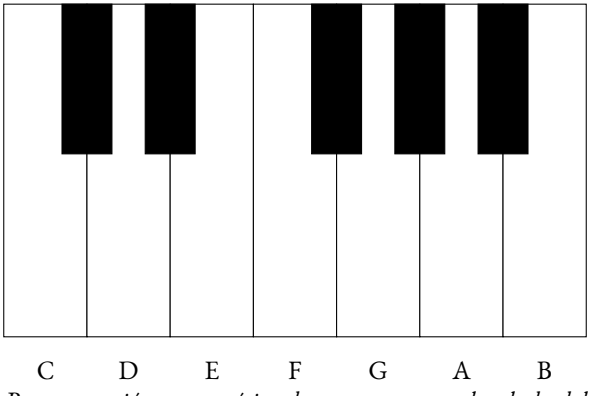


Figura 2.1: *Representación esquemática de una octava en el teclado del piano. Las teclas negras completan las doce clases de altura, aunque sólo se rotulan aquí las notas naturales.*

Sea S el alfabeto finito elegido. Una melodía queda representada como una sucesión

$$(X_n)_{n\geq 1}, \qquad X_n \in S,$$

donde X_n es la clase de altura observada en la posición n. Esta notación no afirma todavía que la melodía sea aleatoria en un sentido musical. Indica que se utilizará una distribución de probabilidad para describir qué continuaciones admite el modelo y con qué peso.

El modelo más simple asignaría a cada posición la misma distribución, con independencia de las notas anteriores. Esa hipótesis pierde la continuidad local que motivó la representación. En el extremo opuesto, condicionar cada nota en todo el historial produce un número de contextos que crece rápidamente y resulta difícil de estimar con datos limitados. La cadena de Markov de primer orden adopta una posición intermedia: conserva la nota presente y descarta el resto del pasado al calcular la siguiente transición.

Definición 2.1. *Sea* $(\Omega, \mathcal{F}, \mathbb{P})$ *un espacio de probabilidad. Una sucesión de variables aleatorias* $(X_n)_{n\geq 1}$ *con valores en un conjunto finito* S *es una* cadena de Markov *si, para todo* $n \geq 1$ *y para cualesquiera* $i_1, \ldots, i_n, j \in S$ *con probabilidad condicionante positiva,*

$$P(X_{n+1} = j \mid X_n = i_n, \ldots, X_1 = i_1) = P(X_{n+1} = j \mid X_n = i_n).$$

En el modelo melódico de primer orden, esta igualdad significa que la nota actual resume el contexto utilizado para predecir la siguiente. No afirma que la música real carezca de motivos, frases o dependencias a mayor distancia. La propiedad markoviana es una simplificación deliberada cuyo efecto puede medirse y compararse con modelos que conservan más contexto.

Si la cadena es homogénea, la probabilidad de pasar de i a j no depende de n y se denota por

$$P_{ij} = P(X_{n+1} = j \mid X_n = i).$$

Estas probabilidades satisfacen

$$P_{ij} \geq 0, \qquad \sum_{j \in S} P_{ij} = 1.$$

La matriz $\mathbf{P} = (P_{ij})_{i,j\in S}$ se denomina *matriz de transición* Ross (2014). Cada renglón responde una pregunta concreta: dada la nota representada por i, ¿cómo distribuye el modelo la probabilidad entre las notas que pueden seguirla?

Cuando se observa una secuencia y no se impone regularización, una estimación

elemental cuenta cuántas veces aparece cada par consecutivo (i, j) y divide por el número de transiciones que parten de i. Este cociente es el estimador de máxima verosimilitud de P_{ij}. Si un par no aparece, su estimación es cero; con corpus pequeños, esa ausencia puede reflejar falta de datos y no imposibilidad musical. Los capítulos posteriores introducen mecanismos probabilísticos que suavizan o comparten información entre estimaciones.

La matriz también permite estudiar el comportamiento agregado de la cadena. Un vector de probabilidad π es estacionario si

$$\pi = \pi \mathbf{P}.$$

En una cadena finita, irreducible y aperiódica, existe una única distribución estacionaria y

$$\lim_{n \to \infty} P(X_n = j \mid X_1 = i) = \pi_j.$$

Bajo esas condiciones, π_j describe el peso de largo plazo del símbolo j dentro del modelo. Esta interpretación pertenece a la cadena estimada; no basta por sí sola para identificar tonalidad, función armónica o estilo.

2.3 De la nota observable al contexto latente

Hasta aquí, el estado de la cadena coincide con la nota observada. Esa identificación vuelve explícita la dependencia entre notas consecutivas, pero no representa un contexto que persista mientras cambian las observaciones. Una misma nota puede aparecer en regiones armónicas distintas y un mismo acorde puede admitir varias notas. Por ello, la nota actual no determina de manera unívoca la organización que se desea estudiar Temperley (2007).

La siguiente extensión separa ambos niveles. La nota pasa a ser una observación y se introduce otra variable para representar un contexto latente que evoluciona en el tiempo. Ese contexto puede examinarse después como candidato armónico o estructural, pero el modelo no le asigna automáticamente una etiqueta musical. El Capítulo 3 formaliza esta separación mediante una cadena de Markov oculta y desarrolla los algoritmos necesarios para evaluar, aprender y decodificar el modelo.

Capítulo 3

Cadenas de Markov ocultas y modelado computacional

El capítulo anterior identificó el estado de una cadena de Markov con la nota observada. Esta elección permite describir transiciones locales, pero obliga a tratar dos apariciones de la misma nota como el mismo contexto. Musicalmente, la simplificación es restrictiva: una clase de altura puede cumplir papeles distintos según la región tonal o armónica en la que aparece.

Una cadena de Markov oculta, o HMM por sus siglas en inglés, separa ambos niveles. La secuencia de notas permanece observable, mientras otra cadena representa el contexto que cambia a lo largo del tiempo. La idea es sencilla: el contexto actual influye en la distribución de la nota y también en el contexto que puede seguir. La definición matemática precisa esa dependencia y conduce a tres preguntas computacionales: evaluar una secuencia, reconstruir una trayectoria latente y aprender los parámetros del modelo Rabiner (1989); Cappé, Moulines, and Rydén (2005).

3.1 Dos procesos y una misma secuencia

Definición 3.1. *Sea* $(\Omega, \mathcal{F}, \mathbb{P})$ *un espacio de probabilidad. Una* cadena de Markov oculta *está formada por dos procesos estocásticos en tiempo discreto,*

$$(X_t)_{t\geq 1}, \qquad (Y_t)_{t\geq 1},$$

donde X_t toma valores en un espacio finito de estados ocultos

$$\mathcal{S} = \{1, \ldots, N\},$$

y Y_t toma valores en un espacio discreto de observaciones

$$\mathcal{V} = \{v_1, \ldots, v_M\}.$$

El proceso (X_t) satisface la propiedad de Markov y, condicionado en X_t, el valor de Y_t es independiente de los demás estados y observaciones. El modelo se especifica mediante

$$\pi_i = P(X_1 = i), \qquad a_{ij} = P(X_t = j \mid X_{t-1} = i), \quad t \geq 2, \qquad b_j(v) = P(Y_t = v \mid X_t = j), \quad t \geq 1.$$

Los tres grupos de probabilidades se reúnen en

$$\lambda = (\pi, \mathbf{A}, \mathbf{B}).$$

El vector π describe el estado inicial, el renglón i de $\mathbf{A}$ distribuye la probabilidad del siguiente estado cuando el actual es i y el renglón j de $\mathbf{B}$ distribuye las observaciones que puede emitir el estado j. Cada vector es una distribución de probabilidad:

$$\sum_{i=1}^{N} \pi_i = 1, \qquad \sum_{j=1}^{N} a_{ij} = 1, \qquad \sum_{v \in \mathcal{V}} b_j(v) = 1.$$

En la lectura musical, Y_t es la clase de altura registrada y X_t es un contexto latente. Puede resultar útil examinar ese contexto como candidato a región armónica, acorde o función, y los HMM se han utilizado para tareas de segmentación y reconocimiento de acordes Sheh and Ellis (2003). Sin embargo, un ajuste no supervisado no asigna por sí solo esos nombres. Los estados son etiquetas estadísticas y su interpretación exige observar sus emisiones, sus transiciones y, cuando exista, su correspondencia con anotaciones externas.

La distribución conjunta de una trayectoria $x_{1:T}$ y una secuencia observada $y_{1:T}$ se

factoriza como

$$P(X_{1:T} = x_{1:T}, Y_{1:T} = y_{1:T} \mid \lambda) = \pi_{x_1} b_{x_1}(y_1) \prod_{t=2}^{T} a_{x_{t-1}x_t} b_{x_t}(y_t).$$

La expresión puede leerse de izquierda a derecha. Primero se elige el estado inicial; después, cada paso combina una transición latente y una emisión observable. Esta factorización es la que permite sustituir una enumeración exponencial de trayectorias por algoritmos de programación dinámica.

Aunque (X_t) sea una cadena de Markov, el proceso observable (Y_t) no tiene por qué serlo. Las observaciones anteriores aportan información sobre el estado oculto actual y esa información puede cambiar la distribución de la siguiente nota. Al considerar el par (X_t, Y_t) se recupera una cadena de Markov en el espacio producto. El Apéndice B demuestra ambos resultados y presenta el caso límite en el que la observación determina el estado oculto.

3.2 Tres problemas computacionales

Una vez especificada la forma del HMM, todavía falta decidir qué se quiere obtener de él. La literatura distingue tres problemas clásicos Rabiner (1989). La *evaluación* calcula la probabilidad de una secuencia bajo parámetros conocidos. La *decodificación* busca una trayectoria latente compatible con las observaciones. El *aprendizaje* estima los parámetros a partir de datos cuando los estados no se observan. Los tres aparecen en esta tesis: la log-verosimilitud permite comparar ajustes, Viterbi produce trayectorias para inspección y Baum-Welch ajusta el HMM finito de la comparación final.

3.2.1 Evaluación mediante el algoritmo hacia adelante

Dado un modelo λ y una secuencia $y_{1:T}$, el problema de evaluación consiste en calcular

$$P(y_{1:T} \mid \lambda).$$

La suma directa contiene una contribución por cada una de las N^T trayectorias ocultas posibles. El algoritmo hacia adelante evita enumerarlas porque reúne en una sola

cantidad todas las trayectorias que terminan en el mismo estado. Se define

$$\alpha_t(j) = P(Y_{1:t} = y_{1:t}, X_t = j \mid \lambda).$$

La inicialización y la recurrencia son

$$\alpha_1(j) = \pi_j b_j(y_1),$$

$$\alpha_{t+1}(j) = b_j(y_{t+1}) \sum_{i=1}^{N} \alpha_t(i) a_{ij}.$$

Al finalizar,

$$P(y_{1:T} \mid \lambda) = \sum_{j=1}^{N} \alpha_T(j).$$

El costo es $O(TN^2)$. En secuencias largas, las multiplicaciones de probabilidades pequeñas pueden producir subdesbordamiento numérico; por ello, las implementaciones suelen reescalar las variables o trabajar en dominio logarítmico Rabiner (1989); Cappé, Moulines, and Rydén (2005).

La cantidad $\alpha_t(j)$ no es todavía la probabilidad posterior del estado j, pues incluye la probabilidad conjunta de las observaciones parciales. Aun así, permite una lectura intuitiva: acumula el peso de todas las explicaciones latentes que llegan al estado j después de observar los primeros t símbolos.

3.2.2 Decodificación mediante Viterbi

La evaluación suma sobre todas las trayectorias; la decodificación formula otra pregunta. Dada la secuencia, ¿qué trayectoria maximiza la probabilidad conjunta con las observaciones? Como $P(y_{1:T} \mid \lambda)$ es constante respecto de la trayectoria, maximizar la probabilidad conjunta equivale a maximizar la probabilidad posterior de la trayectoria completa.

El algoritmo de Viterbi conserva, para cada estado final, sólo el mejor camino parcial. Se define

$$\delta_t(j) = \max_{x_{1:t-1}} P(X_{1:t-1} = x_{1:t-1}, X_t = j, Y_{1:t} = y_{1:t} \mid \lambda),$$

con

$$\delta_1(j) = \pi_j b_j(y_1)$$

y

$$\delta_t(j) = b_j(y_t) \max_{i \in \mathcal{S}} \delta_{t-1}(i) a_{ij}.$$

Además del valor máximo se guarda el estado que lo alcanza, lo que permite reconstruir la trayectoria mediante un recorrido hacia atrás.

Algorithm 1 Algoritmo de Viterbi

Require: Observaciones $O = (o_1, \ldots, o_T)$, estados $\mathcal{S} = \{1, \ldots, N\}$ y parámetros (π, A, B)

Ensure: Trayectoria más probable $X^* = (x_1^*, \ldots, x_T^*)$

Inicialización
for $j = 1$ **to** N **do**
    $\delta_1(j) \leftarrow \pi_j b_j(o_1)$
    $\psi_1(j) \leftarrow 0$
end for

Recursión
for $t = 2$ **to** T **do**
    for $j = 1$ **to** N **do**
        $\delta_t(j) \leftarrow \max_{1 \le i \le N} \left[\delta_{t-1}(i) a_{ij}\right] b_j(o_t)$
        $\psi_t(j) \leftarrow \arg\max_{1 \le i \le N} \left[\delta_{t-1}(i) a_{ij}\right]$
    end for
end for

Terminación y retroceso
$x_T^* \leftarrow \arg\max_{1 \le j \le N} \delta_T(j)$
for $t = T-1, T-2, \ldots, 1$ **do**
    $x_t^* \leftarrow \psi_{t+1}(x_{t+1}^*)$
end for
return X^*

Viterbi produce una explicación óptima bajo el modelo, no una verdad musical observada. Puede haber otras trayectorias con probabilidad cercana y la identidad numérica de un estado no contiene una etiqueta armónica. En los capítulos experimentales, la trayectoria se utiliza para contar estados ocupados y visualizar transiciones; cualquier interpretación estructural más fuerte queda condicionada a una referencia externa.

3.2.3 Aprendizaje mediante Baum-Welch

En una aplicación real suelen conocerse las notas, pero no la trayectoria que las generó. El problema de aprendizaje consiste en estimar λ a partir de una o varias secuencias observadas. Si los estados fueran conocidos, bastaría contar inicios, transiciones y emisiones. Como están ocultos, el algoritmo de Baum-Welch utiliza el esquema de esperanza-maximización: reemplaza los conteos desconocidos por sus valores esperados bajo los parámetros actuales y después vuelve a normalizarlos Rabiner (1989).

En la iteración r, el paso de esperanza calcula probabilidades posteriores de estados y transiciones mediante los recorridos hacia adelante y hacia atrás. El paso de maximización elige parámetros que maximizan la esperanza de la log-verosimilitud completa,

$$\lambda^{(r+1)} = \arg\max_{\lambda} \mathbb{E}_{X|Y,\lambda^{(r)}} \left[\log P(X, Y \mid \lambda)\right].$$

Cada iteración no reduce la log-verosimilitud observada, pero el resultado puede depender de la inicialización y no tiene garantía de ser el máximo global. Esta limitación explica el uso de varias semillas y de un conjunto de validación en la comparación experimental.

Baum-Welch estima probabilidades para un número N de estados ya fijado. No responde cuántos estados debe tener el modelo. Aumentar N ofrece más capacidad, pero también cambia el costo, la estabilidad del ajuste y la facilidad con la que los estados pueden reutilizarse. El ejercicio siguiente permite observar una consecuencia concreta de esa decisión.

3.3 Una comprobación manual sobre el Preludio en Do mayor

Antes de abandonar el modelo finito conviene observar un ejercicio pequeño en el que la trayectoria inferida pueda contrastarse con una lectura de la partitura. Se utilizó el *Preludio en Do mayor*, BWV 846, de J. S. Bach. La sucesión armónica de

referencia se identificó manualmente; a partir de ella se contaron transiciones entre acordes y cada renglón se normalizó para obtener una matriz de probabilidades. Esta matriz no constituye una verdad musical única: resume una lectura concreta de la obra y depende de las decisiones tomadas al asignar los acordes.

El ejercicio utilizó un HMM con distribución inicial uniforme y una matriz de transición a priori que favorece la permanencia. Para N estados se fijó

$$A_{ii} = \frac{\alpha}{\alpha + (N-1)\beta}, \qquad A_{ij} = \frac{\beta}{\alpha + (N-1)\beta}, \quad i \neq j, \tag{3.1}$$

con $\alpha = 210$, $\beta = 1$ y $\pi_i = 1/N$. El registro textual del ejercicio indica $N = 24$; las imágenes conservadas muestran diez etiquetas armónicas. Como no se preservó la hoja intermedia de conteos, no puede establecerse a partir de las figuras si esas diez etiquetas corresponden a una restricción del vocabulario completo o a la selección final utilizada para visualizarlo. La comparación siguiente se limita, por ello, a las diez etiquetas efectivamente mostradas.

Una vez aplicada la decodificación de Viterbi, se contaron las transiciones de la trayectoria inferida y se normalizaron del mismo modo. Las Figuras 3.1 y 3.2 presentan ambas matrices por separado para conservar la legibilidad de las celdas. Las versiones limpias transcriben los valores impresos en las imágenes originales; no reemplazan el conteo manual ni añaden precisión a sus dos decimales.

La diagonal domina en las dos matrices: una vez asignado un acorde, la siguiente posición suele conservar la misma etiqueta. Varias transiciones fuera de la diagonal también aparecen en ambas. La discrepancia principal se concentra en `E min`. La referencia manual le asigna probabilidad 0.92 de permanencia y 0.08 de transición a `F Maj`, mientras que la trayectoria inferida no visita ese estado. Esta ausencia deja un renglón sin conteos y muestra de manera concreta el problema que motivó el ejercicio: un estado previsto por el vocabulario puede no aparecer en la decodificación.

La Figura 3.3 conserva la matriz de diferencias absolutas registrada durante el ejercicio. Sus valores se transcribieron directamente de la imagen histórica. No se recalcularon restando las cifras visibles de las otras dos matrices, porque esas cifras ya están

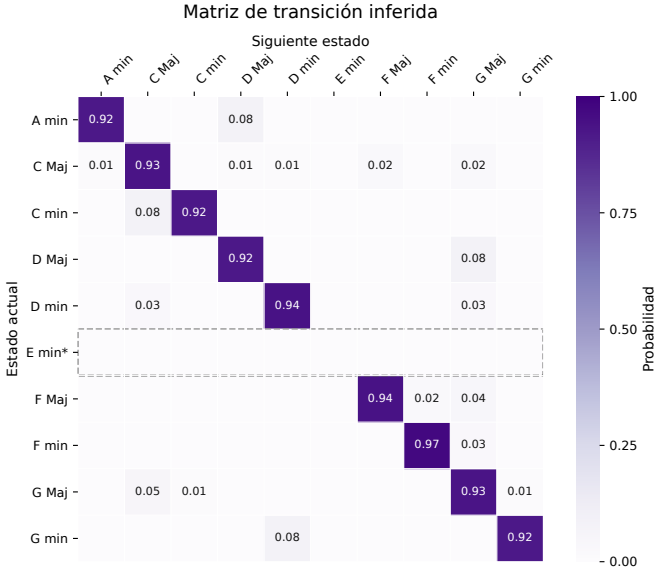


Figura 3.1: *Matriz obtenida de la trayectoria inferida para el Preludio en Do mayor. El marco discontinuo identifica el renglón de* `E min`*, para el cual no se registraron transiciones inferidas. Las celdas sin cifra representan valores registrados como cero.*

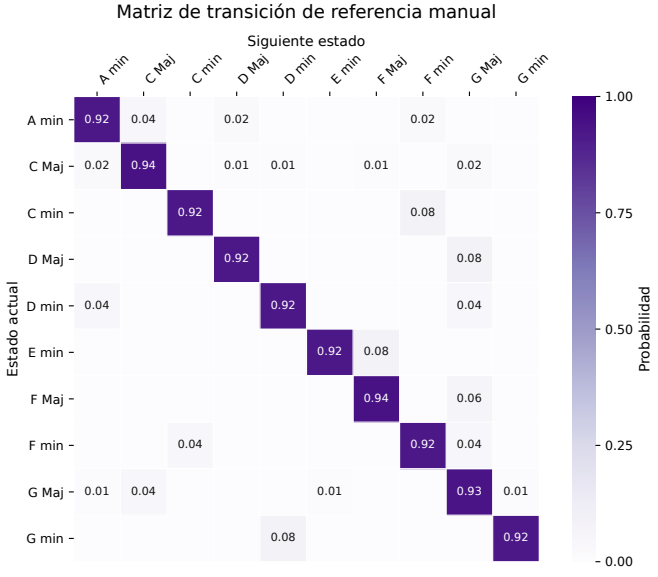


Figura 3.2: *Matriz construida mediante etiquetado y conteo manual de la partitura del Preludio en Do mayor. Las celdas sin cifra representan valores registrados como cero.*

redondeadas y no reproducen todas las diferencias de la hoja de cálculo original.

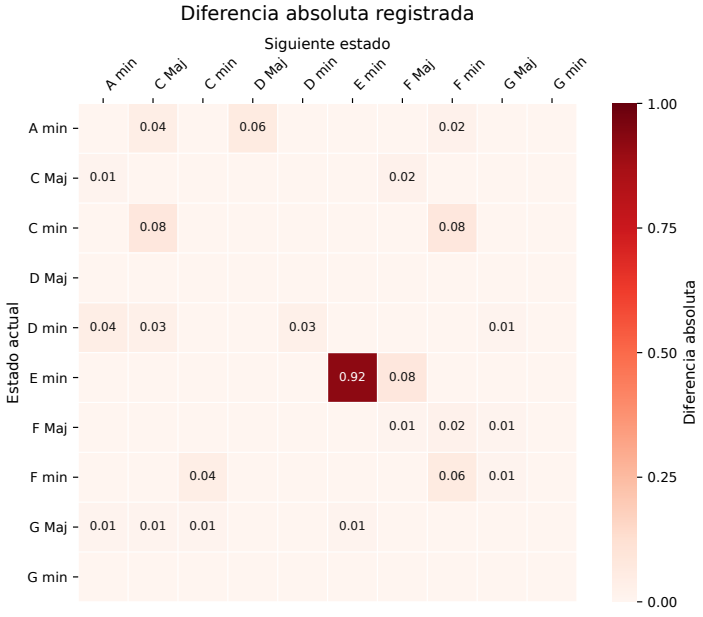


Figura 3.3: *Diferencia absoluta registrada entre la matriz inferida y la referencia manual. Las celdas sin cifra representan diferencias registradas como cero.*

El conteo manual registró 30 cambios de acorde en la referencia y 27 en la trayectoria inferida. De esos 27 cambios inferidos, 22 coincidieron con la referencia. Las razones $27/30 = 0.90$ y $22/27 \approx 0.815$ describen, respectivamente, la cantidad relativa de cambios producidos y la proporción de cambios inferidos que coincidió con el ejercicio manual. La primera no debe interpretarse como una tasa de detección, pues cinco cambios inferidos no coincidieron con la referencia. Tampoco se dispone de un segundo anotador ni de una regla de tolerancia documentada para coincidencias cercanas.

El ejemplo cumple una función diagnóstica, no comparativa. Muestra que el HMM puede reproducir algunas regularidades de una organización armónica propuesta y, al mismo tiempo, omitir por completo uno de sus estados. Una sola obra y una sola anotación manual no permiten generalizar esa proporción ni atribuir el desacuerdo exclusivamente al número de estados. Sí permiten formular con mayor precisión la

pregunta siguiente: ¿qué ocurre cuando el tamaño del vocabulario latente deja de tratarse como una cantidad conocida de antemano?

3.4 El límite del número fijo de estados

El HMM finito ya separa observación y contexto latente, y sus algoritmos permiten ajustar y examinar esa separación. Sin embargo, antes de ejecutar cualquiera de ellos se debe elegir

$$\mathcal{S} = \{1, \ldots, N\}.$$

Un valor pequeño puede reunir comportamientos distintos; uno grande puede repartir la misma regularidad entre estados redundantes. La selección por validación permite comparar algunos valores de N, pero sigue exigiendo una rejilla finita y un techo decidido por anticipado.

El Capítulo 4 mantiene la misma intuición generativa y modifica esa decisión. En lugar de afirmar que la obra contiene exactamente N contextos, introduce una colección abierta de estados potenciales y deja que la inferencia ocupe sólo una parte. El paso conduce al proceso de Dirichlet jerárquico y, para el cálculo, a su aproximación truncada.

Capítulo 4
Cadenas de Markov ocultas infinitas

En el capítulo anterior se introdujo una cadena de Markov oculta con N estados. Las notas forman la secuencia observable y los estados representan contextos musicales que no aparecen escritos de manera directa en la partitura. Una vez fijado N, pueden estimarse transiciones, emisiones y trayectorias latentes. Queda, sin embargo, una decisión previa: ¿cuántos contextos deben permitirse?

La respuesta no es evidente incluso en un ejemplo sencillo. Si se permiten muy pocos estados, el modelo puede reunir bajo una misma etiqueta regiones musicales que se comportan de manera distinta. Si se permiten demasiados, una regularidad que debería repetirse puede quedar repartida entre varios estados casi redundantes. El número de estados no es entonces un detalle de implementación, pues determina el nivel de resolución con el que se describe la obra.

Este capítulo conserva la separación entre proceso latente y observación, pero deja de tratar N como una cantidad conocida. La pregunta es si el modelo puede mantener un conjunto amplio de estados potenciales y utilizar sólo aquellos que la secuencia necesita. Para llegar a esa formulación conviene comenzar con un vocabulario finito y observar cómo crece.

Como ejemplo conceptual, supóngase que cada estado oculto debe corresponder a un acorde. El HMM clásico exige fijar primero un conjunto finito S de acordes per-

mitidos y después identificar el espacio de estados ocultos con

$$\mathcal{S} = \{1, 2, \ldots, N\}, \qquad N = |S|.$$

La elección de S determina la dimensión de la distribución inicial π, de la matriz de transición $\mathbf{A}$ y de la familia de emisiones $\mathbf{B}$. Una manera de construir ese vocabulario consiste en usar pares de la forma

$$(\text{fundamental, plantilla armónica}).$$

El primer componente indica la fundamental y el segundo la cualidad armónica.

Sea

$$\mathcal{R} = \{C, C^\sharp, D, E^\flat, E, F, F^\sharp, G, A^\flat, A, B^\flat, B\}$$

el conjunto de clases de altura fundamentales. Sea además

$$\mathcal{Q} = \left\{ \begin{array}{l} \text{Maj, min, dim, aug,} \\ \text{Maj7, 7, m7, m(Maj7), } \varnothing\text{7, dim7,} \\ \text{6, m6, add9, madd9, 6/9,} \\ \text{sus2, sus4, 7sus4,} \\ \text{Maj9, 9, m9} \end{array} \right\}$$

una familia de plantillas que distingue triadas, séptimas, suspensiones y extensiones.

Se define entonces

$$S = \mathcal{R} \times \mathcal{Q}.$$

En consecuencia,

$$|S| = 12 \times 21 = 252.$$

El ejemplo produce 252 acordes posibles antes de observar una sola nota. No se utiliza después como una lista de etiquetas verdaderas para los experimentos, cuyos estados latentes permanecen sin nombre y cuyas observaciones son clases de altura. Su función es mostrar cómo una decisión musical razonable puede generar rápidamente un espacio grande y, aun así, no indicar cuántos estados necesita una obra concreta. El paso siguiente consiste en separar el número de estados potenciales del

número de estados que el modelo utiliza efectivamente.

4.1 Del número fijo a una colección abierta de estados

Los modelos bayesianos no paramétricos permiten formalizar esta idea. El término *no paramétrico* puede resultar engañoso: el modelo sí tiene parámetros, pero el número de componentes que utiliza no queda fijado antes de observar los datos. En este caso se parte de una colección numerable de estados potenciales y se asigna mayor probabilidad a unos que a otros mediante un proceso de Dirichlet Ferguson (1973); Sethuraman (1994). El Apéndice A desarrolla el paso desde una distribución de Dirichlet finita hasta esta construcción.

La extensión conserva el HMM del capítulo anterior y modifica únicamente su espacio de estados. En lugar de usar $\{1, \dots, N\}$, se considera

$$\mathcal{S} = \mathbb{N}.$$

La propiedad de Markov no cambia. El siguiente estado depende del estado presente y la observación depende del estado latente actual. La diferencia es que ya no se reserva de antemano un número exacto de contextos.

Definición 4.1. *Una* cadena de Markov oculta infinita *está determinada por dos procesos estocásticos en tiempo discreto*

$$(X_t)_{t\geq 1}, \qquad (Y_t)_{t\geq 1},$$

donde (X_t) toma valores en $\mathbb{N}$ y (Y_t) toma valores en un espacio de observaciones $\mathcal{V}$. Se fija una distribución inicial

$$\pi = (\pi_i)_{i\geq 1},$$

una matriz de transición infinita

$$\mathbf{A} = (a_{ij})_{i,j\geq 1},$$

y una familia de distribuciones de emisión

$$\mathbf{B} = (b_j)_{j \geq 1},$$

de modo que, para todo $i, j \geq 1$ *y todo* $v \in \mathcal{V}$*,*

$$P(X_1 = i \mid \pi) = \pi_i,$$

$$P(X_t = j \mid X_{t-1} = i, \mathbf{A}) = a_{ij}, \quad t \geq 2, \qquad P(Y_t = v \mid X_t = j, \mathbf{B}) = b_j(v), \quad t \geq 1,$$

con

$$\sum_{i=1}^{\infty} \pi_i = 1, \qquad \sum_{j=1}^{\infty} a_{ij} = 1, \qquad \sum_{v \in \mathcal{V}} b_j(v) = 1.$$

La definición anterior parece una ampliación menor, pero plantea una dificultad concreta. Cada renglón de $\mathbf{A}$ debe asignar probabilidad a la misma colección de estados para que el estado j signifique lo mismo desde cualquier estado de origen. El proceso de Dirichlet jerárquico resuelve este problema mediante una distribución global compartida. En el contexto de cadenas ocultas, esta construcción da lugar al HMM basado en un proceso de Dirichlet jerárquico, o HDP-HMM, y constituye una realización de la cadena de Markov oculta infinita, abreviada iHMM Beal, Ghahramani, and Rasmussen (2002); Teh et al. (2006).

La distribución global puede imaginarse como una barra de longitud uno que se rompe sucesivamente. El primer fragmento recibe peso β_1; del resto se obtiene β_2, y así sucesivamente. Los fragmentos forman una distribución de probabilidad sobre los estados potenciales. En lo que sigue, $DP(c, H)$ denota un proceso de Dirichlet con concentración c y medida base H; la abreviatura *i.i.d.* indica variables independientes con la misma distribución. Formalmente, se escribe

$$\beta = \sum_{k=1}^{\infty} \beta_k \delta_k,$$

donde

$$\beta_k = v_k \prod_{\ell=1}^{k-1} (1 - v_\ell), \qquad v_k \overset{\text{i.i.d.}}{\sim} \text{Beta}(1, \gamma), \qquad k \geq 1,$$

y se supone que

$$\pi \mid \beta \sim DP(\alpha_0, \beta), \qquad A_i \mid \beta \sim DP(\alpha, \beta), \qquad i \geq 1,$$

donde A_i es el renglón i-ésimo de $\mathbf{A}$.

$$\mathbb{E}[a_{ij} \mid \beta] = \beta_j.$$

La distribución global β funciona como un catálogo compartido. Cada renglón A_i puede favorecer transiciones distintas, pero todos se refieren a los mismos estados y parten de los pesos globales β_j. En una lectura musical, un contexto ya utilizado puede reaparecer desde distintas regiones de la obra y un contexto nuevo conserva una probabilidad pequeña, pero positiva, de incorporarse.

El alfabeto observable no necesita crecer junto con los estados. Si $\mathcal{V}$ contiene doce clases de altura, cada contexto latente puede conservar una distribución categórica sobre esas mismas doce posibilidades. Lo desconocido es cuántos contextos hacen falta para organizar la secuencia, no cuántos símbolos pueden observarse.

El calificativo "infinito" describe la colección disponible, no el número de estados que aparecerán en una obra finita. Una trayectoria de longitud T puede visitar, como máximo, T estados y normalmente utiliza muchos menos. La ventaja conceptual consiste en no decidir ese número antes del ajuste. Aun así, los estados obtenidos siguen siendo categorías estadísticas sin una etiqueta musical garantizada; su interpretación requiere examinar emisiones, transiciones y correspondencia con una referencia externa.

4.2 Del modelo infinito a un cálculo finito

Una computadora no puede almacenar una matriz con infinitos renglones y columnas. La implementación introduce entonces un techo K y aproxima la colección numerable mediante los estados $1, \ldots, K$ Ishwaran and James (2001); Fox et al. (2011); Van Gael et al. (2008). El objetivo no es afirmar que la obra tiene exactamente K contextos, sino elegir un techo suficientemente alto y permitir que la inferencia deje estados sin usar.

Definición 4.2. *Fijado un entero $K \geq 2$, un* HDP-HMM truncado *con espacio*

observable discreto $\mathcal{V} = \{1, \dots, V\}$ *queda determinado por las variables aleatorias*

$$v_k \sim \text{Beta}(1, \gamma), \qquad k = 1, \dots, K-1,$$

$$\beta_k = v_k \prod_{\ell=1}^{k-1} (1 - v_\ell), \qquad k = 1, \dots, K-1,$$

$$\beta_K = \prod_{\ell=1}^{K-1} (1 - v_\ell),$$

por el vector global $\beta = (\beta_1, \dots, \beta_K)$ *y por las distribuciones condicionadas*

$$\pi \mid \beta \sim \text{Dir}(\alpha_0 \beta_1, \dots, \alpha_0 \beta_K),$$

$$A_i \mid \beta \sim \text{Dir}(\alpha\beta + \varkappa e_i), \qquad i = 1, \dots, K,$$
$$\varphi_i \sim \text{Dir}\left(\frac{\eta}{V}, \dots, \frac{\eta}{V}\right), \qquad i = 1, \dots, K,$$

donde e_i *denota el i-ésimo vector canónico de* $\mathbb{R}^K$*. Si* $\text{Cat}(p)$ *denota la distribución categórica con vector de probabilidades p, la cadena latente y las observaciones satisfacen*

$$X_1 \mid \pi \sim \text{Cat}(\pi), \qquad X_t \mid X_{t-1} = i, \mathbf{A} \sim \text{Cat}(A_i),$$

$$Y_t \mid X_t = i, \varphi_i \sim \text{Cat}(\varphi_i), \qquad t \geq 1.$$

La notación compacta permite separar el techo computacional de los estados que la trayectoria ocupa efectivamente.

La formulación conserva la lógica del modelo infinito dentro de ese techo. β reparte el peso global entre los K estados; γ influye en cómo se reparte ese peso; α_0 regula la distribución inicial y α permite que cada renglón de transición se aparte del patrón global. El parámetro $\varkappa$ puede favorecer la permanencia en el mismo estado, mientras que η controla la concentración de las emisiones sobre el alfabeto observable.

Una vez fijado K, las transiciones y emisiones vuelven a representarse mediante matrices finitas. Para una secuencia de longitud T, el costo dominante es del orden de $O(TK^2)$, pues en cada posición deben considerarse transiciones entre pares de estados. Así, un techo innecesariamente grande no es gratuito. Un techo demasiado

pequeño, en cambio, puede convertirse en una restricción activa.

En los experimentos se denomina *estado efectivo* a un estado que aparece ocupado en la trayectoria inferida. Esta cuenta permite comprobar si el modelo utiliza una parte pequeña del techo disponible, pero no mide por sí misma calidad musical. Dos estados efectivos pueden separar contextos útiles o dividir arbitrariamente una misma región; esa diferencia sólo puede establecerse mediante interpretación o anotaciones externas.

En esta tesis, las observaciones son clases de altura y el iHMM conserva un papel conceptual. El HDP-HMM truncado es la realización computacional que se ajusta sobre las obras y se compara con el HMM finito. Antes de ampliar la evaluación a un corpus, conviene observar cómo cambia la trayectoria en una sola pieza extensa.

4.3 De una obra al corpus

Antes de calcular promedios conviene observar una obra en la que la diferencia entre trayectorias pueda verse con detalle. Se utiliza como caso ilustrativo el tercer movimiento de la Sonata no. 14 de Beethoven, una de las piezas extensas del corpus, con 4133 notas y 201 compases. Este ejemplo ayuda a leer las salidas, pero no constituye por sí solo evidencia general a favor de un modelo.

Las tablas y figuras de este capítulo son exportaciones versionadas de corridas anteriores del repositorio experimental. La copia actual conserva el código que las generó, pero no los CSV primarios de esas corridas. Por ello, las cifras pueden auditarse contra las exportaciones incluidas en la tesis, aunque una reproducción completa requiere recuperar los artefactos estructurados. El Capítulo 5 dispone de un reporte fijado por commit y documenta por separado la misma limitación para sus CSV y JSON.

La Tabla 4.1 compara log-verosimilitud, estados ocupados y segmentos contiguos de la trayectoria. Un segmento es una sucesión de posiciones consecutivas a las que el modelo asigna el mismo estado; un cambio de estado inicia el siguiente. Para una misma secuencia, una log-verosimilitud mayor, es decir, menos negativa, indica que el modelo asigna más probabilidad a las observaciones. La magnitud depende de la longitud de la pieza, de modo que estos valores no deben compararse directamente entre obras de tamaños distintos.

Modelo	$\log L$	Estados	Segmentos	Long. media
HMM finito	-10242.186	88	560	7.380
HDP-HMM truncado	-7834.175	9	1075	3.845

Tabla 4.1: *Comparación entre el HMM finito y el HDP-HMM truncado sobre la obra ancla: el tercer movimiento de la Sonata no. 14 de Beethoven.*

La diferencia tiene dos componentes. El HMM finito ocupa 88 estados y obtiene log-verosimilitud -10242.186; el HDP-HMM ocupa 9 y obtiene -7834.175, una ganancia de 2408.011 unidades. Sin embargo, el modelo truncado produce 1075 segmentos, frente a 560 del HMM, y su longitud media es menor. En esta obra, reducir el vocabulario de estados no equivale a producir menos cambios: el HDP-HMM reutiliza un conjunto pequeño de etiquetas con mayor frecuencia.

El caso singular sugiere una diferencia, pero todavía puede depender de las particularidades de la sonata. El siguiente paso utiliza seis piezas breves y permite comprobar si el mismo patrón aparece en un conjunto controlado antes de ampliar el repertorio.

4.3.1 Resultados sobre un subconjunto clásico

La comparación controlada utiliza las seis piezas breves de la Tabla 4.2. Las observaciones son clases de altura. Para el HDP-HMM se fija $K = 12$, con $\alpha = 8$, $\alpha_0 = 4$, $\gamma = 2$, $\eta = 1$ y $\varkappa = 0$. La inferencia realiza veinte iteraciones, descarta las diez primeras como calentamiento y utiliza semilla 7. Estos valores documentan la configuración de la corrida, pero no constituyen una búsqueda exhaustiva de hiperparámetros ni sustituyen los artefactos primarios faltantes.

Obra	Compositor	Notas	Compases
Cumpleaños feliz (Do mayor)	Tradicional	37	8
Oda a la alegría (variación fácil)	Desconocido	87	17
Para Elisa (versión fácil)	Beethoven	103	22
Cumpleaños feliz (arreglo)	Manjuprasad	106	19
Para Elisa (piano para principiantes)	Beethoven	149	23
Greensleeves	Desconocido	166	33

Tabla 4.2: *Subconjunto clásico limitado utilizado para la comparación documentada entre el HMM finito y el HDP-HMM truncado.*

La Tabla 4.3 reúne los resultados. En las seis obras, el modelo truncado obtiene una log-verosimilitud mayor que el HMM finito. La ganancia media es de 92.970 unidades y la mediana de 98.739. Al mismo tiempo, el HDP-HMM ocupa en

promedio 6.667 estados, frente a 10.833 del HMM finito.

Métrica	Valor
Obras comparables	6
Casos en que el HDP-HMM truncado mejora	6
Casos en que el HDP-HMM truncado empeora	0
Empates	0
Ganancia media de log-verosimilitud	92.970
Ganancia mediana de log-verosimilitud	98.739
Media de log-verosimilitud del HMM finito	-267.685
Media de log-verosimilitud del HDP-HMM truncado	-174.715
Estados activos medios del HMM finito	10.833
Estados efectivos medios del HDP-HMM truncado	6.667

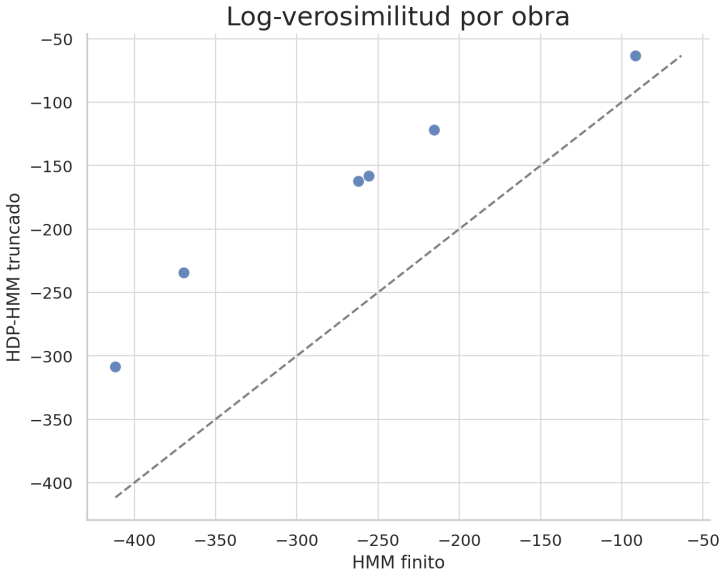
Tabla 4.3: *Resumen agregado de la comparación entre el HMM finito y el HDP-HMM truncado sobre el subconjunto clásico limitado.*

La Tabla 4.4 permite ver cómo se forma ese promedio. La ganancia no tiene la misma magnitud en todas las piezas, pero siempre es positiva dentro de este conjunto. Como sólo se consideran seis obras y se evalúa ajuste sobre las secuencias analizadas, el patrón debe leerse como un resultado descriptivo de la corrida, no como una prueba general de superioridad predictiva.

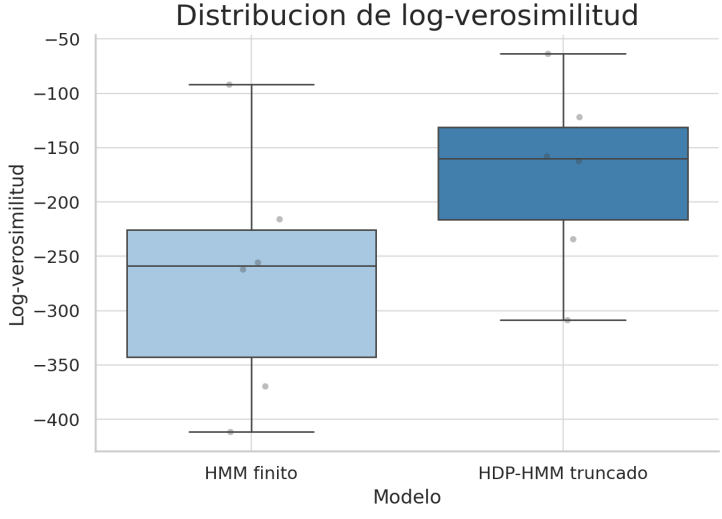
Obra	Compositor	Notas	$\log L_{fin}$	$\log L_{hdp}$	$\Delta \log L$
Cumpleaños feliz (Do mayor)	Tradicional	37	-91.575	-63.314	28.261
Oda a la alegría (variación fácil)	Desconocido	87	-215.515	-121.835	93.680
Para Elisa (versión fácil)	Beethoven	103	-255.714	-158.149	97.565
Cumpleaños feliz (arreglo)	Manjuprasad	106	-262.027	-162.114	99.914
Greensleeves	Desconocido	166	-411.682	-308.600	103.083
Para Elisa (piano para principiantes)	Beethoven	149	-369.596	-234.276	135.321

Tabla 4.4: *Comparación por obra en las seis piezas del subconjunto clásico. La ganancia se calcula como la diferencia HDP-HMM truncado − HMM finito.*

La Figura 4.1 representa el mismo patrón. En el panel por obra, todos los puntos quedan del lado de mayor log-verosimilitud para el HDP-HMM; el panel agregado muestra la separación entre ambas distribuciones dentro de estas seis piezas.



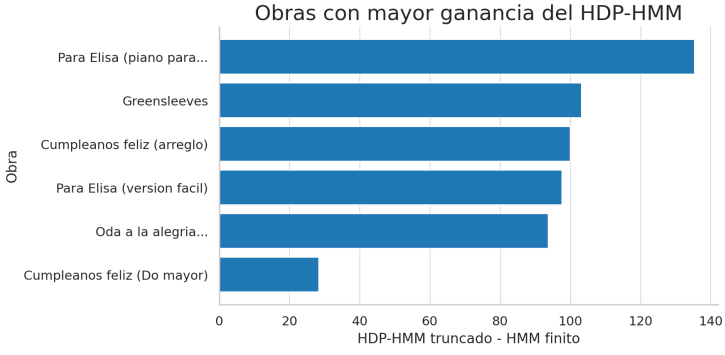
(a) *Comparación de log-verosimilitud por obra.*



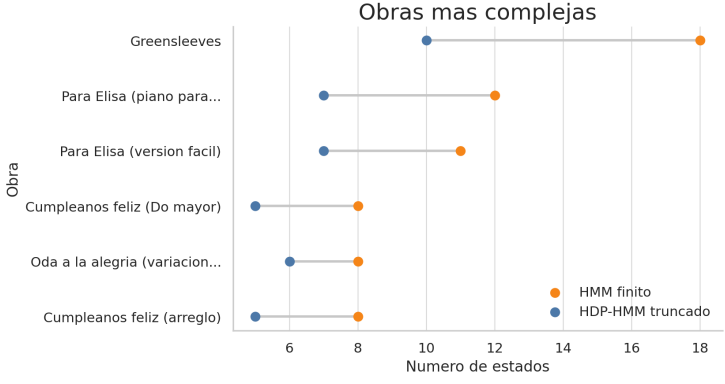
(b) *Distribución agregada de log-verosimilitud por modelo.*

Figura 4.1: *Ajuste probabilístico en el subconjunto clásico. Los paneles presentan los mismos seis casos por obra y de manera agregada.*

La Figura 4.2 relaciona ajuste y número de estados. En estas corridas, la mayor log-verosimilitud del HDP-HMM aparece junto con una ocupación menor del espacio latente. La cuenta de estados describe compacidad estadística, aunque todavía no permite juzgar la calidad musical de la trayectoria.



(a) *Ganancia de log-verosimilitud por obra.*



(b) *Comparación del número de estados por obra.*

Figura 4.2: *Ganancia de log-verosimilitud y ocupación latente en el subconjunto clásico. El panel izquierdo muestra la diferencia de ajuste y el derecho el número de estados ocupados.*

El subconjunto clásico permite pasar de una sola obra a un patrón repetido, pero sigue siendo pequeño. También conviene recordar que log-verosimilitud y número de estados responden preguntas estadísticas; ninguna de las dos medidas establece que las fronteras latentes correspondan a frases, acordes o secciones. Para comprobar

si la diferencia de ajuste se mantiene fuera de este repertorio breve, se amplía después la evaluación a dos fuentes musicales distintas.

4.3.2 Resultados sobre el corpus extendido

El corpus extendido permite preguntar si el patrón anterior aparece también en obras más largas y en otro entorno musical. Se reúnen dos fuentes: repertorio occidental identificado como `MuseTrainer` y material de tradición makam procedente de `SymbTr`. La Tabla 4.5 resume su composición. Ambos repertorios conservan su procedencia; reunirlos para la evaluación no implica que compartan la misma teoría armónica.

Fuente	Perfil del material incorporado	Obras
MuséTrainer	Repertorio tonal occidental de orientación pedagógica y clásica, con piezas breves y medianas en formato MusicXML.	69
SymbTr	Repertorio de música artística turca; el adaptador conserva metadatos de *makam*, *usul* y forma para preservar la procedencia modal.	100
Total	Corpus extendido usado para comprobar si el patrón descriptivo aparece también en un repertorio más heterogéneo.	169

Tabla 4.5: *Composición del corpus extendido utilizado en la comparación multicorpus.*

De las 169 obras catalogadas, 168 pudieron procesarse y 167 quedaron comparables entre ambos modelos. Una obra de Mozart no entró al lote final y una pieza de Brahms produjo un error de ejecución. La Tabla 4.6 conserva esos casos fuera del denominador y resume las 167 comparaciones válidas. En todas ellas, el HDP-HMM obtiene una log-verosimilitud mayor. La ganancia media es de 452.751 unidades y la mediana de 377.039; el HDP-HMM ocupa en promedio 8.222 estados, frente a 32.162 del HMM finito.

Fuente	Obras	$\overline{\Delta \log L}$	$\widetilde{\Delta \log L}$	$\overline{\log L}_{fin}$	$\overline{\log L}_{hdp}$	$\overline{K}_{fin}$	$\overline{K}_{hdp}$
Global	167	452.751	377.039	-1598.180	-1145.429	32.162	8.222
MuséTrainer	67	585.443	467.011	-2667.850	-2082.406	46.418	8.731
SymbTr	100	363.848	336.438	-881.502	-517.654	22.610	7.880

Tabla 4.6: *Resumen agregado de la comparación entre el HMM finito y el HDP-HMM truncado sobre el corpus extendido. La mejora se calcula como HDP-HMM truncado − HMM finito.*

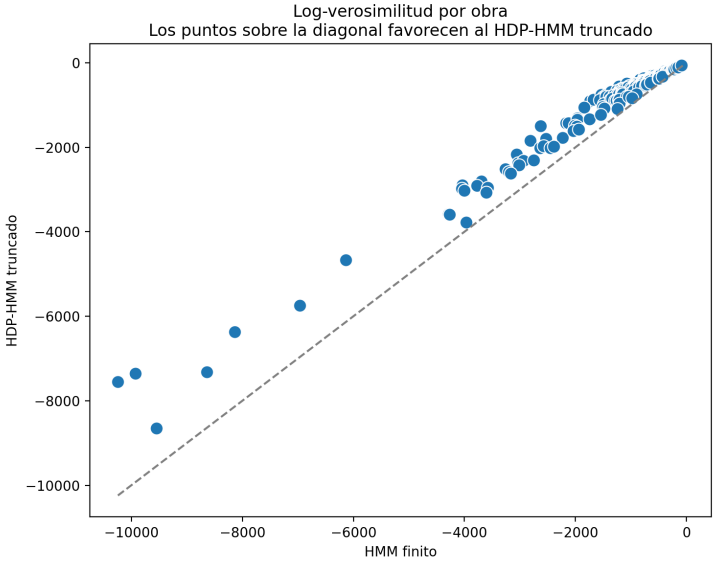
Una tabla con las 167 obras interrumpiría la lectura. La Tabla 4.7 presenta por ello ocho ejemplos, cuatro de cada fuente y con longitudes distintas. Esta selección es

ilustrativa; los promedios y denominadores de la Tabla 4.6 proceden del conjunto completo de casos válidos.

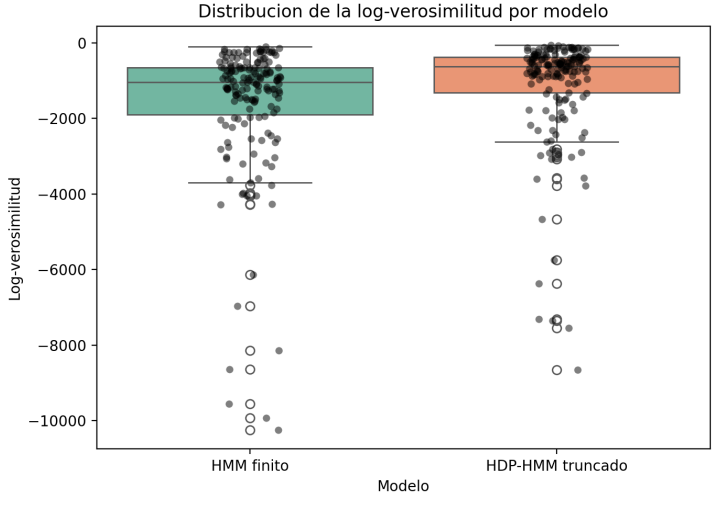
Fuente	Obra	Notas	$\log L_{fin}$	$\log L_{bdp}$	$\Delta \log L$
MuseTrainer	Cumpleaños feliz (Do mayor)	37	-91.575	-62.059	29.516
MuseTrainer	Danse Villageoise	519	-1286.408	-887.259	399.149
MuseTrainer	Clair de Lune	1220	-3020.550	-2421.226	599.324
MuseTrainer	Sonata no. 14, tercer movimiento	4133	-10242.186	-7549.906	2692.280
SymbTr	Acemkürdî Aranağme (Düyek)	58	-144.102	-66.151	77.951
SymbTr	Aldanma Dünya Varına	266	-660.614	-349.715	310.898
SymbTr	Yıllar Sonra Rastladım...	417	-1035.314	-546.391	488.922
SymbTr	Âşık-I Ger	1135	-2815.965	-1841.559	974.407

Tabla 4.7: *Ejemplos de resultados por obra en el corpus extendido. Se incluyen cuatro piezas de* `MuseTrainer` *y cuatro de* `SymbTr` *con distintas longitudes.*

La Figura 4.3 muestra las 167 comparaciones. El diagrama por obra permite comprobar el signo de cada diferencia y el diagrama de caja resume la distribución de log-verosimilitud dentro de cada modelo.



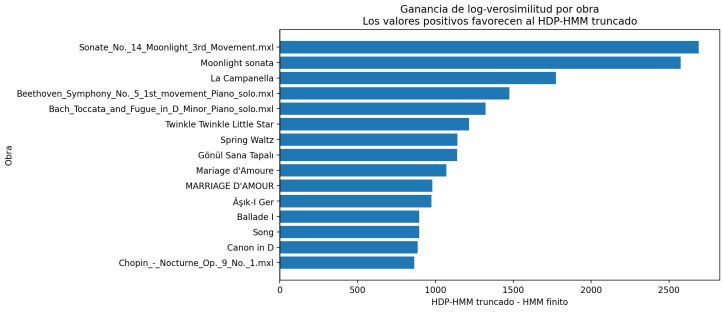
(a) *Comparación de log-verosimilitud por obra en el corpus extendido.*



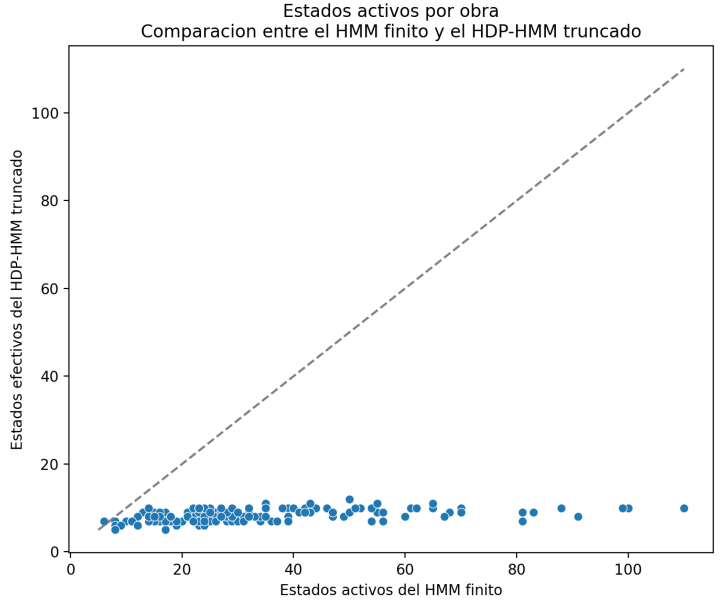
(b) *Distribución agregada de log-verosimilitud por modelo.*

Figura 4.3: *Log-verosimilitud por obra y distribución agregada en el corpus extendido. Las comparaciones se limitan a los* 167 *casos válidos para ambos modelos.*

La Figura 4.4 separa los dos componentes del resultado. El panel izquierdo muestra que la diferencia de log-verosimilitud es positiva en los casos comparables. El derecho muestra que el HDP-HMM utiliza menos estados efectivos en promedio. Como en el subconjunto clásico, ambas observaciones describen ajuste y ocupación, no calidad de segmentación.



(a) *Ganancia de log-verosimilitud por obra.*



(b) *Comparación del número de estados utilizados por ambos modelos.*

Figura 4.4: *Ganancia de log-verosimilitud y ocupación latente en el corpus extendido. El número de estados ocupados no constituye una métrica estructural de referencia.*

En las corridas de este capítulo, el HDP-HMM combina mayor log-verosimilitud con un vocabulario latente ocupado más pequeño. El patrón aparece en el subconjunto clásico y en las 167 obras comparables del corpus extendido. En `SymbTr`, sin embargo, este resultado no demuestra que los estados recuperen categorías propias

de la teoría makam; sólo describe cómo se ajusta el modelo a las clases de altura utilizadas.

El alcance de la conclusión es, por tanto, descriptivo. El HDP-HMM truncado ofrece una representación latente más compacta y un mejor ajuste sobre estas mismas secuencias, pero todavía no se ha evaluado contra anotaciones estructurales ni mediante una tarea predictiva común fuera de muestra. El capítulo siguiente separa esas preguntas: conserva la estructura como objetivo musical y compara HMM finito, HDP-HMM, VOMM y transformador sobre predicción del siguiente evento. Esta distinción permite que un modelo mejore el ajuste en el presente capítulo y, aun así, no sea el mejor predictor en la comparación final.

Capítulo 5

Comparación predictiva entre HMM, HDP-HMM, VOMM y transformador

En el capítulo anterior se introdujo el HDP-HMM truncado como una respuesta al problema de fijar de antemano el número de estados ocultos. Tanto ese modelo como el HMM finito parten de una intuición común: la melodía observable está organizada por una trayectoria latente que evoluciona en el tiempo. Esta formulación permite preguntar qué estados aparecen, cómo se conectan y con qué frecuencia se reutilizan. Sin embargo, no es la única manera de modelar una secuencia musical.

Un transformador causal adopta otro punto de partida. En lugar de postular una trayectoria discreta de estados ocultos, utiliza el contexto anterior para asignar probabilidades al siguiente evento mediante atención Vaswani et al. (2017). El mismo principio se ha aplicado a secuencias musicales simbólicas Huang et al. (2019). Esta diferencia vuelve poco informativa una comparación directa entre sus componentes internos: una cabeza de atención no desempeña el mismo papel que un estado de un HMM. Para establecer un terreno común conviene formular una pregunta más sencilla: dada una sucesión de clases de altura, ¿qué probabilidad asigna cada modelo a la nota que efectivamente aparece después?

La pregunta anterior permite comparar predicción, pero no agota el problema musical. Un modelo puede anticipar bien la siguiente nota sin recuperar frases, secciones o funciones armónicas; de manera inversa, una trayectoria latente puede ser inter-

pretable y no alcanzar la mejor predicción fuera de muestra. Por ello, en este capítulo se separan tres lecturas. La descripción estructural conserva el papel de objetivo musical, aunque todavía no cuenta con una evaluación externa; la predicción del siguiente evento funciona como tarea común entre familias y el costo computacional se registra como una condición transversal.

Además de HMM finito, HDP-HMM y transformador, se incorpora un modelo de Markov de orden variable, o VOMM por sus siglas en inglés Begleiter, El-Yaniv, and Yona (2004). Este modelo sirve como puente diagnóstico. A diferencia del HMM de primer orden, puede utilizar varios eventos observados del pasado; a diferencia del transformador, lo hace mediante tablas explícitas de conteos. Su inclusión ayuda a distinguir cuánto de la mejora predictiva puede obtenerse con memoria local antes de recurrir a una arquitectura neuronal.

La Figura 5.1 resume la lógica del capítulo. Los cuatro modelos reciben la misma representación musical y responden la pregunta predictiva. HMM finito y HDP-HMM producen además trayectorias latentes candidatas para el análisis estructural. El hecho de producirlas, no obstante, todavía no demuestra que coincidan con una segmentación musical de referencia.

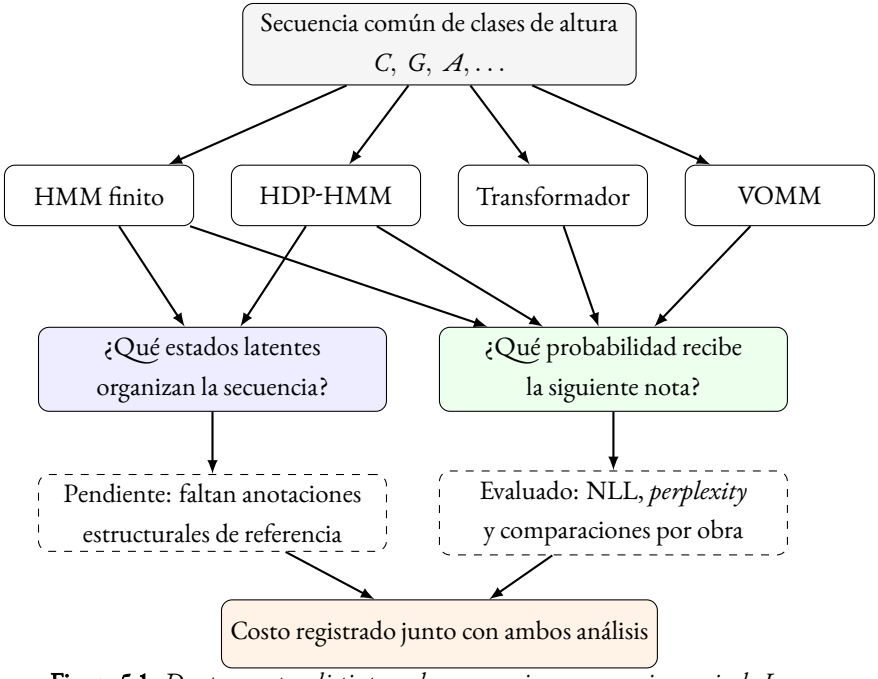


Figura 5.1: *Dos preguntas distintas sobre una misma secuencia musical. La predicción pudo compararse entre las cuatro familias; la descripción estructural requiere todavía una referencia externa.*

5.1 Una tarea común para modelos diferentes

Para convertir la intuición anterior en una medida comparable, considérese un segmento de prueba $y_1, \ldots, y_T$. En cada posición t, el modelo observa el contexto permitido c_t y asigna una probabilidad al símbolo que realmente sigue. La sorpresa promedio del modelo se mide mediante la NLL por evento,

$$\mathrm{NLL} = -\frac{1}{T}\sum_{t=1}^{T} \log P(y_t \mid c_t), \qquad \text{perplexity} = \exp(\mathrm{NLL}).$$

Cuando el modelo concentra mayor probabilidad en los eventos observados, la penalización disminuye. Por ello, valores menores de NLL y *perplexity* indican mejor predicción. Ambas cantidades expresan la misma información en escalas distintas: la *perplexity* facilita la lectura, pero no constituye una segunda fuente independiente

de evidencia.

Para que esta medida sea justa no basta usar la misma fórmula. Los modelos también deben puntuar exactamente los mismos eventos. El símbolo de inicio se utiliza como contexto, pero no cuenta como una nota adicional que deba predecirse. De manera análoga, el símbolo de relleno utilizado por el transformador queda fuera de la distribución evaluada. Validación y prueba se dividen en segmentos no superpuestos de hasta 128 eventos y se conserva la cola final, aunque sea corta. Así, cada nota de prueba se puntúa una sola vez y con los mismos reinicios de contexto en las cuatro familias.

Esta tarea común tiene un alcance deliberadamente limitado. La clase de altura conserva la identidad de la nota módulo octava, pero omite duración, registro, dinámica y buena parte de la organización métrica. El experimento permite estudiar regularidad secuencial sobre un alfabeto compartido; no permite reconstruir por sí solo toda la información de la partitura.

5.2 Cómo se construye la comparación

La unidad básica de partición es la obra canónica. Si una pieza tiene arreglos o variantes, todos se asignan al mismo conjunto. Esta decisión evita una forma de fuga de información: el modelo no debe entrenarse con una versión de una obra y evaluarse después sobre otra versión casi equivalente. Con semilla 7, se reserva el 15% de las obras para prueba y el 10% para validación; el resto se utiliza para entrenamiento.

Una sola partición permite comparar modelos, pero no muestra cómo responde cada uno al aumento de datos. Para observar ese comportamiento se construyen subconjuntos anidados con el 10%, 25%, 50%, 75% y 100% del acervo de entrenamiento. "Anidados" significa que cada fracción amplía la anterior para una misma semilla, en lugar de reemplazarla por un conjunto distinto. Las semillas de datos 1, 2 y 3 cambian el orden de incorporación de las obras, mientras que las semillas de modelo 1 y 2 modifican la inicialización.

En la fracción completa aparece una particularidad. Cuando se usa el 100% de las obras, cambiar la semilla de datos ya no puede cambiar el subconjunto. Las tres filas correspondientes contienen entonces el mismo acervo y no deben interpretarse como tres muestras independientes. Esta repetición no altera la comparación

pareada por obra, pero sí obliga a leer con cautela la dispersión del último punto de la curva.

La selección de configuraciones se realiza únicamente con validación. El HMM finito compara 12, 24 y 48 estados. El HDP-HMM permite hasta 24 estados latentes y contrasta tres combinaciones de hiperparámetros. El transformador conserva una arquitectura pequeña de tres capas y dimensión interna 128. El VOMM compara órdenes 1, 2, 4 y 8. La Tabla 5.1 reúne la configuración necesaria para interpretar la corrida.

Tabla 5.1: *Protocolo ejecutado para la comparación predictiva*

Componente	Configuración ejecutada
Tarea	Predicción autorregresiva de la siguiente clase de altura
Representación	`pitch_class`; sin silencios, sin transposición y con preferencia por la voz aguda
Partición primaria	75% entrenamiento, 10% validación y 15% prueba; agrupación por obra canónica; semilla 7
Corpus	Muestra de 3000 archivos de PDMX; semilla de muestreo 7; 2933 piezas preparadas
Curva de aprendizaje	Fracciones 0.10, 0.25, 0.50, 0.75 y 1.00; semillas de datos 1, 2 y 3; subconjuntos anidados por obra
Repeticiones	Semillas de modelo 1 y 2; en la fracción completa las semillas de datos repiten el mismo subconjunto y no constituyen réplicas independientes
HMM finito	Selección entre 12, 24 y 48 estados; máximo de 100 iteraciones
HDP-HMM truncado	Truncamiento 24; 120 iteraciones; calentamiento de 60; tres configuraciones de hiperparámetros
Transformador	Tres capas; dimensión 128; cuatro cabezas; dimensión intermedia 256; hasta 25 épocas con detención temprana
VOMM	Control diagnóstico; selección por validación entre órdenes 1, 2, 4 y 8
Métrica primaria	NLL de prueba por token con cobertura idéntica auditada
Medidas complementarias	*Perplexity*, tiempo, parámetros, seis diferencias pareadas, intervalo *bootstrap* y ajuste de Holm

El análisis final vuelve a la obra como unidad de comparación. Primero se promedian las variantes y repeticiones pertenecientes a una misma obra; después se calcula, para cada par de modelos, la diferencia de NLL sobre las mismas obras. Este emparejamiento convierte cada pieza en su propio punto de comparación y evita que una obra larga se transforme, por su número de notas, en centenares de observaciones independientes. El intervalo *bootstrap* aproxima la incertidumbre mediante 10 000 remuestreos de las obras; la prueba de rangos con signo de Wilcoxon utiliza el signo y el orden de las diferencias pareadas; y el ajuste de Holm controla que se examinan

seis pares a la vez Wilcoxon (1945); Holm (1979); Efron (1979); Demšar (2006).

5.2.1 Comprobaciones previas

Antes de interpretar una diferencia entre modelos fue necesario resolver una pregunta más básica: ¿todos estaban resolviendo realmente la misma tarea? Durante la integración se corrigió el tratamiento del símbolo de inicio en VOMM, se excluyó el relleno de la distribución puntuada por el transformador y se añadió una auditoría que compara, obra por obra, los eventos esperados con los eventos evaluados. Una omisión, una duplicación o un cambio de orden invalida la corrida en lugar de producir silenciosamente un denominador distinto.

También se corrigió la conservación del modelo elegido por validación, la reanudación después de una línea incompleta de *checkpoint* y el uso de la caché cuando se solicita una muestra menor del corpus. En HMM finito y HDP-HMM se incorporaron cálculos reescalados y vectorizados para reducir el tiempo sin cambiar la formulación probabilística. Las pruebas de regresión comparan estas rutas con las implementaciones anteriores en dominio logarítmico. Tales pruebas respaldan la integridad del programa; no se utilizan como resultados musicales.

5.3 La corrida completada sobre PDMX

La comparación se ejecutó con la corrida `tesis_3000_gpu_20260823_1941`, terminada el 23 de agosto de 2026. Se muestrearon 3000 archivos del corpus PDMX con semilla 7 Long et al. (2025). Después del preprocesamiento quedaron 2933 piezas utilizables y 67 exclusiones, para un total de 693 754 eventos. La prueba reunió 424 piezas; en la fracción completa, el entrenamiento utilizó 2173 piezas y 500 959 eventos.

El diseño contiene quince celdas, formadas por tres semillas de datos y cinco fracciones de entrenamiento. En cada celda se ajustaron dos inicializaciones de HMM finito, HDP-HMM y transformador, además de un VOMM determinista, lo que produjo 105 filas. El transformador se ajustó en GPU mediante CUDA; los tres modelos restantes se ejecutaron en CPU con doce procesos. Esta diferencia de dispositivo deberá recordarse cuando se comparen tiempos.

La ejecución fue interrumpida previamente como medida preventiva ante la temperatura del equipo. La reanudación recuperó los 3000 archivos desde la caché y

continuó desde los modelos ya terminados. En consecuencia, el incidente no se interpreta como una corrida fallida, pero sí como una razón práctica para conservar *checkpoints* y controlar por separado la carga de CPU y GPU.

5.4 Qué cambia cuando aumenta el corpus

La Tabla 5.2 muestra la *perplexity* media de prueba. En la primera fracción, que contiene alrededor de 55 000 eventos de entrenamiento, el transformador y el HMM finito obtienen valores muy próximos: 7.640 y 7.655. La diferencia es pequeña frente a la variación registrada y no permite sostener una ventaja clara de uno sobre otro en ese régimen de datos.

Tabla 5.2: Perplexity *media de prueba por fracción de entrenamiento. Menor es mejor; la última columna compara cada modelo consigo mismo entre los extremos de la curva.*

Modelo	0.10	0.25	0.50	0.75	1.00	Cambio 0.10 → 1.00
Transformador	7.640	7.287	6.878	6.259	5.823	-23.8%
HMM finito	7.655	7.447	7.403	7.363	7.356	-3.9%
HDP-HMM truncado	8.223	8.033	8.018	7.956	7.968	-3.1%
VOMM	8.756	8.496	8.376	8.195	8.022	-8.4%

Al añadir obras, las curvas dejan de evolucionar de la misma manera. El transformador reduce su *perplexity* de 7.640 a 5.823, un cambio de 23.8%. El HMM finito pasa de 7.655 a 7.356 y el HDP-HMM de 8.223 a 7.968; sus reducciones son de 3.9% y 3.1%. El VOMM ocupa una posición intermedia y reduce su valor en 8.4%. Dentro del intervalo estudiado, el transformador sigue aprovechando el aumento del corpus, mientras que las configuraciones evaluadas de los otros modelos cambian menos.

Esta lectura necesita una salvedad. En las treinta selecciones del HMM finito se eligieron 48 estados, exactamente el valor más alto disponible. Por ello, la curva sólo muestra que el HMM con $K \leq 48$ se aproxima a una meseta; no demuestra que toda la familia finita haya agotado su capacidad. Para separar ambas explicaciones se requiere ampliar la rejilla y repetir la selección mediante validación.

El HDP-HMM obtiene una *perplexity* mayor que el HMM finito en las cinco fracciones. El modelo utiliza entre 14 y 17 estados efectivos de los 24 disponibles, por lo que la cota no parece actuar como una restricción inmediata. Bajo este corpus y esta

tarea predictiva, permitir una cardinalidad latente flexible no produjo una ventaja. Este resultado no contradice el Capítulo 4: allí se estudió log-verosimilitud de ajuste y complejidad latente sobre otros corpus, mientras que aquí se mide predicción fuera de muestra sobre PDMX.

5.4.1 Comparación obra por obra

Los promedios anteriores reúnen todo el conjunto de prueba, pero todavía conviene preguntar si la diferencia se distribuye entre las obras o depende de unas cuantas piezas largas. De las 424 piezas de prueba, 414 obras tuvieron una NLL válida para cada par comparado. La Tabla 5.3 muestra los seis contrastes. Un signo negativo favorece al primer modelo nombrado.

Tabla 5.3: *Comparaciones pareadas de NLL por obra en la fracción completa. Los intervalos se obtuvieron mediante* bootstrap *y los valores p se ajustaron conjuntamente mediante Holm.*

Comparación	Diferencia media	IC del 95%	p ajustado
HMM finito − HDP-HMM	-0.1071	$[-0.1184, -0.0959]$	2.5×10^{-52}
HMM finito − transformador	$+0.2505$	$[+0.2367, +0.2641]$	7.1×10^{-68}
HMM finito − VOMM	-0.0734	$[-0.0855, -0.0613]$	9.6×10^{-27}
HDP-HMM − transformador	$+0.3576$	$[+0.3401, +0.3750]$	4.2×10^{-68}
HDP-HMM − VOMM	$+0.0336$	$[+0.0164, +0.0513]$	3.5×10^{-4}
Transformador − VOMM	-0.3240	$[-0.3382, -0.3100]$	1.1×10^{-68}

La diferencia media entre HMM finito y transformador es de 0.2505 nats por evento, con intervalo $[0.2367, 0.2641]$, a favor del transformador. El nat es la unidad que resulta de utilizar el logaritmo natural en la NLL. Frente al HDP-HMM, la diferencia asciende a 0.3576 nats. Ninguno de los seis intervalos incluye el cero y los valores p permanecen por debajo de 0.05 después del ajuste de Holm. Dado el número de obras, la magnitud y el intervalo describen mejor el resultado que un valor p aislado.

La comparación entre HDP-HMM y VOMM ilustra por qué importa definir la unidad de análisis. Si se suman primero todos los eventos, las obras largas reciben mayor peso y el promedio favorece ligeramente al HDP-HMM. Si cada obra recibe el mismo peso, el contraste favorece al VOMM por 0.0336 nats. Las dos operaciones responden preguntas distintas. En esta tesis se adopta la segunda para la inferencia pareada y se conserva la primera únicamente como resumen global.

5.5 *El costo de la mejora predictiva*

Una mejora predictiva puede ser poco útil si exige un presupuesto desproporcionado. Por ello, la Tabla 5.4 presenta tiempo de ajuste, tiempo de evaluación y tamaño del modelo en sus unidades originales. No se combinan en una puntuación única porque un segundo de cómputo, un parámetro y una unidad de NLL no son cantidades intercambiables.

Tabla 5.4: *Costo medio observado en la fracción completa. Los tiempos de pared cruzan dispositivos distintos y no constituyen una comparación neutral de hardware.*

Modelo	Parámetros	Ajuste (s)	Evaluación (s)	NLL
Transformador	415 872	169	2.6	1.762
HDP-HMM truncado	863	578	0.5	2.075
HMM finito	2 879	628	0.6	1.996
VOMM	101 201[a]	41	8.4	2.082

[a] Para VOMM, la cifra corresponde al tamaño de la tabla de conteos y no a parámetros continuos entrenables.

Bajo la configuración disponible, el transformador ajustó en 169 segundos, frente a 578 del HDP-HMM y 628 del HMM finito. La arquitectura neuronal no fue la más lenta en esta corrida. Sin embargo, el transformador se ejecutó en GPU y los modelos clásicos en CPU. Sólo puede afirmarse que fue más rápido en esta máquina y con esta implementación.

El VOMM ofrece el menor tiempo de ajuste, 41 segundos, pero tarda más en evaluar y obtiene peor NLL que el transformador y el HMM finito. Si se consideran simultáneamente NLL, ajuste y evaluación, las cuatro familias conservan alguna combinación no dominada y permanecen en la frontera parcial de Pareto Miettinen (1999). Dicho de otro modo, ningún modelo mejora los tres valores a la vez frente a todos los demás. Se habla de una frontera parcial porque todavía falta la calidad estructural; el cálculo no debe confundirse con una decisión completa sobre utilidad musical.

5.6 *Lo que la predicción todavía no responde*

Hasta este punto se ha mostrado qué modelo asigna mayor probabilidad a las notas de prueba. Falta volver a la pregunta que motivó la introducción de estados ocultos: ¿la trayectoria inferida coincide con una organización musical reconocible? Para re-

sponderla se necesitan, sobre las mismas obras, fronteras o etiquetas estructurales independientes del modelo. Sólo entonces pueden compararse las fronteras, las particiones y los estados inferidos con una referencia externa.

La infraestructura ya admite ese tipo de anotaciones. Para los puntos de cambio calcula F_1 de fronteras; para comparar particiones completas utiliza información mutua normalizada e índice de Rand ajustado. En la corrida completada no se dispuso del archivo de referencia. El artefacto estructural registró `not_evaluated`; por tanto, no se obtuvieron puntuaciones estructurales y la frontera completa de estructura, predicción y costo quedó sin evaluar.

Sin una referencia, la interpretación debe detenerse antes de atribuir significado musical a las salidas. La menor NLL del transformador no demuestra que su atención recupere frases o secciones. Una secuencia de estados del HMM o del HDP-HMM tampoco se convierte automáticamente en una segmentación válida. Los estados son una hipótesis de organización que las anotaciones estructurales permitirían someter a contraste.

Quedan además tres comprobaciones necesarias. La rejilla del HMM finito debe ampliarse más allá de 48 estados; la conclusión debe repetirse con otra semilla de partición; y los tiempos deben compararse, si se busca neutralidad de hardware, bajo recursos equivalentes. También falta recuperar y preservar los CSV y JSON originales de la corrida. Las tablas actuales se regeneran desde el reporte versionado, lo que conserva trazabilidad, pero no sustituye una auditoría directa de los artefactos primarios.

En la corrida estudiada, el transformador obtiene la menor *perplexity* desde la fracción 0.25, y la diferencia frente a los otros modelos aumenta conforme se incorporan más obras. Entre los modelos de estados latentes, el HMM finito obtiene mejor predicción que el HDP-HMM bajo las configuraciones evaluadas. El VOMM conserva interés como control de ajuste rápido, aunque no alcanza la mejor calidad predictiva.

La conclusión estructural permanece abierta. La predicción muestra qué modelo anticipa mejor la siguiente clase de altura, pero no determina cuál explica mejor la organización de una obra. Por ello, el siguiente paso prioritario es incorporar una

referencia estructural que conecte los estados inferidos con la pregunta musical de la tesis.

Capítulo A

De la distribución de Dirichlet al proceso jerárquico

A.1 Sobre el proceso de Dirichlet y los modelos jerárquicos

El capítulo 3 introduce el proceso de Dirichlet en el punto en que hace falta para definir el modelo. Lo que se reúne aquí es un paso previo: no la formulación del HDP-HMM, sino la cadena de ideas que vuelve natural su aparición. Esa cadena puede resumirse así. Una distribución categórica describe probabilidades sobre un conjunto finito de símbolos. La distribución de Dirichlet permite modelar incertidumbre sobre esas probabilidades. Un modelo jerárquico permite poner en relación varias distribuciones del mismo tipo sin estimarlas por separado. El proceso de Dirichlet aparece cuando se quiere conservar esa lógica, pero sin fijar de antemano el número de categorías latentes Murphy (2012); Ferguson (1973); Teh et al. (2006).

Sea $\mathcal{V} = \{1, \ldots, K\}$ un conjunto finito. Una variable aleatoria Y con valores en $\mathcal{V}$ sigue una distribución categórica si existe un vector de probabilidades

$$\mathbf{p} = (p_1, \ldots, p_K), \qquad p_k \geq 0, \qquad \sum_{k=1}^{K} p_k = 1,$$

tal que

$$P(Y = k \mid \mathbf{p}) = p_k.$$

El vector $\mathbf{p}$ pertenece al simplex de dimensión $K-1$ y expresa, simplemente, el peso asignado a cada categoría posible. Si se observa una sola realización, la estructura parece elemental. Pero cuando se observan muchas realizaciones y se desea inferir el valor de $\mathbf{p}$, ya no interesa sólo contar frecuencias: también importa cómo representar la incertidumbre sobre esas frecuencias.

La distribución de Dirichlet cumple esa función. Se escribe

$$\mathbf{p} \sim \text{Dirichlet}(a_1, \ldots, a_K),$$

y define una distribución de probabilidad sobre el conjunto de todos los vectores $\mathbf{p}$ admisibles. Los parámetros $(a_1, \ldots, a_K)$ controlan la concentración de masa en el simplex: si todos son grandes, la distribución se concentra más; si son pequeños, permite configuraciones más extremas. En términos intuitivos, la distribución de Dirichlet actúa como una distribución a priori sobre probabilidades categóricas.

Su importancia práctica proviene de la conjugación. Si se observa una muestra de variables categóricas con conteos

$$(n_1, \ldots, n_K),$$

entonces la distribución posterior de $\mathbf{p}$ vuelve a ser Dirichlet:

$$\mathbf{p} \mid \text{datos} \sim \text{Dirichlet}(a_1 + n_1, \ldots, a_K + n_K).$$

Esta propiedad hace que la actualización bayesiana sea particularmente transparente. Cada conteo observado corrige el peso previo asociado a su categoría, y el resultado sigue viviendo en la misma familia de distribuciones. Por eso la Dirichlet puede entenderse como una forma de regularizar probabilidades discretas sin abandonar una interpretación probabilística clara.

La dificultad aparece cuando una sola distribución ya no basta. En muchos problemas no se tiene un único vector de probabilidades, sino varios. En un modelo de secuencias, por ejemplo, puede haber una distribución distinta para cada contexto. Si se estimaran todas de manera independiente, el modelo perdería dos cosas a la vez: estabilidad estadística y estructura común. La primera se pierde porque contextos

con pocos datos producirían estimaciones demasiado ruidosas. La segunda se pierde porque ya no habría un mecanismo que recogiera similitudes globales entre las distribuciones locales.

Aquí entra la idea de modelo jerárquico. En general, un modelo jerárquico es aquel en el que ciertos parámetros no se fijan de una vez por todas, sino que a su vez son tratados como variables aleatorias gobernadas por un nivel superior. La ganancia conceptual es que el modelo deja de ser una colección de piezas aisladas: los parámetros locales quedan acoplados por una estructura común. En vez de estimar cada distribución como si nada la conectara con las demás, se admite que todas proceden de una misma organización global.

En el caso finito, esta idea puede escribirse así. Se introduce primero una distribución global

$$\mathbf{p}^{(0)} \sim \text{Dirichlet}(b_1, \ldots, b_K),$$

y después se definen distribuciones locales

$$\mathbf{p}^{(j)} \mid \mathbf{p}^{(0)} \sim \text{Dirichlet}(\lambda p_1^{(0)}, \ldots, \lambda p_K^{(0)}), \qquad j = 1, \ldots, m.$$

Aquí $\mathbf{p}^{(0)}$ fija un perfil global, mientras que cada $\mathbf{p}^{(j)}$ representa una distribución local que puede apartarse de él, aunque no de manera arbitraria. El parámetro λ regula cuánta fidelidad guardan los niveles locales respecto del nivel global. Cuando λ es grande, las distribuciones locales tienden a parecerse más entre sí; cuando es pequeño, hay mayor libertad para que diverjan.

Ésta es la razón por la cual los modelos jerárquicos resultan relevantes en problemas de este tipo. En un HMM, por ejemplo, no hay una sola distribución discreta: hay una distribución inicial, varios renglones de una matriz de transición y, según la formulación, varias distribuciones de emisión. Todas ellas describen comportamientos locales, pero no conviene tratarlas como objetos completamente inconexos. Una estructura jerárquica permite compartir información entre esos niveles, suavizar estimaciones pobres y conservar una idea común del repertorio latente disponible. En la literatura bayesiana este compromiso se conoce como agrupamiento parcial: no se estiman los contextos de manera independiente ni se obliga a que compartan una sola distribución Murphy (2012).

Hasta aquí, sin embargo, todo sigue dependiendo de un supuesto fuerte: el número de categorías K es finito y conocido. La distribución de Dirichlet resuelve la incertidumbre sobre un vector de probabilidades cuando ese vector ya tiene dimensión fija. Pero si el problema exige permitir que el número de componentes latentes no esté prefijado, entonces la construcción finita deja de ser suficiente. Lo que se necesita ya no es una distribución sobre vectores de dimensión fija, sino una distribución sobre medidas de probabilidad.

Ése es precisamente el paso que da el proceso de Dirichlet Ferguson (1973). En lugar de asignar una distribución a priori a un vector finito $\mathbf{p}$, asigna una distribución a priori a una medida aleatoria G. La intuición es la misma que en el caso finito: se sigue modelando incertidumbre sobre pesos probabilísticos. Lo que cambia es que ahora el repertorio de átomos potenciales no tiene por qué fijarse de antemano mediante un entero K. Bajo esta formulación, el espacio de componentes latentes puede ampliarse con la complejidad exigida por los datos.

Además, una propiedad central del proceso de Dirichlet es que sus realizaciones son casi seguramente discretas, incluso cuando la medida base no lo sea. En consecuencia, puede pensarse como una medida de probabilidad construida a partir de una familia numerable de átomos con pesos aleatorios. La representación de *stick-breaking* introducida por Sethuraman expresa esta idea de manera explícita Sethuraman (1994): la masa total se reparte sucesivamente en una colección numerable de porciones, generando así una medida discreta aleatoria.

El paso jerárquico se conserva. Así como en el caso finito una distribución global organizaba a las distribuciones locales, en el caso no paramétrico una medida global puede servir de referencia para varias medidas locales. La relevancia de este punto para el capítulo 3 es directa: cuando se desea modelar una familia de distribuciones de transición relacionadas entre sí, pero sin imponer un número fijo de estados latentes, hace falta una construcción que combine dos exigencias. Por un lado, permitir un repertorio potencialmente infinito. Por otro, conservar una estructura común entre las distribuciones locales. El proceso de Dirichlet jerárquico responde justamente a esas dos exigencias Teh et al. (2006).

El proceso de Dirichlet y los modelos jerárquicos responden así a una dificultad concreta. Cuando no se conoce de antemano la complejidad latente y varias distribu-

ciones deben compartir información, la jerarquía bayesiana conserva un repertorio común sin fijar un único comportamiento local. El Capítulo 4 utiliza esta construcción para definir el HDP-HMM y después introduce el truncamiento necesario para calcularlo.

Capítulo B
Propiedades del proceso observable en un HMM

El Capítulo 3 afirma que las observaciones de un HMM no forman, en general, una cadena de Markov, aunque el par compuesto por estado y observación sí lo hace. Las demostraciones se reúnen aquí para conservar el argumento formal sin interrumpir la introducción de los algoritmos.

B.1 Las observaciones pueden conservar memoria

Proposición B.1. *El proceso observable $(Y_t)_{t\geq 1}$ de una cadena de Markov oculta no es, en general, una cadena de Markov de primer orden.*

Proof. Considérese $\mathcal{S} = \{1, 2\}$, $\mathcal{V} = \{0, 1\}$ y

$$A = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, \qquad P(X_1 = 1) = P(X_1 = 2) = \tfrac{1}{2}.$$

El estado inicial permanece fijo durante toda la trayectoria. Condicionado en $X_1 = 1$, las observaciones son Bernoulli independientes con parámetro p; condicionado en $X_1 = 2$, lo son con parámetro q, donde $p, q \in (0, 1)$ y $p \neq q$.

Por la ley de la probabilidad total,

$$P(Y_3 = 1 \mid Y_2 = 1, Y_1 = 1) = \frac{p^3 + q^3}{p^2 + q^2},$$

mientras que

$$P(Y_3 = 1 \mid Y_2 = 1) = \frac{p^2 + q^2}{p + q}.$$

Ambas cantidades son distintas, pues

$$(p^3 + q^3)(p + q) - (p^2 + q^2)^2 = pq(p - q)^2 > 0.$$

Por tanto, conocer Y_1 además de Y_2 cambia la distribución de Y_3 y el proceso observable no satisface la propiedad de Markov de primer orden. □

La razón del resultado es más sencilla que el cálculo. Cada observación aporta evidencia sobre cuál de los dos regímenes ocultos está activo. Dos observaciones contienen más información sobre ese régimen que una sola y, por ello, pueden cambiar la predicción del siguiente símbolo.

B.2 El proceso conjunto sí es markoviano

Proposición B.2. *Sea $Z_t = (X_t, Y_t)$. Entonces $(Z_t)_{t \geq 1}$ es una cadena de Markov en $\mathcal{S} \times \mathcal{V}$.*

Proof. Sean $(i, v), (j, w) \in \mathcal{S} \times \mathcal{V}$. Por la propiedad de Markov de (X_t) y la independencia condicional de las emisiones,

$$\begin{aligned} &P(Z_{t+1} = (j, w) \mid Z_t = (i, v), Z_{t-1}, \ldots, Z_1) \\ &\quad = P(X_{t+1} = j \mid X_t = i) P(Y_{t+1} = w \mid X_{t+1} = j) \\ &\quad = a_{ij} b_j(w). \end{aligned}$$

La expresión depende del presente sólo a través de Z_t, por lo que el proceso conjunto satisface la propiedad de Markov. □

B.3 Un caso límite

Si la observación revela por completo el estado oculto, la memoria adicional desaparece. La proposición siguiente formaliza ese caso.

Proposición B.3. *Supóngase que existe una función $f\colon \mathcal{V} \to \mathcal{S}$ tal que*

$$X_t = f(Y_t) \quad \textit{casi seguramente para todo } t \geq 1.$$

Entonces $(Y_t)_{t\geq 1}$ es una cadena de Markov de primer orden.

Proof. Para cualquier historial $y_{1:t}$ con probabilidad positiva, conocer $Y_t = y_t$ determina $X_t = f(y_t)$. La distribución de la siguiente observación es entonces

$$\begin{aligned} &P(Y_{t+1} = v \mid Y_t = y_t, \dots, Y_1 = y_1) \\ &\quad = \sum_{j \in \mathcal{S}} P(Y_{t+1} = v \mid X_{t+1} = j) P(X_{t+1} = j \mid X_t = f(y_t)) \\ &\quad = \sum_{j \in \mathcal{S}} b_j(v) a_{f(y_t)j}. \end{aligned}$$

El último término depende únicamente de y_t. Por tanto,

$$P(Y_{t+1} = v \mid Y_t = y_t, \dots, Y_1 = y_1) = P(Y_{t+1} = v \mid Y_t = y_t),$$

y el proceso observable es markoviano. □

La condición anterior es excepcional en la interpretación musical de la tesis. Una clase de altura aislada no suele identificar un único contexto armónico. Precisamente por eso el historial de observaciones puede aportar información sobre el estado latente incluso cuando la dinámica oculta es de primer orden Cappé, Moulines, and Rydén (2005).

Bibliografía

Beal, Matthew J., Zoubin Ghahramani, and Carl Edward Rasmussen. 2002. "The Infinite Hidden Markov Model." Paper presented at the Advances in Neural Information Processing Systems 14, Cambridge, MA.

Begleiter, Ron, Ran El-Yaniv, and Golan Yona. 2004. "On Prediction Using Variable Order Markov Models." *Journal of Artificial Intelligence Research* 22: 385–421.

Cappé, Olivier, Eric Moulines, and Tobias Rydén. 2005. *Inference in Hidden Markov Models*. New York: Springer.

Demšar, Janez. 2006. "Statistical Comparisons of Classifiers over Multiple Data Sets." *Journal of Machine Learning Research* 7: 1–30.

Efron, Bradley. 1979. "Bootstrap Methods: Another Look at the Jackknife." *The Annals of Statistics* 7(1): 1–26.

Ferguson, Thomas S. 1973. "A Bayesian Analysis of Some Nonparametric Problems." *The Annals of Statistics* 1(2): 209–230.

Fox, Emily B., Erik B. Sudderth, Michael I. Jordan, and Alan S. Willsky. 2011. "A Sticky HDP-HMM with Application to Speaker Diarization." *The Annals of Applied Statistics* 5(2A): 1020–1056.

Holm, Sture. 1979. "A Simple Sequentially Rejective Multiple Test Procedure." *Scandinavian Journal of Statistics* 6(2): 65–70.

Huang, Cheng-Zhi Anna, Ashish Vaswani, Jakob Uszkoreit, Noam Shazeer, Ian Simon, Curtis Hawthorne, Andrew M. Dai, Matthew D. Hoffman, Monica Dinculescu, and Douglas Eck. 2019. "Music Transformer: Generating Music with Long-Term Structure." Paper presented at the International Conference on Learning Representations (ICLR),.

Ishwaran, Hemant, and Lancelot F. James. 2001. "Gibbs Sampling Methods for Stick-Breaking Priors." *Journal of the American Statistical Association* 96(453): 161–173.

Long, Phillip, Zachary Novack, Taylor Berg-Kirkpatrick, and Julian McAuley. 2025. "PDMX: A Large-Scale Public Domain MusicXML Dataset for Symbolic Music Processing." Paper presented at the ICASSP 2025 – 2025 IEEE International Conference on Acoustics, Speech and Signal Processing,.

Miettinen, Kaisa. 1999. *Nonlinear Multiobjective Optimization*. Boston: Kluwer Academic Publishers.

Murphy, Kevin P. 2012. *Machine Learning: A Probabilistic Perspective*. Cambridge, MA: MIT Press.

Pearce, Marcus T., and Geraint A. Wiggins. 2012. "Auditory Expectation: The Information Dynamics of Music Perception and Cognition." *Topics in Cognitive Science* 4(4): 625–652.

Rabiner, Lawrence R. 1989. "A tutorial on hidden Markov models and selected applications in speech recognition." *Proceedings of the IEEE* 77(2): 257–286.

Ross, Sheldon M. 2014. *Introduction to Probability Models*. 10 ed. Amsterdam: Academic Press.

Sethuraman, Jayaram. 1994. "A Constructive Definition of Dirichlet Priors." *Statistica Sinica* 4(2): 639–650.

Sheh, Alexander, and Daniel P. W. Ellis. 2003. "Chord Segmentation and Recognition Using EM-Trained Hidden Markov Models." Paper presented at the Proceedings of the 4th International Conference on Music Information Retrieval,.

Teh, Yee Whye, Michael I. Jordan, Matthew J. Beal, and David M. Blei. 2006. "Hierarchical Dirichlet Processes." *Journal of the American Statistical Association* 101(476): 1566–1581.

Temperley, David. 2007. *Music and Probability*. Cambridge, MA: MIT Press.

Van Gael, Jurgen, Yunus Saatci, Yee Whye Teh, and Zoubin Ghahramani. 2008. "Beam Sampling for the Infinite Hidden Markov Model." Paper presented at the Proceedings of the 25th International Conference on Machine Learning,.

Vaswani, Ashish, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. 2017. "Attention Is All You Need." Paper presented at the Advances in Neural Information Processing Systems 30 (NeurIPS 2017),.

W3C Music Notation Community Group. 2021. MusicXML 4.0. Final community group report World Wide Web Consortium. Editado por Michael Good. https://www.w3.org/2021/06/musicxml40/

Wilcoxon, Frank. 1945. "Individual Comparisons by Ranking Methods." *Biometrics Bulletin* 1(6): 80–83.

Modelado probabilístico de melodías:
cadenas de Markov ocultas y comparación
predictiva , de Adrián Janus Gonzalez Adamuz,
fue preparado en Ciudad de México en 2026.