Instituto Tecnológico Autónomo de México



Modelado probabilístico de melodías: cadenas de Markov ocultas y comparación predictiva

TESIS

QUE PARA OBTENER EL TÍTULO DE

Licenciado en Matemáticas Aplicadas e Ingeniería en Computación

PRESENTA

Adrián Janus Gonzalez Adamuz

Asesora: Airam Blancas Serrat

Ciudad de México, México
Otoño, 2026

"Con fundamento en los artículos 21 y 27 de la Ley Federal de Derecho de Autor y como titular de los derechos moral y patrimonial de la obra titulada "*Modelado probabilístico de melodías: cadenas de Markov ocultas y comparación predictiva*", otorgo de manera gratuita y permanente al Instituto Tecnológico Autónomo de México y a la biblioteca Raúl Baillères Jr., autorización para que fijen la obra en cualquier medio, incluido el electrónico, y la divulguen entre sus usuarios, profesores, estudiantes o terceras personas, sin que pueda percibir por tal divulgación una prestación"

Adrián Janus Gonzalez Adamuz

Otoño, 2026



Abstract

This thesis studies what different probabilistic sequence models can show when a symbolic melody is represented as an ordered sequence of pitch classes. The development begins with finite Markov chains. Hidden Markov models (HMMs) then separate the observed notes from latent musical contexts, while an HMM based on the hierarchical Dirichlet process (HDP-HMM) avoids assuming that the number of latent states is known beforehand. Computational experiments accompany this theoretical development, and their limits of reproducibility and interpretation are made explicit.

The final experiment evaluates a finite HMM, a truncated HDP-HMM, a variable-order Markov model, and a causal transformer on the same task of predicting the next event. The data are split by canonical work, keeping arrangements of the same piece together. Of the 3,000 sampled PDMX files, 2,933 pieces remained after preprocessing.

At the full training fraction, the transformer obtained a test perplexity of 5.823. The corresponding values were 7.356 for the finite HMM, 7.968 for the HDP-HMM, and 8.022 for the variable-order model. These results favor the transformer for prediction at the scale studied, but they do not establish structural superiority. The completed run had no reference annotations for phrases, sections, or harmonic functions, so the predictive result is not taken as evidence of musical interpretation. Prediction, structural correspondence, latent-state compactness, and computational cost remain separate criteria rather than interchangeable measures.

Resumen

Esta tesis estudia qué información aporta cada familia de modelos cuando una melodía simbólica se representa como una sucesión de clases de altura. El desarrollo comienza con cadenas de Markov finitas. Las cadenas de Markov ocultas (HMM) separan después las notas observables de los contextos musicales latentes, mientras que un HMM basado en el proceso de Dirichlet jerárquico (HDP-HMM) evita suponer que el número de estados se conoce de antemano. Este desarrollo teórico se acompaña de experimentos computacionales, cuyos límites de reproducibilidad e interpretación también se exponen.

El experimento final evalúa un HMM finito, un HDP-HMM truncado, un modelo de Markov de orden variable y un transformador causal en la misma tarea: predecir el siguiente evento. Las particiones se construyen por obra canónica, de modo que los arreglos de una misma pieza permanezcan juntos. De los 3000 archivos de PDMX muestreados, 2933 piezas quedaron después del preprocesamiento.

Con la fracción completa de entrenamiento, el transformador obtuvo una *perplexity* de prueba de 5.823. Los valores correspondientes fueron 7.356 para el HMM finito, 7.968 para el HDP-HMM y 8.022 para el modelo de orden variable. Estos resultados favorecen al transformador para la predicción con el tamaño de corpus considerado, pero no establecen una superioridad estructural. La corrida final no contó con anotaciones de referencia para frases, secciones o funciones armónicas, por lo que el resultado predictivo no se toma como evidencia de interpretación musical. La predicción, la correspondencia estructural, la compacidad latente y el costo

computacional se evalúan por separado, pues no son medidas intercambiables.

Índice general

Abstract v

Resumen v

Índice de figuras xi

Índice de cuadros xiii

1 Diseño computacional del sistema de modelado musical . . 1
1.1 Problema de diseño 1
1.2 Requerimientos del sistema 2
1.3 Restricciones observadas 3
1.4 Estándares y límites de uso 3
1.5 Modelos considerados 4
1.6 Arquitectura implementada 4
1.7 Estrategia y resultado de la comparación 5

2 Preliminares 6
2.1 De la melodía a una secuencia 6
2.2 Dependencia local y cadenas de Markov 7
2.3 De la nota observable al contexto latente 9

3 Cadenas de Markov ocultas y modelado computacional . . 10
3.1 Dos procesos y una misma secuencia 10

3.2 Tres problemas computacionales 12
3.2.1 Evaluación mediante el algoritmo hacia adelante 12
3.2.2 Decodificación mediante Viterbi 13
3.2.3 Aprendizaje mediante Baum-Welch 15
3.3 Una comprobación manual sobre el Preludio en Do mayor 15
3.4 El límite del número fijo de estados 20

4 Cadenas de Markov ocultas infinitas **21**
4.1 Del número fijo a una colección abierta de estados 22
4.2 Del modelo infinito a un cálculo finito 25
4.3 De una obra al corpus 27
4.3.1 Resultados sobre un subconjunto clásico 28
4.3.2 Resultados sobre el corpus extendido 32

5 Comparación predictiva entre HMM, HDP-HMM, VOMM y transformador **38**
5.1 Una tarea común para modelos diferentes 40
5.2 Cómo se construye la comparación 41
5.2.1 Comprobaciones previas 43
5.3 La corrida final con PDMX 43
5.4 Qué cambia cuando aumenta el corpus 44
5.4.1 Comparación obra por obra 45
5.5 El costo de la mejora predictiva 46
5.6 Lo que la predicción todavía no responde 46

Apéndice A De la distribución de Dirichlet al proceso jerárquico **48**
A.1 Sobre el proceso de Dirichlet y los modelos jerárquicos 48

Apéndice B Propiedades del proceso observable en un HMM . **52**
B.1 Las observaciones pueden conservar memoria 52
B.2 El proceso conjunto sí es markoviano 53
B.3 Un caso límite 54

Bibliografía **57**

Índice de figuras

2.1 Representación esquemática de una octava en el teclado del piano. Las teclas negras completan las doce clases de altura, aunque sólo se rotulan aquí las notas naturales. 7

3.1 Matriz obtenida de la trayectoria inferida para el Preludio en Do mayor. El marco discontinuo identifica el renglón de `E min`, para el cual no se registraron transiciones inferidas. Las celdas sin cifra representan valores registrados como cero. 17
3.2 Matriz construida mediante etiquetado y conteo manual de la partitura del Preludio en Do mayor. Las celdas sin cifra representan valores registrados como cero. 18
3.3 Diferencia absoluta registrada entre la matriz inferida y la referencia manual. Las celdas sin cifra representan diferencias registradas como cero. 19

4.1 Ajuste probabilístico en el subconjunto clásico. Los paneles presentan los mismos seis casos por obra y de manera agregada. 30
4.2 Ganancia de log-verosimilitud y ocupación latente en el subconjunto clásico. El panel superior muestra la diferencia de ajuste y el inferior el número de estados ocupados. 31

4.3 Log-verosimilitud por obra y distribución agregada en el corpus extendido. Las comparaciones se limitan a los 167 casos válidos para ambos modelos. 34
4.4 Mayores ganancias de log-verosimilitud y ocupación latente en el corpus extendido. El panel superior muestra una selección de quince obras; el inferior incluye los casos para los que se dispone de ambos conteos. 36

5.1 Dos preguntas distintas sobre una misma secuencia musical. La predicción pudo compararse entre las cuatro familias; la descripción estructural requiere todavía una referencia externa. 40

Índice de cuadros

4.1 Comparación entre el HMM finito y el HDP-HMM truncado en la obra de referencia: el tercer movimiento de la Sonata núm. 14 de Beethoven. 27

4.2 Subconjunto clásico limitado utilizado para la comparación documentada entre el HMM finito y el HDP-HMM truncado. 28

4.3 Resumen agregado de la comparación entre el HMM finito y el HDP-HMM truncado sobre el subconjunto clásico limitado. . . . 29

4.4 Comparación por obra en las seis piezas del subconjunto clásico. La ganancia se calcula como la diferencia HDP-HMM truncado − HMM finito. 29

4.5 Composición del corpus extendido utilizado en la comparación multicorpus. 32

4.6 Resumen agregado de la comparación entre el HMM finito y el HDP-HMM truncado sobre el corpus extendido. La mejora se calcula como HDP-HMM truncado − HMM finito. 32

4.7 Ejemplos de resultados por obra en el corpus extendido. Se incluyen cuatro piezas de `MuseTrainer` y cuatro de `SymbTr` con distintas longitudes. 33

5.1 Protocolo ejecutado para la comparación predictiva 42

5.2 *Perplexity* media de prueba por fracción de entrenamiento. Menor es mejor; la última columna compara cada modelo consigo mismo entre los extremos de la curva. 44

5.3 Comparaciones pareadas de NLL por obra en la fracción completa. Los intervalos se obtuvieron mediante *bootstrap* y los valores *p* se ajustaron conjuntamente mediante Holm. 45
5.4 Costo medio observado en la fracción completa. Los tiempos reales de ejecución se midieron en dispositivos distintos y no constituyen una comparación neutral del hardware. 46

Capítulo 1
Diseño computacional del sistema de modelado musical

Para contrastar con datos la pregunta matemática de esta tesis es necesario formularla como un procedimiento computacional. El sistema debe leer partituras, convertirlas en secuencias comparables, ajustar modelos distintos y dejar constancia de las condiciones de la comparación. El diseño descrito en este capítulo enlaza, por tanto, la formulación matemática con los experimentos de los capítulos posteriores.

El objetivo no es elegir un modelo universal para música simbólica. Se busca observar cómo se comporta cada familia con una representación común, sin confundir dos preguntas. Una se refiere a la estructura: qué contextos latentes pueden describirse dentro de una obra. La otra se refiere a la predicción: qué probabilidad asigna el modelo al siguiente evento musical. Un modelo puede dar una buena respuesta a una de ellas y no a la otra.

1.1 Problema de diseño

Una partitura contiene alturas, duraciones, voces, compases y otras indicaciones, mientras que los modelos estudiados necesitan una secuencia discreta. Antes de comparar modelos se debe decidir qué parte de esa información permanece en la secuencia. En la tarea común se utilizan clases de altura, de modo que una cadena de Markov oculta finita (HMM), su extensión mediante un proceso de Dirichlet jerárquico (HDP-HMM), un modelo de Markov de orden variable (VOMM) y un

transformador causal compartan el mismo alfabeto. La comparación se vuelve posible a costa de excluir registro, duración y parte de la organización métrica.

Una representación común no basta si cambian las condiciones de evaluación. Por ejemplo, colocar un arreglo en entrenamiento y una versión casi idéntica de la misma obra en prueba puede sobrestimar la generalización. Las particiones se hacen por obra canónica para mantener juntas sus variantes. También se verifica que todos los modelos puntúen los mismos eventos y que el símbolo de inicio funcione como contexto, no como una nota adicional.

Queda todavía el problema de interpretar los resultados. Los modelos HMM finito y HDP-HMM producen estados latentes, mientras que el VOMM y el transformador se incluyen principalmente por su capacidad predictiva. La log-verosimilitud negativa por evento, o NLL, permite comparar esa capacidad, pero no dice si un estado coincide con una frase, un acorde o una sección. Por esa razón, el análisis estructural se mantiene separado y exige anotaciones externas antes de atribuir significado musical a los estados inferidos.

1.2 Requerimientos del sistema

Para construir la secuencia observable, el sistema lee archivos MusicXML y su variante comprimida MXL, normaliza su contenido y genera una representación común W3C Music Notation Community Group (2021). Con esas secuencias ajusta las cuatro familias mediante las mismas divisiones por obra, selecciona configuraciones con el conjunto de validación y genera resultados agregados y por pieza. Junto con las métricas registra el dispositivo, los tiempos, la complejidad y la cobertura de los eventos evaluados.

Una corrida también debe poder reconstruirse. Para ello se conservan su configuración, semillas, exclusiones y asignaciones de obras. Los puntos de reanudación permiten continuar cálculos largos sin repetir modelos ya terminados, y las tablas del manuscrito se obtienen de artefactos versionados o estructurados en lugar de transcribirse a mano.

Interpretar estas trayectorias requiere un cuidado adicional. Una trayectoria puede ocupar pocos estados sin coincidir con divisiones musicales reconocibles. Por ello, la ocupación latente, la calidad predictiva y la correspondencia con anotaciones se

evalúan por separado. En la corrida final sólo estuvieron disponibles las dos primeras, pues no se contó con una referencia anotada para completar la evaluación estructural.

1.3 Restricciones observadas

El corpus disponible era demasiado grande para procesarlo en su totalidad dentro del calendario experimental. La comparación final partió de una muestra de 3000 archivos de PDMX Long et al. (2025), de los cuales quedaron 2933 piezas después del preprocesamiento. Este tamaño permitió construir curvas de aprendizaje, aunque los resultados no describen la colección completa.

Los dispositivos empleados tampoco fueron homogéneos. El transformador se ajustó en una unidad de procesamiento gráfico (GPU), mientras que HMM, HDP-HMM y VOMM se ejecutaron en unidades centrales de procesamiento (CPU). Bajo esta configuración, el transformador necesitó menos tiempo real de ejecución que ambos HMM. Esto muestra que la arquitectura neuronal no fue la opción más lenta en la corrida realizada, pero los dispositivos distintos impiden atribuir la diferencia de tiempo únicamente a los algoritmos.

La otra restricción afecta la pregunta estructural. Aunque el repositorio implementa métricas para fronteras y particiones, no hubo anotaciones musicales de referencia para esta corrida. La comparación final permite entonces comparar el desempeño predictivo y describir el costo, pero no establecer qué modelo recupera mejor la organización de una obra.

1.4 Estándares y límites de uso

El uso de formatos simbólicos interoperables permite rastrear la procedencia de cada secuencia sin depender de una codificación particular. MusicXML es un formato abierto para el intercambio de partituras entre aplicaciones, y MXL conserva el mismo contenido en un contenedor comprimido W3C Music Notation Community Group (2021). Al distribuir los datos y los artefactos también deben respetarse las condiciones de licenciamiento del corpus y de las bibliotecas utilizadas.

La reproducibilidad se adopta aquí como un criterio metodológico. Conservar solamente el código del modelo no permite reconstruir una corrida: también hacen falta el *commit*, la configuración, las semillas, el corpus efectivo y las exclusiones. Las prue-

bas unitarias verifican el comportamiento esperado del programa; las conclusiones musicales, en cambio, deben apoyarse en corridas completas y artefactos que puedan revisarse.

1.5 Modelos considerados

Los modelos considerados incorporan el contexto de dos maneras. El HMM finito y el HDP-HMM truncado introducen estados latentes y producen una trayectoria que puede inspeccionarse. El primero obliga a fijar su número antes del ajuste; el segundo puede utilizar sólo una parte de la cota computacional disponible. Esa flexibilidad puede conducir a una representación más compacta, aunque no garantiza por sí misma mejor predicción ni una interpretación musical de los estados.

El VOMM y el transformador amplían, en cambio, el contexto observable. El VOMM utiliza conteos de longitud variable y permite medir el efecto de recordar más eventos sin introducir estados ocultos Begleiter, El-Yaniv, and Yona (2004). El transformador causal aprende a distribuir la atención sobre el contexto anterior Vaswani et al. (2017), una estrategia que también se ha aplicado a secuencias musicales simbólicas Huang et al. (2019). Ambos asignan probabilidades al siguiente evento, pero no producen una trayectoria discreta directamente comparable con la de los HMM.

1.6 Arquitectura implementada

La implementación separa la preparación de datos, el modelado y la evaluación. Primero se leen las partituras, se extraen las clases de altura y se registran las exclusiones. Después, las variantes se agrupan por obra canónica para construir las divisiones de entrenamiento, validación y prueba. Los cuatro modelos se ajustan con esa misma base de datos. El componente de evaluación reúne las métricas, los tiempos, la auditoría de cobertura y las comparaciones por obra; los puntos de reanudación se conservan junto con cada corrida.

Esta separación resultó útil durante la corrida larga. La caché evitó procesar otra vez los 3000 archivos, y los puntos de reanudación permitieron continuar después de una interrupción preventiva por temperatura. La auditoría de cobertura verificó que las diferencias de NLL no se debieran a que los modelos puntuaran eventos distintos.

1.7 Estrategia y resultado de la comparación

La tarea común consiste en predecir el siguiente evento. Todos los modelos se alimentan con secuencias de clases de altura y utilizan las mismas particiones por obra y los mismos reinicios de contexto. La métrica principal es la NLL por evento, cuya transformación exponencial es la *perplexity*. Los tiempos y las medidas de complejidad se presentan aparte porque no comparten una unidad que permita reunirlos en una sola cantidad interpretable.

La lectura de los resultados depende de la finalidad del modelo. El transformador fue el mejor predictor en las fracciones medias y grandes del corpus, y el HMM finito obtuvo mejor predicción que el HDP-HMM. Este último mantuvo la representación más compacta en los experimentos descriptivos del Capítulo 4, mientras que el VOMM requirió el menor tiempo de ajuste. Como no hubo una referencia anotada, estos resultados no permiten determinar cuál de los modelos latentes representa mejor la estructura musical.

Para entender cómo se llega a esta comparación todavía hace falta construir la secuencia común y precisar qué dependencia se supone entre sus eventos. El Capítulo 2 comienza con esa decisión de representación y presenta la cadena de Markov que sirve de punto de partida.

Capítulo 2
Preliminares

Una melodía se percibe como una sucesión organizada, no como una colección de notas independientes. Después de escuchar varios eventos se forman expectativas sobre lo que puede ocurrir a continuación, aunque esas expectativas no determinen una única continuación posible. Esta combinación de regularidad e incertidumbre permite plantear una primera pregunta matemática: ¿qué parte de la continuidad melódica puede describirse mediante probabilidades de transición? La relación entre expectativa musical y aprendizaje estadístico ha sido estudiada tanto desde la teoría musical como desde la cognición de la música Temperley (2007); Pearce and Wiggins (2012).

Antes de asignar probabilidades hay que decidir qué cuenta como un evento. Una partitura contiene alturas, duraciones, voces, compases y otros signos, mientras que una cadena de Markov opera sobre una sucesión de símbolos. Reducir la primera a la segunda obliga a precisar qué se observa y qué significa avanzar un paso. Una vez fijada esa secuencia, puede formularse la dependencia markoviana y observarse por qué será necesario introducir estados ocultos.

2.1 De la melodía a una secuencia

En esta tesis, la melodía se estudia a partir de partituras simbólicas. Cada nota seleccionada por el preprocesamiento cuenta como un evento y el índice n indica su lugar en la secuencia. Avanzar de n a $n+1$ no supone que entre ambos eventos transcurra

siempre la misma duración física. La comparación experimental del Capítulo 5 utiliza la misma representación para predecir la siguiente clase de altura. Como no se incorporan la duración, el registro, la dinámica ni parte de la organización métrica, las conclusiones tampoco abarcan esos aspectos.

La altura puede conservarse con distinto grado de detalle. Una nota con registro, como C_4, distingue la octava; una clase de altura agrupa notas equivalentes módulo octava y las representa con un mismo símbolo, como C. Para la comparación común se utilizan las doce clases de altura del sistema cromático occidental. La Figura 2.1 muestra ese alfabeto dentro de una octava del teclado.

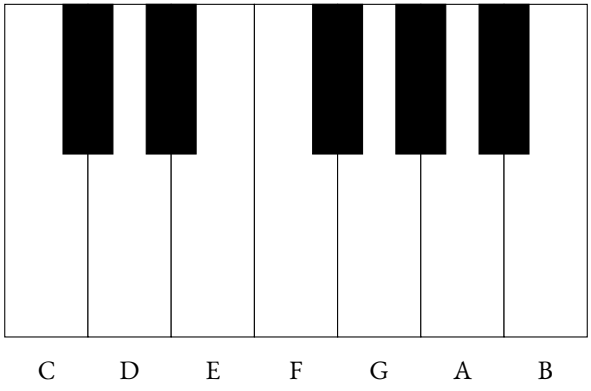


Figura 2.1: *Representación esquemática de una octava en el teclado del piano. Las teclas negras completan las doce clases de altura, aunque sólo se rotulan aquí las notas naturales.*

Sea S el alfabeto finito elegido. Una melodía queda representada como una sucesión

$$(X_n)_{n \geq 1}, \qquad X_n \in S,$$

donde X_n es la clase de altura observada en la posición n. Tratar X_n como variable aleatoria no implica que la melodía carezca de organización musical. La distribución de probabilidad sólo expresa qué continuaciones admite el modelo y qué peso asigna a cada una.

2.2 Dependencia local y cadenas de Markov

El modelo más simple asignaría a cada posición la misma distribución, con independencia de las notas anteriores. Esa hipótesis no representa la continuidad local que

motivó la secuencia. En el extremo opuesto, condicionar cada nota a toda la historia previa produce un número de contextos que crece rápidamente y resulta difícil de estimar con datos limitados. La cadena de Markov de primer orden adopta una posición intermedia: conserva la nota presente y descarta el resto del pasado al calcular la siguiente transición.

Definición 2.1. *Sea* $(\Omega, \mathcal{F}, \mathbb{P})$ *un espacio de probabilidad. Una sucesión de variables aleatorias* $(X_n)_{n\geq 1}$ *con valores en un conjunto finito* S *es una* cadena de Markov *si, para todo* $n \geq 1$ *y para cualesquiera* $i_1, \ldots, i_n, j \in S$ *con probabilidad condicionante positiva,*

$$P(X_{n+1} = j \mid X_n = i_n, \ldots, X_1 = i_1) = P(X_{n+1} = j \mid X_n = i_n).$$

En el modelo melódico de primer orden, esta igualdad significa que la nota actual resume el contexto utilizado para predecir la siguiente. La música puede contener motivos, frases y dependencias a mayor distancia, pero la cadena no los representa de forma directa. Se trata de una simplificación deliberada cuyo efecto puede evaluarse al compararla con modelos que conservan más contexto.

Si la cadena es homogénea, la probabilidad de pasar de i a j no depende de n y se denota por

$$P_{ij} = P(X_{n+1} = j \mid X_n = i).$$

Estas probabilidades satisfacen

$$P_{ij} \geq 0, \qquad \sum_{j \in S} P_{ij} = 1.$$

La matriz $\mathbf{P} = (P_{ij})_{i,j\in S}$ se denomina *matriz de transición* Ross (2014). Cada renglón responde una pregunta concreta: dada la nota representada por i, ¿cómo distribuye el modelo la probabilidad entre las notas que pueden seguirla?

Cuando se observa una secuencia y no se impone regularización, una estimación elemental cuenta cuántas veces aparece cada par consecutivo (i, j) y divide por el número de transiciones que parten de i. Este cociente es el estimador de máxima verosimilitud de P_{ij}. Si un par no aparece, su estimación es cero; con corpus pe-

queños, esa ausencia puede reflejar falta de datos y no imposibilidad musical. Los mecanismos probabilísticos de los capítulos posteriores buscan precisamente que la estimación no dependa sólo de cada conteo aislado.

La matriz también permite estudiar el comportamiento agregado de la cadena. Un vector de probabilidad π es estacionario si

$$\pi = \pi \mathbf{P}.$$

En una cadena finita, irreducible y aperiódica, existe una única distribución estacionaria y

$$\lim_{n \to \infty} P(X_n = j \mid X_1 = i) = \pi_j.$$

Bajo esas condiciones, π_j describe la probabilidad a largo plazo del símbolo j dentro del modelo. Se trata de una propiedad de la cadena estimada y no basta por sí sola para identificar tonalidad, función armónica o estilo.

2.3 De la nota observable al contexto latente

En la cadena descrita hasta ahora, cada nota es a la vez observación y estado. Esto permite describir qué notas suelen sucederse, pero no permite representar un contexto que permanezca mientras cambian las observaciones. Una misma nota puede aparecer en regiones armónicas distintas y un mismo acorde puede admitir varias notas. La nota actual, por tanto, no determina de manera unívoca la organización que se desea estudiar Temperley (2007).

Para conservar ese contexto se separan los dos niveles. La nota pasa a ser la observación y una segunda variable representa el contexto latente que evoluciona en el tiempo. El contexto inferido puede estudiarse para determinar si corresponde a una región armónica o estructural, aunque el modelo no le asigna automáticamente una etiqueta musical. El Capítulo 3 formaliza esta idea mediante una cadena de Markov oculta y presenta los algoritmos para evaluar, aprender y decodificar el modelo.

Capítulo 3

Cadenas de Markov ocultas y modelado computacional

En la cadena de Markov del capítulo anterior, el estado era la nota observada. Así podían describirse transiciones locales, pero dos apariciones de la misma nota recibían necesariamente el mismo tratamiento. Esta identificación resulta restrictiva porque una clase de altura puede cumplir funciones distintas según la región tonal o armónica en la que aparece.

Una cadena de Markov oculta, o HMM por sus siglas en inglés, separa la nota de ese contexto. Las notas forman la secuencia observable y una segunda cadena representa un contexto que cambia a lo largo del tiempo. El contexto actual determina tanto la distribución de las notas observables como la del contexto siguiente. A partir de esta dependencia se pueden evaluar secuencias, reconstruir trayectorias latentes y aprender los parámetros del modelo Rabiner (1989); Cappé, Moulines, and Rydén (2005).

3.1 Dos procesos y una misma secuencia

Definición 3.1. *Sea* $(\Omega, \mathcal{F}, \mathbb{P})$ *un espacio de probabilidad. Una* cadena de Markov oculta *está formada por dos procesos estocásticos en tiempo discreto,*

$$(X_t)_{t\geq 1}, \qquad (Y_t)_{t\geq 1},$$

donde X_t toma valores en un espacio finito de estados ocultos

$$\mathcal{S} = \{1, \dots, N\},$$

y Y_t toma valores en un espacio discreto de observaciones

$$\mathcal{V} = \{v_1, \dots, v_M\}.$$

El proceso (X_t) satisface la propiedad de Markov y, condicionado en X_t, el valor de Y_t es independiente de los demás estados y observaciones. El modelo se especifica mediante

$$\pi_i = P(X_1 = i), \qquad a_{ij} = P(X_t = j \mid X_{t-1} = i), \quad t \geq 2, \qquad b_j(v) = P(Y_t = v \mid X_t = j), \quad t \geq 1.$$

Estas probabilidades se reúnen en

$$\lambda = (\pi, \mathbf{A}, \mathbf{B}).$$

El vector π describe el estado inicial. El renglón i de $\mathbf{A}$ distribuye la probabilidad del siguiente estado cuando el actual es i, mientras que el renglón j de $\mathbf{B}$ hace lo mismo con las observaciones que puede emitir el estado j. En cada caso las probabilidades suman uno:

$$\sum_{i=1}^{N} \pi_i = 1, \qquad \sum_{j=1}^{N} a_{ij} = 1, \qquad \sum_{v \in \mathcal{V}} b_j(v) = 1.$$

En la aplicación musical, Y_t es la clase de altura registrada y X_t es un contexto latente. Los HMM se han utilizado para segmentar música y reconocer acordes Sheh and Ellis (2003), por lo que cabe examinar si cada estado representa una región armónica, un acorde o una función. El ajuste no supervisado no proporciona esa interpretación. Los estados siguen siendo etiquetas estadísticas y su lectura musical requiere estudiar sus emisiones, sus transiciones y, cuando se dispone de ellas, anotaciones externas.

La distribución conjunta de una trayectoria $x_{1:T}$ y una secuencia observada $y_{1:T}$ se

factoriza como

$$P(X_{1:T} = x_{1:T}, Y_{1:T} = y_{1:T} \mid \lambda) = \pi_{x_1} b_{x_1}(y_1) \prod_{t=2}^{T} a_{x_{t-1}x_t} b_{x_t}(y_t).$$

La expresión sigue el orden en que se genera la secuencia. Primero se elige el estado inicial y su observación; después, cada paso combina una transición latente con una nueva emisión. Gracias a esta factorización, los algoritmos de programación dinámica pueden agrupar cálculos que de otro modo se repetirían para cada trayectoria.

Aunque (X_t) sea una cadena de Markov, (Y_t) no tiene por qué satisfacer la misma propiedad. Las notas anteriores informan sobre el estado oculto actual y, por esa vía, cambian la distribución de la nota siguiente. En cambio, el par (X_t, Y_t) sí forma una cadena de Markov en el espacio producto. El Apéndice B demuestra ambos resultados y estudia el caso límite en el que la observación determina el estado oculto.

3.2 Tres problemas computacionales

El uso de un HMM plantea tres problemas distintos Rabiner (1989). Si los parámetros son conocidos, la *evaluación* calcula la probabilidad de una secuencia y la *decodificación* reconstruye una trayectoria latente compatible con ella. Cuando los parámetros también son desconocidos, el *aprendizaje* los estima a partir de las observaciones. En esta tesis, la log-verosimilitud sirve para comparar ajustes, Viterbi produce trayectorias que pueden inspeccionarse y Baum-Welch ajusta el HMM finito de la comparación final.

3.2.1 Evaluación mediante el algoritmo hacia adelante

Para un modelo λ y una secuencia $y_{1:T}$, la evaluación calcula

$$P(y_{1:T} \mid \lambda).$$

Una suma directa tendría una contribución por cada una de las N^T trayectorias ocultas. El algoritmo hacia adelante evita enumerarlas al reunir todas las trayectorias que terminan en un mismo estado. Para ello se define

$$\alpha_t(j) = P(Y_{1:t} = y_{1:t}, X_t = j \mid \lambda).$$

La cantidad $\alpha_t(j)$ acumula el peso de todas las explicaciones latentes que llegan al estado j después de observar los primeros t símbolos. No es la probabilidad posterior de ese estado, pues también contiene la probabilidad conjunta de las observaciones parciales.

La inicialización y la recurrencia son

$$\alpha_1(j) = \pi_j b_j(y_1),$$

$$\alpha_{t+1}(j) = b_j(y_{t+1}) \sum_{i=1}^{N} \alpha_t(i) a_{ij}.$$

Al finalizar,

$$P(y_{1:T} \mid \lambda) = \sum_{j=1}^{N} \alpha_T(j).$$

El costo es $O(TN^2)$. En secuencias largas, el producto de probabilidades pequeñas puede producir subdesbordamiento numérico. Para evitarlo, las implementaciones suelen reescalar las variables o trabajar en dominio logarítmico Rabiner (1989); Cappé, Moulines, and Rydén (2005).

3.2.2 Decodificación mediante Viterbi

La evaluación suma el peso de todas las trayectorias. La decodificación busca, en cambio, la que maximiza la probabilidad conjunta con las observaciones. Como $P(y_{1:T} \mid \lambda)$ es constante respecto de la trayectoria, este criterio también maximiza la probabilidad posterior de la trayectoria completa.

El algoritmo de Viterbi conserva, para cada estado final, sólo el mejor camino parcial. Se define

$$\delta_t(j) = \max_{x_{1:t-1}} P(X_{1:t-1} = x_{1:t-1}, X_t = j, Y_{1:t} = y_{1:t} \mid \lambda),$$

con

$$\delta_1(j) = \pi_j b_j(y_1)$$

y

$$\delta_t(j) = b_j(y_t) \max_{i \in \mathcal{S}} \delta_{t-1}(i) a_{ij}.$$

Además del valor máximo se guarda el estado que lo alcanza, lo que permite reconstruir la trayectoria mediante un recorrido hacia atrás.

Algorithm 1 Algoritmo de Viterbi

Require: Observaciones $O = (o_1, \ldots, o_T)$, estados $\mathcal{S} = \{1, \ldots, N\}$ y parámetros (π, A, B)

Ensure: Trayectoria más probable $X^* = (x_1^*, \ldots, x_T^*)$

Inicialización
for $j = 1$ **to** N **do**
    $\delta_1(j) \leftarrow \pi_j b_j(o_1)$
    $\psi_1(j) \leftarrow 0$
end for

Recursión
for $t = 2$ **to** T **do**
    for $j = 1$ **to** N **do**
        $\delta_t(j) \leftarrow \max_{1 \le i \le N} \left[\delta_{t-1}(i) a_{ij}\right] b_j(o_t)$
        $\psi_t(j) \leftarrow \arg\max_{1 \le i \le N} \left[\delta_{t-1}(i) a_{ij}\right]$
    end for
end for

Terminación y retroceso
$x_T^* \leftarrow \arg\max_{1 \le j \le N} \delta_T(j)$
for $t = T-1, T-2, \ldots, 1$ **do**
    $x_t^* \leftarrow \psi_{t+1}(x_{t+1}^*)$
end for
return X^*

Viterbi produce la trayectoria óptima según el modelo, pero ésta no es una verdad musical observada. Otras trayectorias pueden tener una probabilidad cercana y la identidad numérica de un estado no contiene una etiqueta armónica. En los capítulos experimentales, la decodificación se utiliza para contar estados ocupados y visualizar transiciones. Una interpretación estructural más fuerte requiere una referencia

externa.

3.2.3 Aprendizaje mediante Baum-Welch

En una aplicación musical se conocen las notas, pero no la trayectoria que las generó. El aprendizaje debe entonces estimar λ a partir de una o varias secuencias observadas. Si los estados también se observaran, los parámetros podrían obtenerse contando inicios, transiciones y emisiones. Baum-Welch sustituye esos conteos desconocidos por sus valores esperados bajo los parámetros actuales y luego los normaliza; este procedimiento es una instancia del esquema de esperanza-maximización Rabiner (1989).

En la iteración r, el paso de esperanza calcula probabilidades posteriores de estados y transiciones mediante los recorridos hacia adelante y hacia atrás. El paso de maximización elige parámetros que maximizan la esperanza de la log-verosimilitud completa,

$$\lambda^{(r+1)} = \arg\max_{\lambda} \mathbb{E}_{X \mid Y, \lambda^{(r)}} \left[\log P(X, Y \mid \lambda) \right].$$

La log-verosimilitud observada no disminuye de una iteración a la siguiente. Esto no garantiza un máximo global y el resultado puede depender de la inicialización, de ahí que la comparación experimental utilice varias semillas y un conjunto de validación.

Baum-Welch estima probabilidades para un número N de estados fijado de antemano, pero no indica cuál debe ser ese número. Aumentar N amplía la capacidad del modelo y también cambia el costo, la estabilidad del ajuste y la forma en que se reutilizan los estados. El ejercicio siguiente examina una trayectoria obtenida con un vocabulario ya fijado.

3.3 Una comprobación manual sobre el Preludio en Do mayor

El *Preludio en Do mayor*, BWV 846, de J. S. Bach, permitió contrastar una trayectoria inferida con una lectura directa de la partitura. Primero se identificó manualmente una sucesión armónica. Después se contaron sus transiciones entre acordes y se normalizó cada renglón para obtener una matriz de probabilidades. El resultado es una referencia para este ejercicio, no una única lectura posible de la obra, pues depende de cómo se asignaron los acordes.

El HMM utilizó una distribución inicial uniforme y una matriz de transición a priori

que favorece la permanencia. Para N estados se fijó

$$A_{ii} = \frac{\alpha}{\alpha + (N-1)\beta}, \qquad A_{ij} = \frac{\beta}{\alpha + (N-1)\beta}, \quad i \neq j, \tag{3.1}$$

con $\alpha = 210$, $\beta = 1$ y $\pi_i = 1/N$. Los materiales conservados no coinciden por completo: el registro textual indica $N = 24$, pero las imágenes muestran diez etiquetas armónicas. Como falta la hoja intermedia de conteos, no se sabe si el vocabulario se restringió o si sólo se eligieron diez etiquetas para la figura. El contraste se limita a esas etiquetas visibles.

Tras aplicar la decodificación de Viterbi, se contaron las transiciones de la trayectoria inferida y se aplicó la misma normalización. Las Figuras 3.1 y 3.2 muestran las matrices por separado para que las celdas puedan leerse. Ambas reproducen los valores de las imágenes originales, sin sustituir el conteo manual ni atribuirles más precisión que la registrada.

En ambas matrices predominan los valores de la diagonal: una vez asignado un acorde, la siguiente posición suele conservar la misma etiqueta. También coinciden varias transiciones fuera de la diagonal. La diferencia más visible está en `E min`. La referencia manual le asigna probabilidad 0.92 de permanencia y 0.08 de transición a `F Maj`, pero la trayectoria inferida no visita ese estado. Por eso el renglón correspondiente queda sin conteos, aunque el estado forme parte del vocabulario.

La Figura 3.3 reproduce la matriz de diferencias absolutas del ejercicio. Sus valores se transcribieron de la imagen histórica y no se calcularon de nuevo: las otras dos figuras están redondeadas y no contienen todas las diferencias de la hoja de cálculo original.

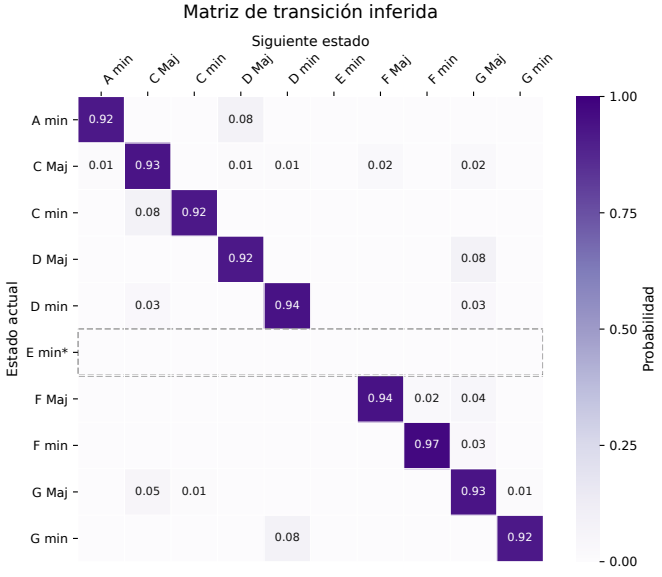


Figura 3.1: *Matriz obtenida de la trayectoria inferida para el Preludio en Do mayor. El marco discontinuo identifica el renglón de* `E min`*, para el cual no se registraron transiciones inferidas. Las celdas sin cifra representan valores registrados como cero.*

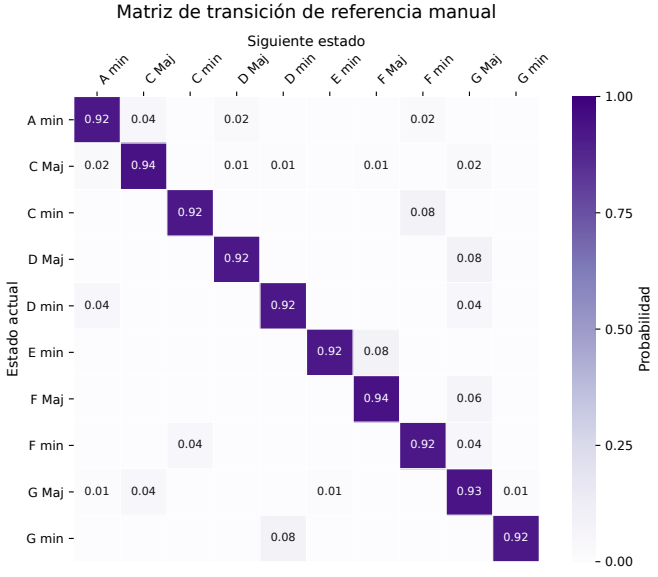


Figura 3.2: *Matriz construida mediante etiquetado y conteo manual de la partitura del Preludio en Do mayor. Las celdas sin cifra representan valores registrados como cero.*

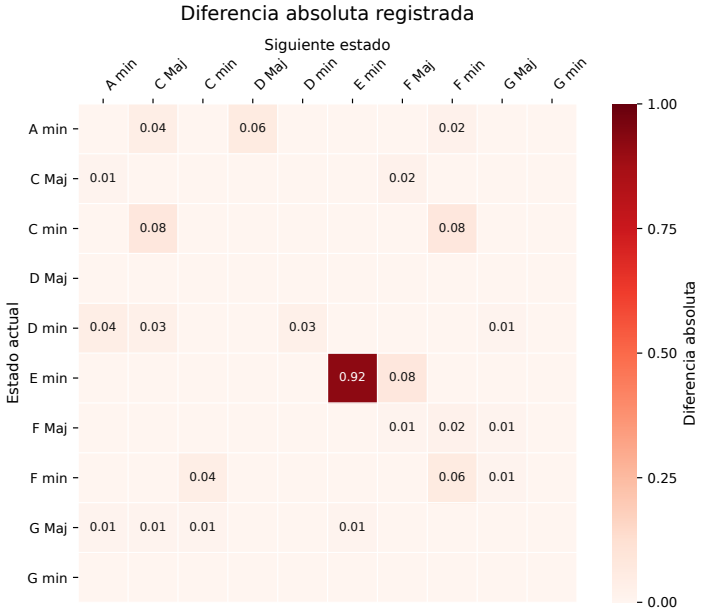


Figura 3.3: *Diferencia absoluta registrada entre la matriz inferida y la referencia manual. Las celdas sin cifra representan diferencias registradas como cero.*

El conteo manual encontró 30 cambios de acorde en la referencia y 27 en la trayectoria inferida. De estos últimos, 22 coincidieron. La razón $27/30 = 0.90$ compara cantidades de cambios, no una tasa de detección, pues cinco cambios inferidos no coincidieron. La razón $22/27 \approx 0.815$ sí expresa la proporción de coincidencias entre los cambios inferidos. En el ejercicio no participó un segundo anotador y tampoco se conserva una regla de tolerancia para coincidencias cercanas.

El HMM recupera algunas regularidades de la organización armónica propuesta, pero omite uno de sus estados. Una sola obra y una sola anotación no bastan para generalizar las proporciones ni para atribuir el desacuerdo al número de estados. El ejercicio tiene un alcance más modesto: muestra que el vocabulario latente tuvo que fijarse antes del ajuste.

3.4 El límite del número fijo de estados

El HMM finito separa la observación del contexto latente, pero antes de ajustarlo se debe elegir

$$\mathcal{S} = \{1, \ldots, N\}.$$

Si N es pequeño, comportamientos distintos pueden quedar reunidos en un mismo estado. Si es grande, una regularidad puede repartirse entre estados redundantes. La selección por validación permite comparar varios valores, aunque todavía requiere una rejilla finita y un límite decidido por anticipado.

El Capítulo 4 conserva la misma relación entre estados y observaciones, pero permite que el número de estados potenciales no se fije de antemano y que la inferencia utilice sólo los necesarios. Esta formulación conduce al proceso de Dirichlet jerárquico y, en el cálculo, a una aproximación truncada.

Capítulo 4

Cadenas de Markov ocultas infinitas

El capítulo anterior introdujo una cadena de Markov oculta con N estados. Las notas forman la secuencia observable y los estados representan contextos musicales que no aparecen escritos de manera directa en la partitura. Una vez fijado N, pueden estimarse transiciones, emisiones y trayectorias latentes. Falta, sin embargo, tomar una decisión previa: ¿cuántos contextos deben permitirse?

La respuesta no es evidente incluso en un ejemplo sencillo. Si se permiten muy pocos estados, el modelo puede reunir bajo una misma etiqueta regiones musicales que se comportan de manera distinta. Si se permiten demasiados, una regularidad que debería repetirse puede quedar repartida entre varios estados casi redundantes. El número de estados no es entonces un detalle de implementación, pues determina el nivel de resolución con el que se describe la obra.

La separación entre proceso latente y observación sigue siendo útil, aunque N deje de tratarse como una cantidad conocida. El modelo puede disponer de muchos estados potenciales y ocupar sólo los que necesita la secuencia. Un vocabulario finito de acordes permite ver primero por qué ambas cantidades no tienen que coincidir.

Supóngase, como ejemplo conceptual, que cada estado oculto debe corresponder a un acorde. El HMM clásico exige fijar primero un conjunto finito S de acordes permitidos y después identificar el espacio de estados ocultos con

$$\mathcal{S} = \{1, 2, \ldots, N\}, \qquad N = |S|.$$

La elección de S determina la dimensión de la distribución inicial π, de la matriz de transición $\mathbf{A}$ y de la familia de emisiones $\mathbf{B}$. Una manera de construir ese vocabulario consiste en usar pares de la forma

$$(\text{fundamental, plantilla armónica}).$$

El primer componente indica la fundamental y el segundo la cualidad armónica.

Sea

$$\mathcal{R} = \{C, C^\sharp, D, E^\flat, E, F, F^\sharp, G, A^\flat, A, B^\flat, B\}$$

el conjunto de clases de altura fundamentales. Sea además

$$\mathcal{Q} = \left\{ \begin{array}{l} \text{Maj}, \text{min}, \text{dim}, \text{aug}, \\ \text{Maj7}, 7, \text{m7}, \text{m(Maj7)}, \varnothing 7, \text{dim7}, \\ 6, \text{m6}, \text{add9}, \text{madd9}, 6/9, \\ \text{sus2}, \text{sus4}, 7\text{sus4}, \\ \text{Maj9}, 9, \text{m9} \end{array} \right\}$$

una familia de plantillas que distingue triadas, séptimas, suspensiones y extensiones.

Se define entonces

$$S = \mathcal{R} \times \mathcal{Q}.$$

En consecuencia,

$$|S| = 12 \times 21 = 252.$$

El vocabulario resultante contiene 252 acordes posibles antes de observar una sola nota. Los experimentos no utilizan esa lista como etiquetas verdaderas: los estados latentes permanecen sin nombre y las observaciones son clases de altura. El cálculo muestra que un vocabulario musical razonable puede crecer con rapidez sin indicar cuántos estados necesita una obra concreta. Conviene entonces separar el número de estados disponibles del número que el modelo utiliza.

4.1 Del número fijo a una colección abierta de estados

Los modelos bayesianos no paramétricos formalizan esa separación. El término *no paramétrico* puede resultar engañoso: el modelo sí tiene parámetros, pero no fija

el número de componentes utilizados antes de observar los datos. En este caso se parte de una colección numerable de estados potenciales y se distribuye entre ellos la probabilidad mediante un proceso de Dirichlet Ferguson (1973); Sethuraman (1994). El Apéndice A desarrolla el paso desde una distribución de Dirichlet finita hasta esta construcción.

La estructura del HMM del capítulo anterior se conserva, pero cambia el espacio de estados. En lugar de usar $\{1, \dots, N\}$, se considera

$$\mathcal{S} = \mathbb{N}.$$

La propiedad de Markov no cambia. El siguiente estado depende del estado presente y la observación depende del estado latente actual. La diferencia es que ya no se fija de antemano un número exacto de contextos.

Definición 4.1. *Una* cadena de Markov oculta infinita *está determinada por dos procesos estocásticos en tiempo discreto*

$$(X_t)_{t\geq 1}, \qquad (Y_t)_{t\geq 1},$$

donde (X_t) toma valores en $\mathbb{N}$ y (Y_t) toma valores en un espacio de observaciones $\mathcal{V}$. Se fija una distribución inicial

$$\pi = (\pi_i)_{i\geq 1},$$

una matriz de transición infinita

$$\mathbf{A} = (a_{ij})_{i,j\geq 1},$$

y una familia de distribuciones de emisión

$$\mathbf{B} = (b_j)_{j\geq 1},$$

de modo que, para todo $i, j \geq 1$ y todo $v \in \mathcal{V}$,

$$P(X_1 = i \mid \pi) = \pi_i,$$

$$P(X_t = j \mid X_{t-1} = i, \mathbf{A}) = a_{ij}, \quad t \geq 2, \qquad P(Y_t = v \mid X_t = j, \mathbf{B}) = b_j(v), \quad t \geq 1,$$

con

$$\sum_{i=1}^{\infty} \pi_i = 1, \qquad \sum_{j=1}^{\infty} a_{ij} = 1, \qquad \sum_{v \in \mathcal{V}} b_j(v) = 1.$$

Al ampliar el espacio de estados surge una dificultad concreta. Cada renglón de $\mathbf{A}$ debe asignar probabilidad a la misma colección, de modo que el estado j conserve su significado sin importar el estado de origen. El proceso de Dirichlet jerárquico establece esa referencia común mediante una distribución global. En las cadenas ocultas, la construcción resultante se denomina HMM basado en un proceso de Dirichlet jerárquico, o HDP-HMM, y constituye una forma de cadena de Markov oculta infinita, abreviada iHMM Beal, Ghahramani, and Rasmussen (2002); Teh et al. (2006).

La distribución global puede imaginarse como una barra de longitud uno que se rompe sucesivamente. El primer fragmento recibe peso β_1; del resto se obtiene β_2, y así sucesivamente. En conjunto, los fragmentos forman una distribución de probabilidad sobre los estados potenciales. En lo que sigue, $DP(c, H)$ denota un proceso de Dirichlet con concentración c y medida base H; la abreviatura *i.i.d.* indica variables independientes con la misma distribución. Formalmente, se escribe

$$\beta = \sum_{k=1}^{\infty} \beta_k \delta_k,$$

donde

$$\beta_k = v_k \prod_{\ell=1}^{k-1} (1 - v_\ell), \qquad v_k \overset{\text{i.i.d.}}{\sim} \text{Beta}(1, \gamma), \qquad k \geq 1,$$

y se supone que

$$\pi \mid \beta \sim DP(\alpha_0, \beta), \qquad \mathcal{A}_i \mid \beta \sim DP(\alpha, \beta), \qquad i \geq 1,$$

donde $\mathcal{A}_i$ es el renglón i-ésimo de $\mathbf{A}$.

$$\mathbb{E}[a_{ij} \mid \beta] = \beta_j.$$

La distribución global β funciona como un catálogo compartido. Cada renglón A_i puede favorecer transiciones distintas, pero todos se refieren a los mismos estados y parten de los pesos β_j. En términos musicales, un contexto ya utilizado puede reaparecer en distintas regiones de la obra; un contexto nuevo tiene una probabilidad pequeña, pero positiva, de incorporarse.

El alfabeto observable no necesita crecer junto con los estados. Si $\mathcal{V}$ contiene doce clases de altura, cada contexto latente puede conservar una distribución categórica sobre esas mismas doce posibilidades. Lo desconocido es cuántos contextos hacen falta para organizar la secuencia, no cuántos símbolos pueden observarse.

El calificativo "infinito" describe la colección disponible, no el número de estados que aparecerán en una obra finita. Una trayectoria de longitud T puede visitar, como máximo, T estados y normalmente utiliza muchos menos. El modelo evita decidir esa cantidad antes del ajuste, aunque los estados obtenidos siguen siendo categorías estadísticas sin una etiqueta musical garantizada. Para interpretarlos deben examinarse sus emisiones, sus transiciones y su correspondencia con una referencia externa.

4.2 Del modelo infinito a un cálculo finito

Una computadora no puede almacenar una matriz con infinitos renglones y columnas. La implementación introduce entonces una cota K y aproxima la colección numerable mediante los estados $1, \dots, K$ Ishwaran and James (2001); Fox et al. (2011); Van Gael et al. (2008). El objetivo no es afirmar que la obra tiene exactamente K contextos, sino elegir una cota suficientemente alta y permitir que la inferencia deje estados sin usar.

Definición 4.2. *Fijado un entero $K \geq 2$, un* HDP-HMM truncado *con espacio observable discreto $\mathcal{V} = \{1, \dots, V\}$ queda determinado por las variables aleatorias*

$$v_k \sim \text{Beta}(1, \gamma), \qquad k = 1, \dots, K-1,$$

$$\beta_k = v_k \prod_{\ell=1}^{k-1} (1 - v_\ell), \qquad k = 1, \dots, K-1,$$

$$\beta_K = \prod_{\ell=1}^{K-1} (1 - v_\ell),$$

por el vector global $\beta = (\beta_1, \ldots, \beta_K)$ *y por las distribuciones condicionadas*

$$\pi \mid \beta \sim \mathrm{Dir}(\alpha_0 \beta_1, \ldots, \alpha_0 \beta_K),$$

$$A_i \mid \beta \sim \mathrm{Dir}(\alpha\beta + \varkappa e_i), \qquad i = 1, \ldots, K,$$

$$\varphi_i \sim \mathrm{Dir}\left(\frac{\eta}{V}, \ldots, \frac{\eta}{V}\right), \qquad i = 1, \ldots, K,$$

donde e_i *denota el i-ésimo vector canónico de* $\mathbb{R}^K$. *Si* $\mathrm{Cat}(p)$ *denota la distribución categórica con vector de probabilidades p, la cadena latente y las observaciones satisfacen*

$$X_1 \mid \pi \sim \mathrm{Cat}(\pi), \qquad X_t \mid X_{t-1} = i, \mathbf{A} \sim \mathrm{Cat}(A_i),$$

$$Y_t \mid X_t = i, \varphi_i \sim \mathrm{Cat}(\varphi_i), \qquad t \geq 1.$$

La notación distingue la cota computacional del número de estados utilizados por la trayectoria. Dentro de esa cota, β reparte el peso global entre los K estados; γ influye en cómo se distribuye ese peso; α_0 regula la distribución inicial y α permite que cada renglón de transición se aparte del patrón global. El parámetro $\varkappa$ puede favorecer la permanencia en el mismo estado, mientras que η controla la concentración de las emisiones sobre el alfabeto observable.

Una vez fijado K, las transiciones y emisiones vuelven a representarse mediante matrices finitas. Para una secuencia de longitud T, el costo dominante es del orden de $O(TK^2)$, pues en cada posición deben considerarse transiciones entre pares de estados. Por ello, una cota innecesariamente grande aumenta el costo de cálculo. Una cota demasiado pequeña, en cambio, puede limitar el ajuste.

En los experimentos se denomina *estado efectivo* a cualquiera de los estados presentes en la trayectoria inferida. Este conteo permite comprobar si el modelo utiliza una parte pequeña de la cota disponible, pero no mide por sí mismo la calidad musical. Dos estados efectivos pueden separar contextos útiles o dividir arbitrariamente una misma región; esa diferencia sólo puede establecerse mediante interpretación o anotaciones externas.

En esta tesis, las observaciones son clases de altura y el iHMM conserva un papel conceptual. El HDP-HMM truncado es la versión computacional que se ajusta con los datos de las obras y se compara con el HMM finito. La comparación comienza con una pieza extensa, cuya trayectoria puede examinarse antes de resumir los resultados del corpus.

4.3 De una obra al corpus

El caso ilustrativo es el tercer movimiento de la Sonata núm. 14 de Beethoven, una de las piezas extensas del corpus, con 4133 notas y 201 compases. Su longitud permite observar con detalle las diferencias entre trayectorias y entender los resultados que después se resumen. Este análisis sólo tiene carácter ilustrativo, pues una obra no constituye evidencia general a favor de un modelo.

Las tablas y figuras proceden de exportaciones conservadas de corridas anteriores. El repositorio contiene el código que las generó, pero no sus CSV primarios; las cifras pueden cotejarse con las exportaciones incluidas, aunque una reproducción completa exige recuperar esos archivos.

La Tabla 4.1 compara log-verosimilitud, estados ocupados y segmentos contiguos de la trayectoria. Un segmento es una sucesión de posiciones consecutivas a las que el modelo asigna el mismo estado; un cambio de estado inicia el siguiente. Para una misma secuencia, una log-verosimilitud mayor, es decir, menos negativa, indica que el modelo asigna más probabilidad a las observaciones. La magnitud depende de la longitud de la pieza, de modo que estos valores no deben compararse directamente entre obras de tamaños distintos.

Modelo	$\log L$	Estados	Segmentos	Long. media
HMM finito	-10242.186	88	560	7.380
HDP-HMM truncado	-7834.175	9	1075	3.845

Tabla 4.1: *Comparación entre el HMM finito y el HDP-HMM truncado en la obra de referencia: el tercer movimiento de la Sonata núm. 14 de Beethoven.*

Los dos modelos difieren tanto en el ajuste como en la ocupación de estados. El HMM finito ocupa 88 estados y obtiene log-verosimilitud -10242.186; el HDP-HMM ocupa 9 y obtiene -7834.175, una ganancia de 2408.011 unidades. Sin embargo, el modelo truncado produce 1075 segmentos, frente a 560 del HMM, y su

longitud media es menor. En esta obra, reducir el vocabulario de estados no equivale a producir menos cambios: el HDP-HMM reutiliza un conjunto pequeño de etiquetas con mayor frecuencia.

El resultado todavía puede depender de las particularidades de la sonata. Para saber si se repite en un conjunto controlado, la comparación se extiende a seis piezas breves antes de incorporar un repertorio mayor.

4.3.1 Resultados sobre un subconjunto clásico

La comparación controlada utiliza las seis piezas breves de la Tabla 4.2. Las observaciones son clases de altura. Para el HDP-HMM se fija $K = 12$, con $\alpha = 8$, $\alpha_0 = 4$, $\gamma = 2$, $\eta = 1$ y $\varkappa = 0$. Se realizan veinte iteraciones de inferencia, se descartan las diez primeras como calentamiento y se utiliza la semilla 7. Estos valores documentan la configuración de la corrida, pero no constituyen una búsqueda exhaustiva de hiperparámetros ni sustituyen los artefactos primarios faltantes.

Obra	Compositor	Notas	Compases
Cumpleaños feliz (Do mayor)	Tradicional	37	8
Oda a la alegría (variación fácil)	Desconocido	87	17
Para Elisa (versión fácil)	Beethoven	103	22
Cumpleaños feliz (arreglo)	Manjuprasad	106	19
Para Elisa (piano para principiantes)	Beethoven	149	23
Greensleeves	Desconocido	166	33

Tabla 4.2: *Subconjunto clásico limitado utilizado para la comparación documentada entre el HMM finito y el HDP-HMM truncado.*

Los resultados agregados aparecen en la Tabla 4.3. En las seis obras, el modelo truncado obtiene una log-verosimilitud mayor que el HMM finito. La ganancia media es de 92.970 unidades y la mediana de 98.739. El HDP-HMM utiliza, en promedio, 6.667 estados, frente a 10.833 del HMM finito.

Métrica	Valor
Obras comparables	6
Casos en que el HDP-HMM truncado mejora	6
Casos en que el HDP-HMM truncado empeora	0
Empates	0
Ganancia media de log-verosimilitud	92.970
Ganancia mediana de log-verosimilitud	98.739
Media de log-verosimilitud del HMM finito	-267.685
Media de log-verosimilitud del HDP-HMM truncado	-174.715
Estados activos medios del HMM finito	10.833
Estados efectivos medios del HDP-HMM truncado	6.667

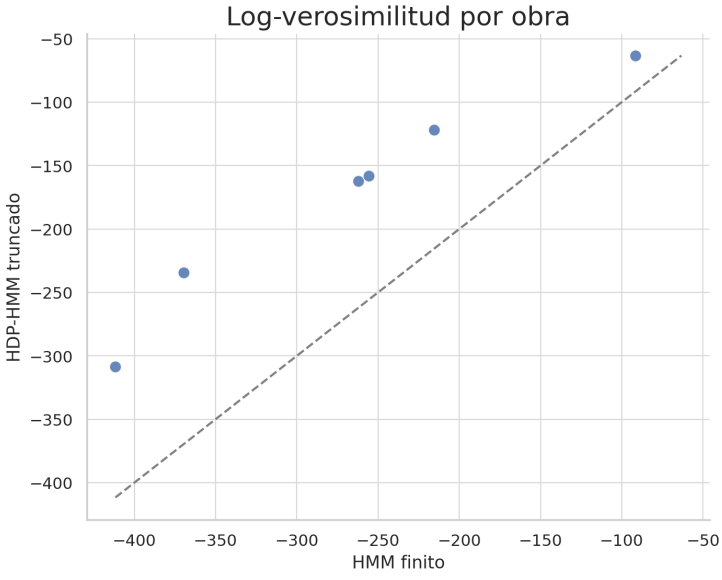
Tabla 4.3: *Resumen agregado de la comparación entre el HMM finito y el HDP-HMM truncado sobre el subconjunto clásico limitado.*

El promedio oculta cuánto cambia la ganancia entre piezas. La Tabla 4.4 presenta ese detalle: la diferencia es positiva en las seis obras, pero su magnitud no es uniforme.

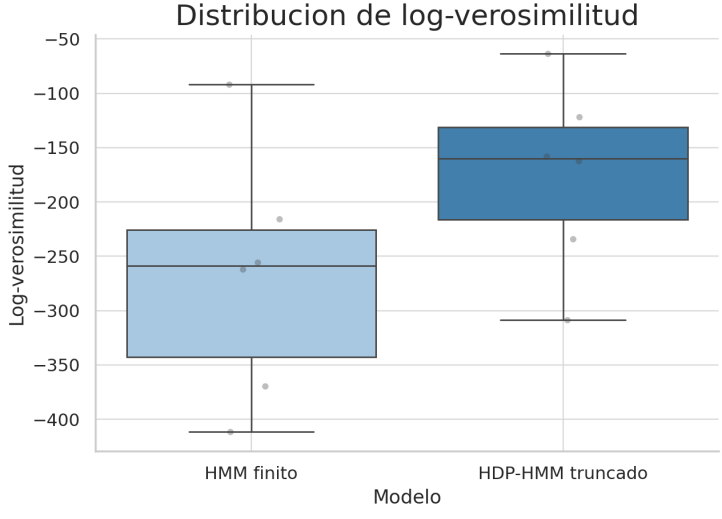
Obra	Compositor	Notas	$\log L_{fin}$	$\log L_{hdp}$	$\Delta \log L$
Cumpleaños feliz (Do mayor)	Tradicional	37	-91.575	-63.314	28.261
Oda a la alegría (variación fácil)	Desconocido	87	-215.515	-121.835	93.680
Para Elisa (versión fácil)	Beethoven	103	-255.714	-158.149	97.565
Cumpleaños feliz (arreglo)	Manjuprasad	106	-262.027	-162.114	99.914
Greensleeves	Desconocido	166	-411.682	-308.600	103.083
Para Elisa (piano para principiantes)	Beethoven	149	-369.596	-234.276	135.321

Tabla 4.4: *Comparación por obra en las seis piezas del subconjunto clásico. La ganancia se calcula como la diferencia HDP-HMM truncado − HMM finito.*

La Figura 4.1 muestra los valores que dan lugar al resumen anterior. El panel superior compara cada obra y el inferior presenta la distribución agregada; así puede distinguirse un patrón común de una diferencia debida a una sola pieza.



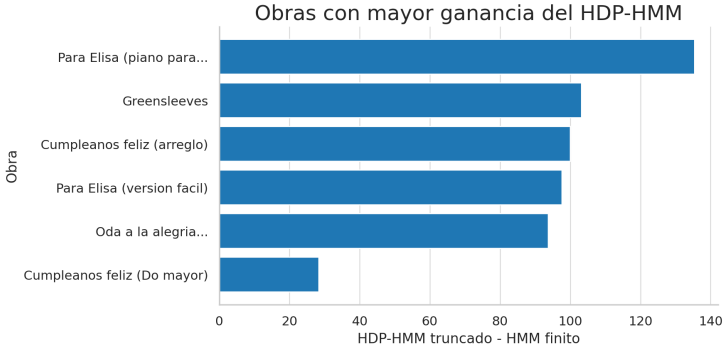
(a) *Comparación de log-verosimilitud por obra.*



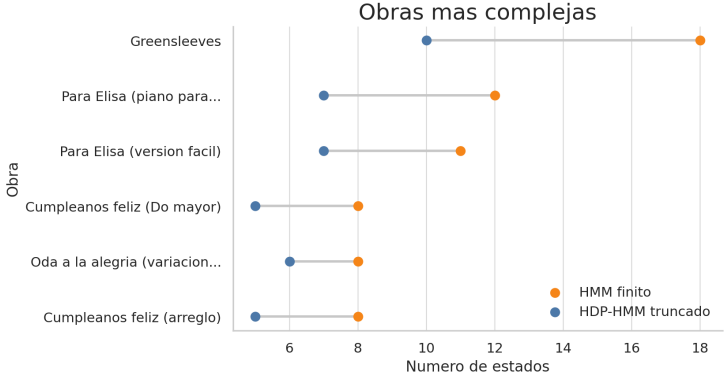
(b) *Distribución agregada de log-verosimilitud por modelo.*

Figura 4.1: *Ajuste probabilístico en el subconjunto clásico. Los paneles presentan los mismos seis casos por obra y de manera agregada.*

Queda otra pregunta: ¿la mayor log-verosimilitud exige ocupar más estados? La Figura 4.2 muestra lo contrario en estas corridas. El HDP-HMM logra un mejor ajuste y utiliza menos estados. Esta combinación indica un uso más compacto de los estados, pero todavía no permite juzgar la calidad musical de la trayectoria.



(a) *Ganancia de log-verosimilitud por obra.*



(b) *Comparación del número de estados por obra.*

Figura 4.2: *Ganancia de log-verosimilitud y ocupación latente en el subconjunto clásico. El panel superior muestra la diferencia de ajuste y el inferior el número de estados ocupados.*

El resultado es descriptivo y se limita a seis piezas: ni la log-verosimilitud ni el número de estados establecen que las fronteras latentes correspondan a frases, acordes o secciones. Para saber si la diferencia de ajuste aparece fuera de este repertorio breve, la evaluación se amplía a dos fuentes musicales.

4.3.2 Resultados sobre el corpus extendido

El corpus extendido incorpora obras más largas y una tradición musical distinta. Reúne repertorio occidental identificado como `MuseTrainer` y material de tradición makam procedente de `SymbTr`; la Tabla 4.5 resume su composición. En el análisis se conserva la procedencia de cada obra. Incluir ambos repertorios en una misma evaluación no supone que compartan la misma teoría armónica.

Fuente	Descripción del material	Obras
MuséTrainer	Repertorio tonal occidental de orientación pedagógica y clásica, con piezas breves y medianas en formato MusicXML.	69
SymbTr	Repertorio de música artística turca; el adaptador conserva metadatos de *makam*, *usul* y forma para preservar la procedencia modal.	100
Total	Corpus extendido utilizado en la comparación descriptiva.	169

Tabla 4.5: *Composición del corpus extendido utilizado en la comparación multicorpus.*

De las 169 obras catalogadas, 168 pudieron procesarse y 167 produjeron resultados comparables entre ambos modelos. Una obra de Mozart no quedó incluida en el lote final y una pieza de Brahms produjo un error de ejecución. Estos casos quedan fuera del denominador de la Tabla 4.6, que resume las 167 comparaciones válidas. En todas ellas, el HDP-HMM obtiene una log-verosimilitud mayor. La ganancia media es de 452.751 unidades y la mediana de 377.039; el HDP-HMM ocupa en promedio 8.222 estados, frente a 32.162 del HMM finito.

Fuente	Obras	$\overline{\Delta \log L}$	$\widetilde{\Delta \log L}$	$\overline{\log L}_{fin}$	$\overline{\log L}_{hdp}$	$\overline{K}_{fin}$	$\overline{K}_{hdp}$
Global	167	452.751	377.039	-1598.180	-1145.429	32.162	8.222
MuséTrainer	67	585.443	467.011	-2667.850	-2082.406	46.418	8.731
SymbTr	100	363.848	336.438	-881.502	-517.654	22.610	7.880

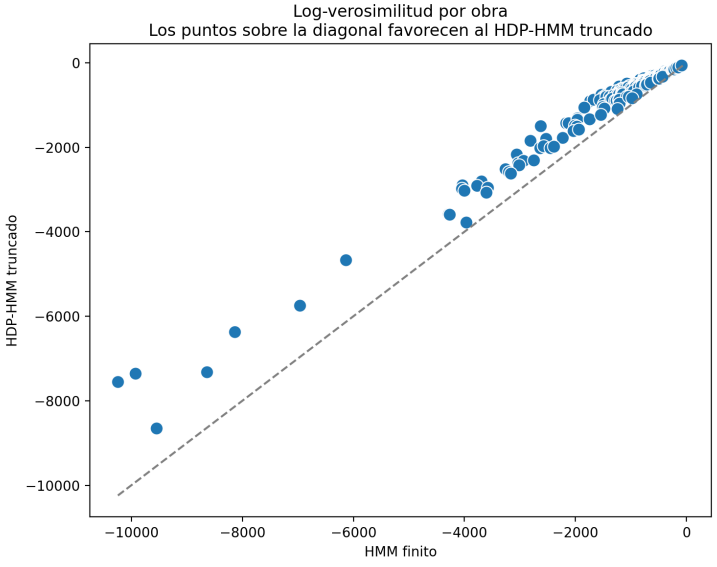
Tabla 4.6: *Resumen agregado de la comparación entre el HMM finito y el HDP-HMM truncado sobre el corpus extendido. La mejora se calcula como HDP-HMM truncado − HMM finito.*

Para no interrumpir la lectura con una tabla de 167 obras, la Tabla 4.7 presenta ocho ejemplos: cuatro de cada fuente y con longitudes distintas. La selección es ilustrativa. Los promedios y denominadores de la Tabla 4.6 proceden del conjunto completo de casos válidos.

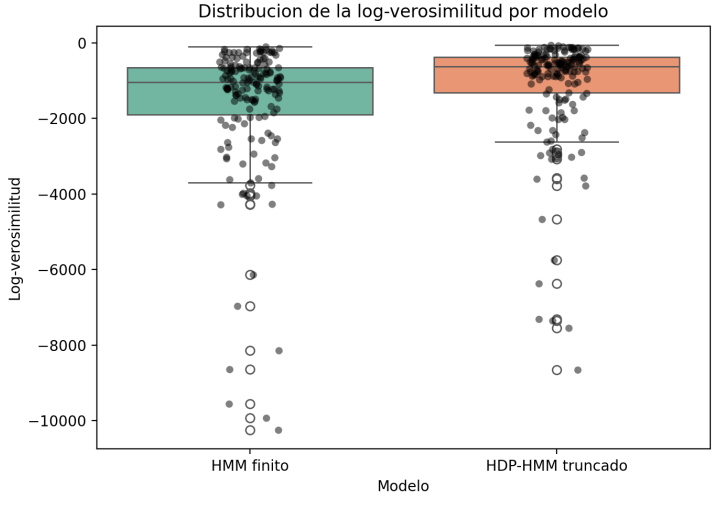
Fuente	Obra	Notas	$\log L_{fin}$	$\log L_{bdp}$	$\Delta \log L$
MuseTrainer	Cumpleaños feliz (Do mayor)	37	-91.575	-62.059	29.516
MuseTrainer	Danse Villageoise	519	-1286.408	-887.259	399.149
MuseTrainer	Clair de Lune	1220	-3020.550	-2421.226	599.324
MuseTrainer	Sonata núm. 14, tercer movimiento	4133	-10242.186	-7549.906	2692.280
SymbTr	Acemkürdî Aranağme (Düyek)	58	-144.102	-66.151	77.951
SymbTr	Aldanma Dünya Varına	266	-660.614	-349.715	310.898
SymbTr	Yıllar Sonra Rastladım...	417	-1035.314	-546.391	488.922
SymbTr	Âşık-I Ger	1135	-2815.965	-1841.559	974.407

Tabla 4.7: *Ejemplos de resultados por obra en el corpus extendido. Se incluyen cuatro piezas de* `MuseTrainer` *y cuatro de* `SymbTr` *con distintas longitudes.*

Las 167 comparaciones aparecen en la Figura 4.3. El primer diagrama permite comprobar el signo de cada diferencia por obra; el segundo resume la distribución de log-verosimilitud dentro de cada modelo.



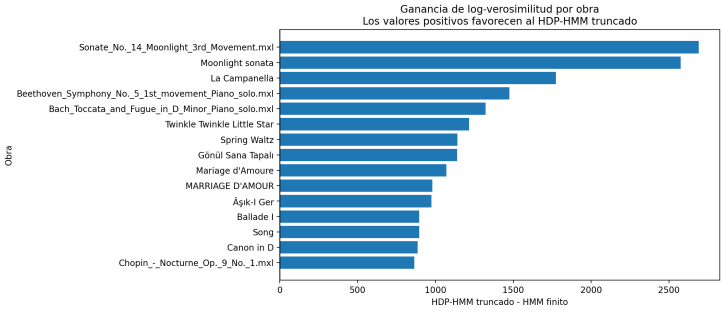
(a) *Comparación de log-verosimilitud por obra en el corpus extendido.*



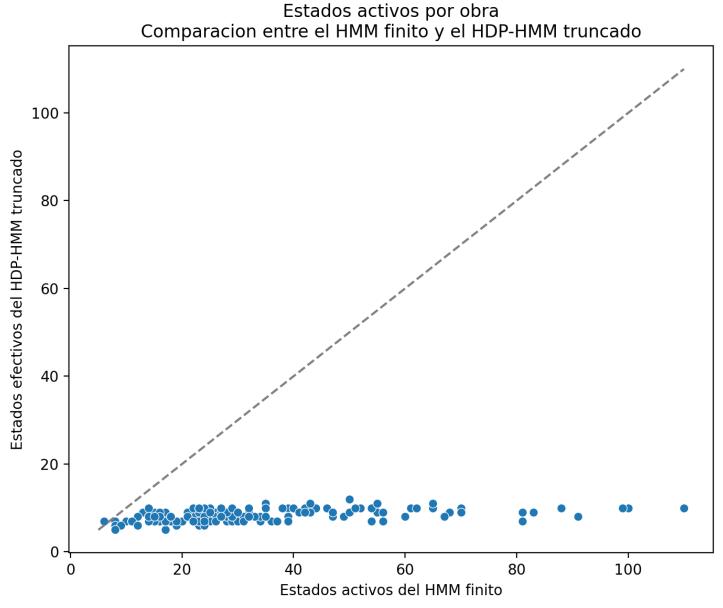
(b) *Distribución agregada de log-verosimilitud por modelo.*

Figura 4.3: *Log-verosimilitud por obra y distribución agregada en el corpus extendido. Las comparaciones se limitan a los* 167 *casos válidos para ambos modelos.*

La Figura 4.4 resume otros dos aspectos del resultado. El panel superior presenta las quince mayores ganancias de log-verosimilitud, no las 167 comparaciones; el signo del conjunto completo se observa en la Figura 4.3 y en la Tabla 4.6. El panel inferior compara el número de estados en los casos que cuentan con ambas medidas.



(a) *Quince obras con mayor ganancia de log-verosimilitud.*



(b) *Comparación del número de estados utilizados por ambos modelos.*

Figura 4.4: *Mayores ganancias de log-verosimilitud y ocupación latente en el corpus extendido. El panel superior muestra una selección de quince obras; el inferior incluye los casos para los que se dispone de ambos conteos.*

En las corridas de este capítulo, el HDP-HMM alcanza una log-verosimilitud mayor y utiliza menos estados. El patrón aparece en el subconjunto clásico y en las 167 obras comparables del corpus extendido, pero se refiere únicamente al ajuste de las

secuencias de clases de altura. No demuestra que los estados recuperen categorías de la teoría makam ni ha sido contrastado con anotaciones estructurales. El capítulo siguiente plantea una evaluación distinta y compara los modelos en una tarea predictiva común fuera de muestra.

Capítulo 5

Comparación predictiva entre HMM, HDP-HMM, VOMM y transformador

El HMM finito y el HDP-HMM se apoyan en una misma representación de la melodía: detrás de las notas observadas hay una trayectoria de estados que cambia en el tiempo. El capítulo anterior utilizó esa representación para estudiar qué estados aparecen, cómo se conectan y con qué frecuencia se reutilizan. Fijar o aprender el número de estados modifica la descripción, pero ambos modelos parten de la misma idea.

Un transformador causal parte de otra representación. No postula una trayectoria discreta de estados ocultos, sino que utiliza el contexto anterior para asignar probabilidades al siguiente evento mediante atención Vaswani et al. (2017). Este principio también se ha aplicado a secuencias musicales simbólicas Huang et al. (2019). Por eso, equiparar sus componentes internos resulta poco informativo: una cabeza de atención no desempeña el mismo papel que un estado de un HMM. La comparación necesita una pregunta que los distintos modelos puedan responder en los mismos términos: dada una sucesión de clases de altura, ¿qué probabilidad asigna cada uno a la nota que aparece después?

Esa pregunta permite establecer una base común, aunque sólo cubre una parte del problema musical. Un modelo puede anticipar bien la siguiente nota sin recuperar frases, secciones o funciones armónicas. También puede ocurrir que una trayectoria

latente sea interpretable y no alcance la mejor predicción fuera de muestra. El capítulo mantiene separados ambos objetivos: la descripción estructural sigue siendo el objetivo musical, pero aún no cuenta con una evaluación externa, mientras que la predicción del siguiente evento proporciona la tarea común. También se registra el costo computacional, pues condiciona qué resultados pueden reproducirse en la práctica.

Se incorpora también un modelo de Markov de orden variable, o VOMM por sus siglas en inglés Begleiter, El-Yaniv, and Yona (2004). A diferencia del HMM de primer orden, el VOMM puede consultar varios eventos observados del pasado; a diferencia del transformador, lo hace mediante tablas explícitas de conteos. Sirve así como punto de comparación para estimar cuánta mejora predictiva puede obtenerse con memoria local antes de recurrir a una arquitectura neuronal.

La Figura 5.1 muestra la relación entre las dos preguntas. Los cuatro modelos reciben la misma representación y predicen el siguiente evento. El HMM finito y el HDP-HMM producen, además, trayectorias latentes que podrían utilizarse en un análisis estructural. A partir de ellas puede proponerse una segmentación, pero no constituyen segmentaciones de referencia.

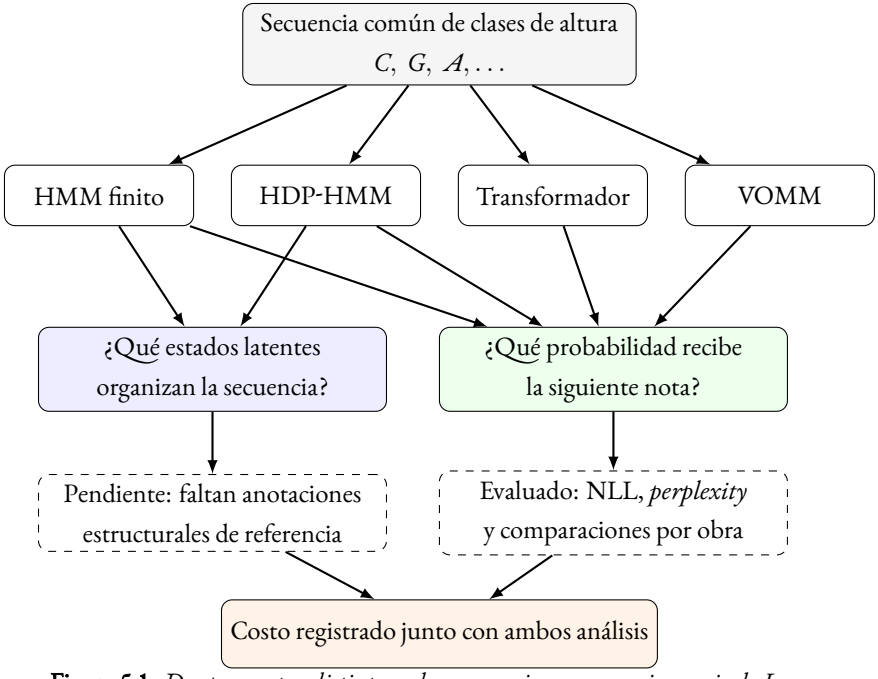


Figura 5.1: *Dos preguntas distintas sobre una misma secuencia musical. La predicción pudo compararse entre las cuatro familias; la descripción estructural requiere todavía una referencia externa.*

5.1 Una tarea común para modelos diferentes

Considérese un segmento de prueba $y_1, \ldots, y_T$. En cada posición t, el modelo observa el contexto permitido c_t y asigna una probabilidad al símbolo que realmente sigue. La NLL por evento mide la sorpresa promedio del modelo:

$$\mathrm{NLL} = -\frac{1}{T}\sum_{t=1}^{T} \log P(y_t \mid c_t), \qquad \text{perplexity} = \exp(\mathrm{NLL}).$$

La penalización disminuye cuando el modelo concentra mayor probabilidad en los eventos observados. Valores menores de NLL y *perplexity* indican, por tanto, mejor predicción. Las dos cantidades expresan la misma información en escalas distintas; la *perplexity* facilita la lectura, pero no aporta una segunda fuente independiente de evidencia.

Usar la misma fórmula no basta para garantizar una comparación equitativa: los modelos deben puntuar exactamente los mismos eventos. El símbolo de inicio se utiliza como contexto, pero no cuenta como una nota adicional que deba predecirse. El símbolo de relleno del transformador tampoco se incluye entre los eventos puntuados. Los conjuntos de validación y prueba se dividen en segmentos no superpuestos de hasta 128 eventos, incluida la cola final aunque sea corta. Cada nota de prueba se puntúa una sola vez, con los mismos reinicios de contexto en las cuatro familias.

La tarea común tiene un alcance limitado. La clase de altura conserva la identidad de la nota módulo octava, pero omite duración, registro, dinámica y buena parte de la organización métrica. El experimento estudia regularidades secuenciales en un alfabeto compartido, no toda la información de la partitura.

5.2 Cómo se construye la comparación

La obra canónica es la unidad básica de partición. Sus arreglos o variantes se asignan siempre al mismo conjunto, pues entrenar con una versión y evaluar con otra casi equivalente produciría una fuga de información. Con semilla 7, se reserva el 15% de las obras para prueba y el 10% para validación; el resto se utiliza para entrenamiento.

Sobre esa partición se construyen subconjuntos anidados con el 10%, 25%, 50%, 75% y 100% del acervo de entrenamiento. Cada fracción amplía la anterior para una misma semilla, en lugar de reemplazarla por un conjunto distinto. Esto permite observar cómo cambia el desempeño de cada modelo al aumentar los datos disponibles. Las semillas de datos 1, 2 y 3 cambian el orden de incorporación de las obras, mientras que las semillas de modelo 1 y 2 modifican la inicialización.

En la fracción completa, cambiar la semilla de datos ya no cambia el subconjunto. Las tres filas correspondientes contienen el mismo acervo y no son tres muestras independientes. La repetición no altera la comparación pareada por obra, pero la dispersión del último punto de la curva debe leerse con cautela.

Las configuraciones se seleccionan únicamente con validación. Para el HMM finito se comparan 12, 24 y 48 estados, mientras que para el HDP-HMM se fija una cota de 24 estados latentes y se contrastan tres combinaciones de hiperparámetros. El transformador conserva una arquitectura pequeña de tres capas y dimensión interna 128. Para el VOMM se comparan los órdenes 1, 2, 4 y 8. La Tabla 5.1 reúne la configu-

ración de la corrida.

Tabla 5.1: *Protocolo ejecutado para la comparación predictiva*

Componente	Configuración ejecutada
Tarea	Predicción autorregresiva de la siguiente clase de altura
Representación	`pitch_class`; sin silencios, sin transposición y con preferencia por la voz aguda
Partición primaria	75% entrenamiento, 10% validación y 15% prueba; agrupación por obra canónica; semilla 7
Corpus	Muestra de 3000 archivos de PDMX; semilla de muestreo 7; 2933 piezas utilizables tras el preprocesamiento
Curva de aprendizaje	Fracciones 0.10, 0.25, 0.50, 0.75 y 1.00; semillas de datos 1, 2 y 3; subconjuntos anidados por obra
Repeticiones	Semillas de modelo 1 y 2; en la fracción completa las semillas de datos repiten el mismo subconjunto y no constituyen réplicas independientes
HMM finito	Selección entre 12, 24 y 48 estados; máximo de 100 iteraciones
HDP-HMM truncado	Cota $K = 24$; 120 iteraciones; calentamiento de 60; tres configuraciones de hiperparámetros
Transformador	Tres capas; dimensión 128; cuatro cabezas; dimensión intermedia 256; hasta 25 épocas con detención temprana
VOMM	Control diagnóstico; selección por validación entre órdenes 1, 2, 4 y 8
Métrica primaria	NLL de prueba por token; se comprobó que la cobertura fuera idéntica entre modelos
Medidas complementarias	*perplexity*, tiempo, parámetros, seis diferencias pareadas, intervalo *bootstrap* y ajuste de Holm

El análisis final toma la obra como unidad de comparación. Primero se promedian las variantes y repeticiones de una misma obra. Después se calcula, para cada par de modelos, la diferencia de NLL sobre las mismas piezas. De este modo, cada obra aporta un punto y una pieza larga no se convierte, por su número de notas, en centenares de observaciones independientes. La incertidumbre se estima con un intervalo *boot-*

strap obtenido mediante 10 000 remuestreos de las obras. La prueba de rangos con signo de Wilcoxon utiliza el signo y el orden de las diferencias pareadas, y el ajuste de Holm toma en cuenta que se examinan seis pares a la vez Wilcoxon (1945); Holm (1979); Efron (1979); Demšar (2006).

5.2.1 Comprobaciones previas

Una diferencia entre modelos sólo es interpretable si todos resuelven la misma tarea. En la corrida final, el símbolo de inicio del VOMM funciona como contexto y el relleno del transformador queda fuera del cálculo de la puntuación. Una auditoría compara, obra por obra, los eventos esperados con los evaluados. Cualquier omisión, duplicación o alteración del orden invalida la corrida; no se corrige modificando el denominador.

El programa conserva el modelo elegido por validación, puede reanudarse aun cuando la última línea de un *checkpoint* esté incompleta y reutiliza la caché para muestras menores. Los cálculos reescalados y vectorizados de ambos HMM se contrastan mediante pruebas de regresión con las versiones que operan en dominio logarítmico. Estas comprobaciones verifican que la corrida cumpla las condiciones computacionales previstas; no constituyen un resultado musical.

5.3 La corrida final con PDMX

La corrida `tesis_3000_gpu_20260823_1941` terminó el 23 de agosto de 2026. Se muestrearon 3000 archivos del corpus PDMX con semilla 7 Long et al. (2025). El preprocesamiento dejó 2933 piezas utilizables y excluyó 67, para un total de 693 754 eventos. El conjunto de prueba reunió 424 piezas. En la fracción completa, el entrenamiento utilizó 2173 piezas y 500 959 eventos.

Las tres semillas de datos y las cinco fracciones de entrenamiento forman quince celdas. En cada una se ajustaron dos inicializaciones del HMM finito, del HDP-HMM y del transformador, junto con un VOMM determinista. El diseño produjo 105 filas. El transformador se ajustó en GPU mediante CUDA; los tres modelos restantes se ejecutaron en CPU con doce procesos. Los tiempos observados corresponden, por tanto, a dispositivos distintos.

La ejecución se interrumpió previamente como medida preventiva ante la temperatura del equipo. Al reanudarla, se recuperaron los 3000 archivos desde la caché y

se continuó desde los modelos ya terminados. La interrupción no invalidó el experimento, pues fue posible reanudarlo sin repetir los modelos terminados. Aun así, confirmó la necesidad práctica de conservar *checkpoints* y controlar por separado la carga de CPU y GPU.

5.4 Qué cambia cuando aumenta el corpus

La *perplexity* media de prueba aparece en la Tabla 5.2. En la primera fracción, con alrededor de 55 000 eventos de entrenamiento, el transformador obtiene 7.640 y el HMM finito 7.655. La diferencia es pequeña frente a la variación registrada, de modo que en ese régimen de datos no se observa una ventaja clara entre ambos.

Tabla 5.2: Perplexity *media de prueba por fracción de entrenamiento. Menor es mejor; la última columna compara cada modelo consigo mismo entre los extremos de la curva.*

Modelo	0.10	0.25	0.50	0.75	1.00	Cambio 0.10 → 1.00
Transformador	7.640	7.287	6.878	6.259	5.823	-23.8%
HMM finito	7.655	7.447	7.403	7.363	7.356	-3.9%
HDP-HMM truncado	8.223	8.033	8.018	7.956	7.968	-3.1%
VOMM	8.756	8.496	8.376	8.195	8.022	-8.4%

Las curvas se separan al añadir obras. El transformador reduce su *perplexity* de 7.640 a 5.823, un cambio de 23.8%. El HMM finito pasa de 7.655 a 7.356 y el HDP-HMM de 8.223 a 7.968, con reducciones de 3.9% y 3.1%, respectivamente. El VOMM queda en una posición intermedia y reduce su valor en 8.4%. Dentro del intervalo estudiado, el transformador sigue beneficiándose del aumento del corpus; las configuraciones evaluadas de los otros modelos muestran reducciones menores.

En las treinta selecciones del HMM finito se eligieron 48 estados, el valor más alto disponible. La curva sólo muestra que el HMM con $K \leq 48$ se aproxima a una meseta, no que toda la familia finita haya agotado su capacidad. Distinguir ambas explicaciones exige ampliar la rejilla y repetir la selección mediante validación.

El HDP-HMM obtiene una *perplexity* mayor que el HMM finito en las cinco fracciones. Utiliza entre 14 y 17 estados efectivos de los 24 disponibles, de modo que la cota no parece ser una restricción inmediata. En este corpus y para esta tarea, la cardinalidad latente flexible no produjo una ventaja predictiva. El resultado no contradice el Capítulo 4: allí se estudiaron la log-verosimilitud de ajuste y la complejidad

latente sobre otros corpus; aquí se mide predicción fuera de muestra sobre PDMX.

5.4.1 Comparación obra por obra

Los promedios sobre todos los eventos pueden quedar dominados por unas cuantas piezas largas. Para saber cómo se distribuye la diferencia, se compara la NLL obra por obra. De las 424 piezas de prueba, 414 tuvieron una NLL válida para cada par comparado. La Tabla 5.3 presenta los seis contrastes; un signo negativo favorece al primer modelo nombrado.

Tabla 5.3: *Comparaciones pareadas de NLL por obra en la fracción completa. Los intervalos se obtuvieron mediante* bootstrap *y los valores p se ajustaron conjuntamente mediante Holm.*

Comparación	Diferencia media	IC del 95%	p ajustado
HMM finito − HDP-HMM	-0.1071	$[-0.1184, -0.0959]$	2.5×10^{-52}
HMM finito − transformador	$+0.2505$	$[+0.2367, +0.2641]$	7.1×10^{-68}
HMM finito − VOMM	-0.0734	$[-0.0855, -0.0613]$	9.6×10^{-27}
HDP-HMM − transformador	$+0.3576$	$[+0.3401, +0.3750]$	4.2×10^{-68}
HDP-HMM − VOMM	$+0.0336$	$[+0.0164, +0.0513]$	3.5×10^{-4}
Transformador − VOMM	-0.3240	$[-0.3382, -0.3100]$	1.1×10^{-68}

La diferencia media entre el HMM finito y el transformador es de 0.2505 nats por evento, con intervalo $[0.2367, 0.2641]$, a favor del transformador. El nat es la unidad que resulta de utilizar el logaritmo natural en la NLL. Frente al HDP-HMM, la diferencia es de 0.3576 nats. Ninguno de los seis intervalos incluye el cero y todos los valores p permanecen por debajo de 0.05 después del ajuste de Holm. Con este número de obras, la magnitud de las diferencias y sus intervalos son más informativos que un valor p aislado.

La comparación entre HDP-HMM y VOMM muestra el efecto de elegir una unidad de análisis. Al sumar primero todos los eventos, las obras largas reciben mayor peso y el promedio favorece ligeramente al HDP-HMM. Cuando cada obra recibe el mismo peso, el contraste favorece al VOMM por 0.0336 nats. Son preguntas distintas: esta tesis adopta la segunda para la inferencia pareada y conserva la primera sólo como resumen global.

5.5 El costo de la mejora predictiva

La calidad predictiva no describe por sí sola el costo de obtenerla. La Tabla 5.4 presenta el tiempo de ajuste, el tiempo de evaluación y el tamaño del modelo en sus unidades originales. No se combinan en una sola puntuación porque un segundo de cómputo, un parámetro y una unidad de NLL no son cantidades intercambiables.

Tabla 5.4: *Costo medio observado en la fracción completa. Los tiempos reales de ejecución se midieron en dispositivos distintos y no constituyen una comparación neutral del hardware.*

Modelo	Parámetros	Ajuste (s)	Evaluación (s)	NLL
Transformador	415 872	169	2.6	1.762
HDP-HMM truncado	863	578	0.5	2.075
HMM finito	2 879	628	0.6	1.996
VOMM	101 201[a]	41	8.4	2.082

[a] Para VOMM, la cifra corresponde al tamaño de la tabla de conteos y no a parámetros continuos entrenables.

Con la configuración disponible, el transformador se ajustó en 169 segundos, frente a 578 del HDP-HMM y 628 del HMM finito. La arquitectura neuronal requirió menos tiempo de ajuste que los modelos clásicos en esta corrida. La comparación no es neutral respecto del hardware: el transformador se ejecutó en GPU y los otros modelos en CPU. Por tanto, el menor tiempo observado sólo es válido para esta máquina y estas implementaciones.

El VOMM tiene el menor tiempo de ajuste, 41 segundos, pero tarda más en evaluar y obtiene peor NLL que el transformador y el HMM finito. Ninguna de las cuatro familias queda dominada en los tres criterios de NLL, ajuste y evaluación; por ello, todas forman parte de la frontera parcial de Pareto Miettinen (1999). Ningún modelo mejora los tres valores a la vez frente a todos los demás. La frontera es parcial porque aún falta medir la calidad estructural y, por tanto, no basta para decidir la utilidad musical de cada modelo.

5.6 Lo que la predicción todavía no responde

La NLL indica qué modelo asigna mayor probabilidad a las notas de prueba, pero no dice si una trayectoria latente coincide con una organización musical reconocible. Para responder esa pregunta hacen falta fronteras o etiquetas estructurales anotadas

de manera independiente en las mismas obras. Con esa referencia podrían compararse los puntos de cambio y las particiones inferidas mediante F_1 de fronteras, información mutua normalizada e índice de Rand ajustado.

La corrida no dispuso del archivo de referencia y el artefacto estructural registró `not_evaluated`. Por ello no se calcularon esas métricas. La atención del transformador y los estados de los HMM siguen siendo hipótesis de organización: la menor NLL o la existencia de una trayectoria no demuestran que se hayan recuperado frases, secciones o funciones armónicas.

La comparación predictiva también tiene límites concretos. Debe ampliarse la rejilla del HMM finito más allá de 48 estados y repetirse la comparación con otra semilla de partición. Para obtener tiempos comparables entre dispositivos habría que usar recursos equivalentes. Falta también recuperar y preservar los CSV y JSON originales de la corrida. Las tablas actuales pueden regenerarse a partir del informe conservado en el repositorio. Esto permite rastrear su procedencia, pero no sustituye una auditoría directa de los archivos originales.

En la corrida estudiada, el transformador obtiene la menor *perplexity* desde la fracción 0.25, y su diferencia frente a los otros modelos aumenta al incorporar más obras. Con las configuraciones evaluadas, el HMM finito predice mejor que el HDP-HMM entre los modelos de estados latentes; el VOMM ofrece el ajuste más rápido, pero no la mejor predicción. Estos resultados no permiten ordenar los modelos por su capacidad para representar la organización musical hasta que se incorpore la referencia estructural faltante.

Capítulo A

De la distribución de Dirichlet al proceso jerárquico

A.1 Sobre el proceso de Dirichlet y los modelos jerárquicos

El HDP-HMM relaciona varias distribuciones de transición sin fijar de antemano el número de estados latentes. Para entender esa construcción conviene partir de un problema más sencillo: representar probabilidades sobre un conjunto finito de símbolos y expresar la incertidumbre acerca de ellas. El primer paso utiliza una distribución de Dirichlet; cuando existen varios contextos, sus distribuciones se vinculan mediante una jerarquía. El proceso de Dirichlet extiende esta idea sin prefijar el número de categorías latentes Murphy (2012); Ferguson (1973); Teh et al. (2006).

Sea $\mathcal{V} = \{1, \ldots, K\}$ un conjunto finito. Una variable aleatoria Y con valores en $\mathcal{V}$ sigue una distribución categórica si existe un vector de probabilidades

$$\mathbf{p} = (p_1, \ldots, p_K), \qquad p_k \geq 0, \qquad \sum_{k=1}^{K} p_k = 1,$$

tal que

$$P(Y = k \mid \mathbf{p}) = p_k.$$

El vector $\mathbf{p}$ pertenece al simplex de dimensión $K - 1$ y contiene el peso asignado a cada categoría posible. Al observar muchas realizaciones para inferir $\mathbf{p}$, los conteos

indican qué categorías aparecieron con mayor frecuencia, pero no expresan por sí solos la incertidumbre de la estimación.

La distribución de Dirichlet cumple esa función. Se escribe

$$\mathbf{p} \sim \text{Dirichlet}(a_1, \ldots, a_K),$$

y define una distribución de probabilidad sobre el conjunto de todos los vectores $\mathbf{p}$ admisibles. Los parámetros $(a_1, \ldots, a_K)$ controlan la concentración de masa en el simplex: si todos son grandes, la distribución se concentra más; si son pequeños, permite configuraciones más extremas. En términos intuitivos, la distribución de Dirichlet actúa como una distribución a priori sobre probabilidades categóricas.

Su importancia práctica proviene de la conjugación. Si se observa una muestra de variables categóricas con conteos

$$(n_1, \ldots, n_K),$$

entonces la distribución posterior de $\mathbf{p}$ vuelve a ser Dirichlet:

$$\mathbf{p} \mid \text{datos} \sim \text{Dirichlet}(a_1 + n_1, \ldots, a_K + n_K).$$

La actualización bayesiana tiene entonces una forma directa. Cada conteo observado corrige el peso previo asociado a su categoría, y el resultado sigue perteneciendo a la misma familia de distribuciones. La Dirichlet puede entenderse así como una forma de regularizar probabilidades discretas sin perder su interpretación probabilística.

Una sola distribución deja de bastar cuando cada contexto de una secuencia tiene su propio vector de probabilidades. Estimar estos vectores de manera independiente produce estimaciones inestables en los contextos con pocos datos y desaprovecha las similitudes entre las distribuciones locales.

Un modelo jerárquico introduce entonces un nivel superior que gobierna los parámetros locales, tratados a su vez como variables aleatorias. Las distribuciones dejan así de estimarse como piezas aisladas: pueden apartarse unas de otras, pero permanecen vinculadas por una organización global.

En el caso finito, esta idea puede escribirse así. Se introduce primero una distribución global

$$\mathbf{p}^{(0)} \sim \text{Dirichlet}(b_1, \ldots, b_K),$$

y después se definen distribuciones locales

$$\mathbf{p}^{(j)} \mid \mathbf{p}^{(0)} \sim \text{Dirichlet}(\lambda p_1^{(0)}, \ldots, \lambda p_K^{(0)}), \qquad j = 1, \ldots, m.$$

Aquí $\mathbf{p}^{(0)}$ fija un perfil global, mientras que cada $\mathbf{p}^{(j)}$ representa una distribución local que puede apartarse de él, aunque no de manera arbitraria. El parámetro λ regula el grado de similitud con el nivel global. Cuando λ es grande, las distribuciones locales tienden a parecerse más entre sí; cuando es pequeño, tienen mayor libertad para divergir.

En un HMM hay una distribución inicial, varios renglones de una matriz de transición y, según la formulación, varias distribuciones de emisión. Cada una describe un comportamiento local, aunque todas remiten al mismo repertorio latente. Una estructura jerárquica permite compartir información entre ellas y estabilizar las estimaciones cuando hay pocos datos. En la literatura bayesiana este compromiso se conoce como agrupamiento parcial: los contextos no se estiman de manera independiente, pero tampoco se obliga a que compartan una sola distribución Murphy (2012).

La construcción anterior todavía supone que el número de categorías K es finito y conocido. La distribución de Dirichlet representa la incertidumbre sobre un vector cuya dimensión ya está fijada; si el número de componentes latentes no se conoce de antemano, hace falta pasar de una distribución sobre vectores finitos a una distribución sobre medidas de probabilidad.

El proceso de Dirichlet da este paso Ferguson (1973). En lugar de asignar una distribución a priori a un vector finito $\mathbf{p}$, la asigna a una medida aleatoria G. Se mantiene la intuición del caso finito: todavía se representa incertidumbre sobre pesos probabilísticos, pero el repertorio de átomos potenciales ya no tiene que fijarse mediante un entero K. El espacio latente puede incorporar tantos componentes como requieran los datos.

Aunque la medida base no sea discreta, las realizaciones del proceso de Dirichlet lo

son casi seguramente. Por ello, G puede entenderse como una medida de probabilidad formada por una familia numerable de átomos con pesos aleatorios. La representación de *stick-breaking* introducida por Sethuraman hace explícita esta construcción Sethuraman (1994): la masa total se reparte sucesivamente en una colección numerable de porciones y produce una medida discreta aleatoria.

La jerarquía se conserva en el caso no paramétrico: una medida global sirve de referencia para varias medidas locales, del mismo modo que la distribución global organizaba las distribuciones locales en el caso finito. Con ello se obtiene una familia de distribuciones de transición relacionadas que comparten un repertorio potencialmente infinito de estados latentes Teh et al. (2006).

Cuando no se conoce de antemano la complejidad latente, la jerarquía bayesiana permite que varias distribuciones compartan un repertorio sin imponerles un único comportamiento local. A partir de esta construcción, el Capítulo 4 define el HDP-HMM e introduce el truncamiento necesario para calcularlo.

Capítulo B
Propiedades del proceso observable en un HMM

En un HMM, la propiedad de Markov pertenece a la dinámica oculta y no se transfiere, en general, a las observaciones. El par formado por el estado y la observación sí conserva esa propiedad. Un contraejemplo permite precisar la diferencia utilizada en el Capítulo 3.

B.1 Las observaciones pueden conservar memoria

Proposición B.1. *El proceso observable $(Y_t)_{t\geq 1}$ de una cadena de Markov oculta no es, en general, una cadena de Markov de primer orden.*

Proof. Considérese $\mathcal{S} = \{1, 2\}$, $\mathcal{V} = \{0, 1\}$ y

$$A = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, \qquad P(X_1 = 1) = P(X_1 = 2) = \tfrac{1}{2}.$$

El estado inicial permanece fijo durante toda la trayectoria. Condicionadas a $X_1 = 1$, las observaciones son Bernoulli independientes con parámetro p; condicionadas a $X_1 = 2$, lo son con parámetro q, donde $p, q \in (0, 1)$ y $p \neq q$.

Por la ley de la probabilidad total,

$$P(Y_3 = 1 \mid Y_2 = 1, Y_1 = 1) = \frac{p^3 + q^3}{p^2 + q^2},$$

mientras que

$$P(Y_3 = 1 \mid Y_2 = 1) = \frac{p^2 + q^2}{p + q}.$$

Ambas cantidades son distintas, pues

$$(p^3 + q^3)(p + q) - (p^2 + q^2)^2 = pq(p - q)^2 > 0.$$

Por tanto, conocer Y_1 además de Y_2 cambia la distribución de Y_3 y el proceso observable no satisface la propiedad de Markov de primer orden. □

La razón del resultado es más sencilla que el cálculo. Cada observación aporta evidencia sobre cuál de los dos regímenes ocultos está activo. Dos observaciones contienen más información sobre ese régimen que una sola y, por ello, pueden cambiar la predicción del siguiente símbolo.

B.2 El proceso conjunto sí es markoviano

Proposición B.2. *Sea $Z_t = (X_t, Y_t)$. Entonces $(Z_t)_{t \geq 1}$ es una cadena de Markov en $\mathcal{S} \times \mathcal{V}$.*

Proof. Sean $(i, v), (j, w) \in \mathcal{S} \times \mathcal{V}$. Por la propiedad de Markov de (X_t) y la independencia condicional de las emisiones,

$$\begin{aligned} &P(Z_{t+1} = (j, w) \mid Z_t = (i, v), Z_{t-1}, \ldots, Z_1) \\ &\quad = P(X_{t+1} = j \mid X_t = i) P(Y_{t+1} = w \mid X_{t+1} = j) \\ &\quad = a_{ij} b_j(w). \end{aligned}$$

La expresión depende del presente sólo a través de Z_t, por lo que el proceso conjunto satisface la propiedad de Markov. □

B.3 Un caso límite

La memoria adicional desaparece si la observación revela por completo el estado oculto.

Proposición B.3. *Supóngase que existe una función* $f\colon \mathcal{V} \to \mathcal{S}$ *tal que*

$$X_t = f(Y_t) \quad \textit{casi seguramente para todo } t \geq 1.$$

Entonces $(Y_t)_{t\geq 1}$ *es una cadena de Markov de primer orden.*

Proof. Para cualquier historial $y_{1:t}$ con probabilidad positiva, conocer $Y_t = y_t$ determina $X_t = f(y_t)$. La distribución de la siguiente observación es entonces

$$\begin{aligned} &P(Y_{t+1} = v \mid Y_t = y_t, \dots, Y_1 = y_1) \\ &\quad = \sum_{j\in\mathcal{S}} P(Y_{t+1} = v \mid X_{t+1} = j) P(X_{t+1} = j \mid X_t = f(y_t)) \\ &\quad = \sum_{j\in\mathcal{S}} b_j(v) a_{f(y_t)j}. \end{aligned}$$

El último término depende únicamente de y_t. Por tanto,

$$P(Y_{t+1} = v \mid Y_t = y_t, \dots, Y_1 = y_1) = P(Y_{t+1} = v \mid Y_t = y_t),$$

y el proceso observable es markoviano. □

La condición anterior es excepcional en la interpretación musical de la tesis. Una clase de altura aislada no suele identificar un único contexto armónico. Por eso el historial de observaciones puede aportar información sobre el estado latente incluso cuando la dinámica oculta es de primer orden Cappé, Moulines, and Rydén (2005).

Bibliografía

Beal, Matthew J., Zoubin Ghahramani, and Carl Edward Rasmussen. 2002. "The Infinite Hidden Markov Model." Paper presented at the Advances in Neural Information Processing Systems 14, Cambridge, MA.

Begleiter, Ron, Ran El-Yaniv, and Golan Yona. 2004. "On Prediction Using Variable Order Markov Models." *Journal of Artificial Intelligence Research* 22: 385–421.

Cappé, Olivier, Eric Moulines, and Tobias Rydén. 2005. *Inference in Hidden Markov Models*. New York: Springer.

Demšar, Janez. 2006. "Statistical Comparisons of Classifiers over Multiple Data Sets." *Journal of Machine Learning Research* 7: 1–30.

Efron, Bradley. 1979. "Bootstrap Methods: Another Look at the Jackknife." *The Annals of Statistics* 7(1): 1–26.

Ferguson, Thomas S. 1973. "A Bayesian Analysis of Some Nonparametric Problems." *The Annals of Statistics* 1(2): 209–230.

Fox, Emily B., Erik B. Sudderth, Michael I. Jordan, and Alan S. Willsky. 2011. "A Sticky HDP-HMM with Application to Speaker Diarization." *The Annals of Applied Statistics* 5(2A): 1020–1056.

Holm, Sture. 1979. "A Simple Sequentially Rejective Multiple Test Procedure." *Scandinavian Journal of Statistics* 6(2): 65–70.

Huang, Cheng-Zhi Anna, Ashish Vaswani, Jakob Uszkoreit, Noam Shazeer, Ian Simon, Curtis Hawthorne, Andrew M. Dai, Matthew D. Hoffman, Monica Dinculescu, and Douglas Eck. 2019. "Music Transformer: Generating Music with Long-Term Structure." Paper presented at the International Conference on Learning Representations (ICLR),.

Ishwaran, Hemant, and Lancelot F. James. 2001. "Gibbs Sampling Methods for Stick-Breaking Priors." *Journal of the American Statistical Association* 96(453): 161–173.

Long, Phillip, Zachary Novack, Taylor Berg-Kirkpatrick, and Julian McAuley. 2025. "PDMX: A Large-Scale Public Domain MusicXML Dataset for Symbolic Music Processing." Paper presented at the ICASSP 2025 – 2025 IEEE International Conference on Acoustics, Speech and Signal Processing,.

Miettinen, Kaisa. 1999. *Nonlinear Multiobjective Optimization*. Boston: Kluwer Academic Publishers.

Murphy, Kevin P. 2012. *Machine Learning: A Probabilistic Perspective*. Cambridge, MA: MIT Press.

Pearce, Marcus T., and Geraint A. Wiggins. 2012. "Auditory Expectation: The Information Dynamics of Music Perception and Cognition." *Topics in Cognitive Science* 4(4): 625–652.

Rabiner, Lawrence R. 1989. "A tutorial on hidden Markov models and selected applications in speech recognition." *Proceedings of the IEEE* 77(2): 257–286.

Ross, Sheldon M. 2014. *Introduction to Probability Models*. 10 ed. Amsterdam: Academic Press.

Sethuraman, Jayaram. 1994. "A Constructive Definition of Dirichlet Priors." *Statistica Sinica* 4(2): 639–650.

Sheh, Alexander, and Daniel P. W. Ellis. 2003. "Chord Segmentation and Recognition Using EM-Trained Hidden Markov Models." Paper presented at the Proceedings of the 4th International Conference on Music Information Retrieval,.

Teh, Yee Whye, Michael I. Jordan, Matthew J. Beal, and David M. Blei. 2006. "Hierarchical Dirichlet Processes." *Journal of the American Statistical Association* 101(476): 1566–1581.

Temperley, David. 2007. *Music and Probability*. Cambridge, MA: MIT Press.

Van Gael, Jurgen, Yunus Saatci, Yee Whye Teh, and Zoubin Ghahramani. 2008. "Beam Sampling for the Infinite Hidden Markov Model." Paper presented at the Proceedings of the 25th International Conference on Machine Learning,.

Vaswani, Ashish, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. 2017. "Attention Is All You Need." Paper presented at the Advances in Neural Information Processing Systems 30 (NeurIPS 2017),.

W3C Music Notation Community Group. 2021. MusicXML 4.0. Final community group report World Wide Web Consortium. Editado por Michael Good. https://www.w3.org/2021/06/musicxml40/

Wilcoxon, Frank. 1945. "Individual Comparisons by Ranking Methods." *Biometrics Bulletin* 1(6): 80–83.

Modelado probabilístico de melodías: cadenas de Markov ocultas y comparación predictiva , de Adrián Janus Gonzalez Adamuz, se preparó en Ciudad de México en 2026.