Instituto Tecnológico Autónomo de México



Modelado probabilístico de melodías: cadenas de Markov ocultas y comparación predictiva

TESIS

QUE PARA OBTENER EL TÍTULO DE

Licenciado en Matemáticas Aplicadas e Ingeniería en Computación

PRESENTA

Adrián Janus Gonzalez Adamuz

Asesora: Airam Blancas Serrat

Ciudad de México, México
Otoño, 2026

"Con fundamento en los artículos 21 y 27 de la Ley Federal de Derecho de Autor y como titular de los derechos moral y patrimonial de la obra titulada "*Modelado probabilístico de melodías: cadenas de Markov ocultas y comparación predictiva*", otorgo de manera gratuita y permanente al Instituto Tecnológico Autónomo de México y a la biblioteca Raúl Baillères Jr., autorización para que fijen la obra en cualquier medio, incluido el electrónico, y la divulguen entre sus usuarios, profesores, estudiantes o terceras personas, sin que pueda percibir por tal divulgación una prestación"

Adrián Janus Gonzalez Adamuz

Otoño, 2026



Abstract

This work compares probabilistic models for symbolic melodies represented as pitch-class sequences. Finite Markov chains provide the starting point. Hidden Markov models (HMMs) separate the observed notes from latent contexts, and the hierarchical Dirichlet process HMM (HDP-HMM) expands the potential state inventory. Computational experiments test these formulations and record the conditions needed to reproduce them.

The final experiment evaluates a finite HMM, a truncated HDP-HMM, a variable-order Markov model, and a causal transformer on the same task of predicting the next event. The data are split by canonical work, keeping arrangements of the same piece together. Of the 3,000 sampled PDMX files, 2,933 pieces remained after preprocessing.

At the full training fraction, the transformer obtained a test perplexity of 5.823. The primary-run values were 7.356 for the finite HMM, 7.968 for the HDP-HMM, and 8.022 for the variable-order model. Four audited sensitivity runs changed window overlap, finite-HMM capacity, and the data split one factor at a time. The transformer ranked first in every run. Removing window overlap reduced its margin, whereas the expanded grid improved the finite HMM to 6.984 without locating its optimum.

The transformer therefore had a predictive advantage at the corpus scale studied. A subsequent fixed-configuration benchmark with three repetitions showed that its fit was faster than either HMM and slower than the VOMM. Under the documented

pricing scenario, the GPU rate made its estimated cost higher than that of the CPU alternatives. The complete execution established the technological viability of the research prototype on the available equipment. Social viability was not tested with users. No reference annotations were available for phrases, sections, or harmonic functions; structural quality was not compared.

Resumen

El trabajo compara modelos probabilísticos para melodías simbólicas representadas como secuencias de clases de altura. El punto de partida son las cadenas de Markov finitas. Los modelos ocultos de Markov (HMM) separan las notas observables de los contextos latentes, y el HMM basado en el proceso de Dirichlet jerárquico (HDP-HMM) amplía el repertorio potencial de estados. Los experimentos computacionales contrastan estas formulaciones y documentan sus condiciones de reproducción.

El experimento final evalúa un HMM finito, un HDP-HMM truncado, un modelo de Markov de orden variable y un transformador causal en la misma tarea: predecir el siguiente evento. Las particiones se construyen por obra canónica, de modo que los arreglos de una misma pieza permanezcan juntos. De los 3000 archivos de PDMX muestreados, 2933 piezas quedaron después del preprocesamiento.

Con la fracción completa de entrenamiento, el transformador obtuvo una *perplexity* de prueba de 5.823. En la corrida principal, los valores correspondientes fueron 7.356 para el HMM finito, 7.968 para el HDP-HMM y 8.022 para el modelo de orden variable. Cuatro sensibilidades auditadas modificaron por separado el solapamiento de las ventanas, la capacidad del HMM finito y la partición de los datos. El transformador conservó la mejor predicción en todas. Al eliminar el solapamiento disminuyó su margen, mientras que la rejilla ampliada mejoró al HMM hasta 6.984 sin localizar su óptimo.

En la escala estudiada, el transformador mostró una ventaja predictiva. Una medi-

ción posterior, con configuraciones fijadas y tres repeticiones, mostró que su ajuste fue más breve que el de los HMM y más largo que el del VOMM. Bajo el escenario de tarifas documentado, la GPU elevó su costo estimado por encima de las alternativas de CPU. La ejecución de extremo a extremo verificó la viabilidad tecnológica del prototipo en el equipo utilizado. La viabilidad social no se evaluó con usuarios. Tampoco hubo anotaciones de referencia para frases, secciones o funciones armónicas, de modo que el experimento no compara la calidad estructural de los modelos.

Índice general

Abstract v

Resumen vi

Índice de figuras xv

Índice de cuadros xvii

1 Introducción y planteamiento del problema 1
1.1 Organización de la tesis 2

2 Preliminares 3
2.1 De la melodía a una secuencia 3
2.2 Dependencia local y cadenas de Markov 4
2.3 De la nota observable al contexto latente 6

3 Cadenas de Markov ocultas y modelado computacional . . 7
3.1 Dos procesos y una misma secuencia 7
3.2 Tres problemas computacionales 9
3.2.1 Evaluación mediante el algoritmo hacia adelante 10
3.2.2 Decodificación mediante Viterbi 11
3.2.3 Aprendizaje mediante Baum-Welch 13
3.3 Una comprobación manual sobre el Preludio en Do mayor 13
3.4 El límite del número fijo de estados 18

4 Cadenas de Markov ocultas infinitas 19
4.1 Del número fijo a una colección abierta de estados 20
4.2 Del modelo infinito a un cálculo finito 24
4.3 Comprobación preliminar en una obra de referencia 25
4.4 Comprobación preliminar en el subconjunto clásico 26
4.5 Extensión preliminar a dos corpus 31

5 Diseño de la solución y metodología experimental 36
5.1 Proceso de diseño de la solución 36
5.2 De la partitura a una comparación común 37
5.3 Condiciones y límites del experimento 38
5.4 Alternativas consideradas y arquitectura de la comparación 42
5.5 Una tarea común para modelos diferentes 45
5.6 Construcción del protocolo comparativo 47

6 Resultados y evaluación de la solución 51
6.1 Qué cambia cuando aumenta el corpus 53
6.2 Comparación obra por obra 55
6.3 Sensibilidad de la comparación 56
6.4 El costo de la mejora predictiva 60
6.5 Viabilidad de la solución y responsabilidad profesional 63
6.6 Lo que la predicción todavía no responde 64

7 Conclusiones 66
7.1 Respuesta a la pregunta de investigación 66
7.2 Balance entre mejora, complejidad y viabilidad 67
7.3 Alcance y propuestas de continuación 69

Apéndice A De la distribución de Dirichlet al proceso jerárquico 71
A.1 Sobre el proceso de Dirichlet y los modelos jerárquicos 71

Apéndice B Propiedades del proceso observable en un HMM . 75
B.1 Las observaciones pueden conservar memoria 75
B.2 El proceso conjunto sí es markoviano 76

B.3 Un caso límite 76

Bibliografía **80**

Índice de figuras

2.1 Representación esquemática de una octava en el teclado del piano. Las teclas negras completan las doce clases de altura, aunque sólo se rotulan aquí las notas naturales. 4

3.1 Dependencias básicas de un HMM. Las flechas horizontales representan transiciones entre estados ocultos y las verticales, la distribución de cada observación condicionada por su estado. 9
3.2 Matriz obtenida de la trayectoria inferida para el Preludio en Do mayor. El marco discontinuo identifica el renglón de `E min`, para el cual no se registraron transiciones inferidas. Las celdas sin cifra representan valores registrados como cero. 15
3.3 Matriz construida mediante etiquetado y conteo manual de la partitura del Preludio en Do mayor. Las celdas sin cifra representan valores registrados como cero. 16
3.4 Diferencia absoluta registrada entre la matriz inferida y la referencia manual. Las celdas sin cifra representan diferencias registradas como cero. 17

4.1 Diferencia entre el iHMM ideal y su aproximación truncada. Los círculos superiores representan estados disponibles; la trayectoria inferior utiliza sólo una parte. En el panel derecho, el trazo discontinuo señala un estado disponible que puede quedar sin ocupar. . 23

4.2 Ajuste probabilístico en el subconjunto clásico. Los paneles presentan los mismos seis casos por obra y de manera agregada. 29
4.3 Ganancia de log-verosimilitud y ocupación latente en el subconjunto clásico. El panel superior muestra la diferencia de ajuste y el inferior el número de estados ocupados. 30
4.4 Log-verosimilitud por obra y distribución agregada en el corpus extendido. Las comparaciones se limitan a los 167 casos válidos para ambos modelos. 33
4.5 Mayores ganancias de log-verosimilitud y ocupación latente en el corpus extendido. El panel superior muestra una selección de quince obras; el inferior incluye los casos para los que se dispone de ambos conteos. 34

5.1 Proceso iterativo de diseño de la solución. La verificación contrasta los requisitos con la implementación y la validación examina la evidencia experimental. El retorno corresponde a revisiones posteriores a la corrida principal. 37
5.2 Recorrido computacional desde la partitura hasta la evaluación. La representación y las particiones se fijan antes del ajuste para que los cuatro modelos resuelvan la misma tarea. 38

6.1 Dos maneras de utilizar el contexto observable. El VOMM conserva conteos para contextos de diferentes longitudes y combina su evidencia; cuando los contextos largos aparecen pocas veces, se apoya más en los cortos. El transformador combina representaciones de las posiciones anteriores mediante atención causal. Ambos producen una distribución para la nota siguiente, pero sus mecanismos internos no son equivalentes. 52
6.2 Dos preguntas distintas sobre una misma secuencia musical. La predicción pudo compararse entre las cuatro familias; la descripción estructural requiere todavía anotaciones de referencia y salidas comparables de los modelos. 53

6.3 Curva de aprendizaje de la corrida principal. El transformador presenta la mayor reducción de *perplexity* al pasar del 10% al 100% de los datos; los otros modelos también mejoran, pero menos dentro de sus configuraciones evaluadas. Las barras muestran la desviación estándar de seis ajustes, salvo el VOMM determinista, con tres. En la fracción completa, las tres semillas de incorporación utilizan el mismo conjunto y no constituyen réplicas independientes. 54

6.4 Efecto de la unidad de análisis en la comparación entre HDP-HMM y VOMM. El panel A agrupa las 414 obras por longitud; los intervalos *bootstrap* de los cuartiles primero y cuarto incluyen el cero. El panel B contrasta la media por obra con la media ponderada por eventos. 56

6.5 Diagnóstico de capacidad del HMM finito en la fracción completa y con una semilla. El panel izquierdo utiliza *perplexity* de validación y muestra que la selección continuó tocando el mayor K disponible. El panel derecho registra el tiempo de ajustes individuales; la guía discontinua sirve sólo como referencia cuadrática. Este diagnóstico identifica un límite de cómputo, pero no localiza el óptimo de la familia. 58

6.6 Sensibilidad de la *perplexity* en la fracción completa. Los paneles A y B modifican por separado la exposición del transformador y la rejilla del HMM finito; el panel C muestra la variación entre tres particiones de la misma muestra. El segmento de ± 0.047 sirve como referencia de la mayor desviación estándar observada entre semillas, no como intervalo de incertidumbre común a todos los modelos. . 59

6.7 Comparaciones pareadas por obra en la corrida principal y las cuatro sensibilidades. La diferencia se define como NLL del modelo A menos NLL del modelo B; el lado del cero indica cuál queda favorecido. El punto y el intervalo estrecho corresponden a la corrida principal, y la banda clara abarca los intervalos obtenidos en las sensibilidades. 59

6.8 Proyección de calidad predictiva y costo observado en la corrida principal. Menor es mejor en ambos ejes. El VOMM es el más rápido y el transformador obtiene la menor NLL; este último domina a los dos HMM en esta proyección. La comparación mezcla GPU para el transformador y CPU para los modelos clásicos. . . . 61

Índice de cuadros

4.1 Comparación entre el HMM finito y el HDP-HMM truncado en la obra de referencia: el tercer movimiento de la Sonata núm. 14 de Beethoven. 26

4.2 Subconjunto clásico limitado utilizado para la comparación documentada entre el HMM finito y el HDP-HMM truncado. 27

4.3 Resumen agregado de la comparación entre el HMM finito y el HDP-HMM truncado sobre el subconjunto clásico limitado. . . . 27

4.4 Comparación por obra en las seis piezas del subconjunto clásico. La ganancia se calcula como la diferencia HDP-HMM truncado − HMM finito. 27

4.5 Composición del corpus extendido utilizado en la comparación multicorpus. 31

4.6 Resumen agregado de la comparación entre el HMM finito y el HDP-HMM truncado sobre el corpus extendido. La mejora se calcula como HDP-HMM truncado − HMM finito. 31

4.7 Ejemplos de resultados por obra en el corpus extendido. Se incluyen cuatro piezas de `MuseTrainer` y cuatro de `SymbTr` con distintas longitudes. 32

5.1 Trazabilidad entre los requisitos del sistema, las decisiones de diseño y la evidencia de verificación. 41

5.2 Síntesis de los antecedentes que sustentan las alternativas consideradas. El límite indicado corresponde a la comparación de esta tesis, no a una valoración general de cada familia. 43
5.3 Matriz cualitativa de las alternativas de diseño. La decisión final depende del propósito de uso y de los resultados del protocolo común; no se asignaron pesos retrospectivos. 44
5.4 Lectura de las métricas utilizadas en la comparación. Las medidas de predicción determinan qué modelo asigna más probabilidad a las notas de prueba; las de costo se interpretan por separado. . . . 46
5.5 Protocolo ejecutado para la comparación predictiva 48

6.1 *Perplexity* media de prueba por fracción de entrenamiento. Menor es mejor; la última columna compara cada modelo consigo mismo entre los extremos de la curva. 54
6.2 Comparaciones pareadas de NLL por obra en la fracción completa. Los intervalos *bootstrap* marginales corresponden a la diferencia media; los valores *p* de Wilcoxon se ajustaron conjuntamente mediante Holm. 55
6.3 Costo medio observado en la fracción completa. La selección y el ajuste abarcan presupuestos distintos entre familias y se midieron en dispositivos diferentes; no constituyen una comparación neutral del hardware ni del ajuste final aislado. 60
6.4 Medición de recursos con configuraciones fijadas. Los tiempos muestran mediana [mínimo, máximo] de tres repeticiones. El primer costo incluye un ajuste; el segundo, el ajuste y cien evaluaciones. Los costos proceden de las medias de tiempo y de las tarifas documentadas en el escenario. 62

Capítulo 1
Introducción y planteamiento del problema

Una obra musical puede describirse con modelos de complejidad muy distinta. En una cadena de Markov o un HMM pequeño, las transiciones y los estados pueden examinarse de manera explícita, a costa de restringir el contexto representado. Un modelo con mayor capacidad puede predecir mejor, pero también exige más decisiones de diseño, recursos de cómputo y cautela al interpretar sus mecanismos. La pregunta es si esa complejidad adicional produce una mejora que justifique su costo.

La pregunta central es la siguiente: bajo los mismos datos observables, particiones por obra y criterios de evaluación, ¿la mayor complejidad de un HDP-HMM o de un transformador aporta una mejora sustancial frente a modelos más sencillos? La respuesta considera el desempeño predictivo, el costo computacional, la interpretabilidad y las condiciones de reproducción. El problema tiene dos componentes: predecir el siguiente evento musical y describir contextos latentes dentro de una obra. Ambos se analizan por separado.

El objetivo general es diseñar, implementar y validar un sistema reproducible para comparar cuatro familias: HMM finito, HDP-HMM truncado, VOMM y transformador causal. Los cuatro modelos comparten la representación, las particiones por obra y los eventos puntuados. El protocolo también registra el tiempo, el dispositivo y la complejidad de cada ejecución.

El sistema integra la preparación de datos, el ajuste, la auditoría y la evaluación. Su

ejecución completa aporta la base para estudiar la viabilidad tecnológica; los tiempos medidos sustentan una estimación económica paramétrica. La dimensión social se delimita, pues no se realizó una evaluación con usuarios.

La obra constituye la unidad de inferencia para el contraste predictivo. Los componentes internos de las cuatro familias no se equiparan: las interpretaciones musicales de estados o patrones requieren anotaciones externas.

El alcance se restringe a secuencias de clases de altura extraídas de una muestra de PDMX y a las configuraciones y recursos utilizados. La validación final cubre la predicción del siguiente evento. La correspondencia entre estados y estructura musical quedó sin evaluar por falta de anotaciones de referencia y de salidas comparables para los cuatro modelos.

1.1 Organización de la tesis

Los capítulos 2–4 desarrollan la representación secuencial, los HMM y la ampliación del espacio de estados. El Capítulo 5 documenta el diseño del sistema y el protocolo común; el Capítulo 6 reúne los resultados, las sensibilidades y la evaluación de viabilidad. El Capítulo 7 responde la pregunta de investigación.

Capítulo 2
Preliminares

Una melodía se percibe como una sucesión organizada, no como una colección de notas independientes. Después de escuchar varios eventos se forman expectativas sobre lo que puede ocurrir a continuación, aunque esas expectativas no determinen una única continuación posible. De esta combinación de regularidad e incertidumbre surge una primera pregunta matemática: ¿qué parte de la continuidad melódica puede describirse mediante probabilidades de transición? La relación entre expectativa musical y aprendizaje estadístico ha sido estudiada tanto desde la teoría musical como desde la cognición de la música Temperley (2007); Pearce and Wiggins (2012).

Antes de asignar probabilidades hay que decidir qué cuenta como un evento. Una partitura contiene alturas, duraciones, voces, compases y otros signos, mientras que una cadena de Markov opera sobre una sucesión de símbolos. Reducir la primera a la segunda obliga a precisar qué se observa y qué significa avanzar un paso. Una vez fijada esa secuencia, puede formularse la dependencia markoviana y observarse por qué será necesario introducir estados ocultos.

2.1 De la melodía a una secuencia

La representación parte de partituras simbólicas. Cada nota seleccionada por el preprocesamiento cuenta como un evento y el índice n indica su lugar en la secuencia. Avanzar de n a $n+1$ no supone que entre ambos eventos transcurra siempre la misma duración física. La comparación experimental del Capítulo 6 utiliza la misma repre-

sentación para predecir la siguiente clase de altura. Quedan fuera la duración, el registro, la dinámica y parte de la organización métrica.

La altura puede conservarse con distinto grado de detalle. Una nota con registro, como C_4, distingue la octava; una clase de altura agrupa notas equivalentes módulo octava y las representa con un mismo símbolo, como C. Para la comparación común se utilizan las doce clases de altura del sistema cromático occidental. La Figura 2.1 muestra ese alfabeto dentro de una octava del teclado.

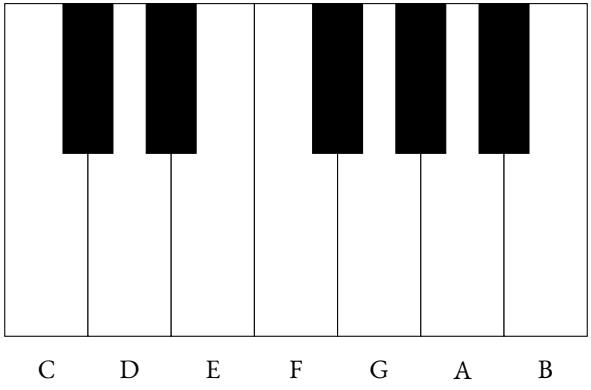


Figura 2.1: *Representación esquemática de una octava en el teclado del piano. Las teclas negras completan las doce clases de altura, aunque sólo se rotulan aquí las notas naturales.*

Sea S el alfabeto finito elegido. Una melodía queda representada como una sucesión

$$(X_n)_{n\geq 1}, \qquad X_n \in S,$$

donde X_n es la clase de altura observada en la posición n. Tratar X_n como variable aleatoria no implica que la melodía carezca de organización musical. La distribución de probabilidad sólo expresa qué continuaciones admite el modelo y qué peso asigna a cada una.

2.2 Dependencia local y cadenas de Markov

El modelo más simple asignaría a cada posición la misma distribución, con independencia de las notas anteriores. Esa hipótesis no representa la continuidad local que motivó la secuencia. En el extremo opuesto, condicionar cada nota a toda la historia previa produce un número de contextos que crece rápidamente y resulta difícil de

estimar con datos limitados. La cadena de Markov de primer orden adopta una posición intermedia: conserva la nota presente y descarta el resto del pasado al calcular la siguiente transición.

Definición 2.1. *Sea* $(\Omega, \mathcal{F}, \mathbb{P})$ *un espacio de probabilidad. Una sucesión de variables aleatorias* $(X_n)_{n\geq 1}$ *con valores en un conjunto finito* S *es una* cadena de Markov *si, para todo* $n \geq 1$ *y para cualesquiera* $i_1, \ldots, i_n, j \in S$ *con probabilidad condicionante positiva,*

$$P(X_{n+1} = j \mid X_n = i_n, \ldots, X_1 = i_1) = P(X_{n+1} = j \mid X_n = i_n).$$

En el modelo melódico de primer orden, esta igualdad significa que la nota actual resume el contexto utilizado para predecir la siguiente. La música puede contener motivos, frases y dependencias a mayor distancia, pero la cadena no los representa de forma directa. Se trata de una simplificación deliberada cuyo efecto puede evaluarse al compararla con modelos que conservan más contexto.

Si la cadena es homogénea, la probabilidad de pasar de i a j no depende de n y se denota por

$$P_{ij} = P(X_{n+1} = j \mid X_n = i).$$

Estas probabilidades satisfacen

$$P_{ij} \geq 0, \qquad \sum_{j \in S} P_{ij} = 1.$$

La matriz $\mathbf{P} = (P_{ij})_{i,j\in S}$ se denomina *matriz de transición* Ross (2014). Cada renglón responde una pregunta concreta: dada la nota representada por i, ¿cómo distribuye el modelo la probabilidad entre las notas que pueden seguirla?

Cuando se observa una secuencia y no se impone regularización, una estimación elemental cuenta cuántas veces aparece cada par consecutivo (i, j) y divide por el número de transiciones que parten de i. Este cociente es el estimador de máxima verosimilitud de P_{ij}. Si un par no aparece, su estimación es cero; con corpus pequeños, esa ausencia puede reflejar falta de datos y no imposibilidad musical. Los mecanismos probabilísticos de los capítulos posteriores buscan precisamente que la

estimación no dependa sólo de cada conteo aislado.

La matriz también describe el comportamiento agregado de la cadena. Un vector de probabilidad π es estacionario si

$$\pi = \pi \mathbf{P}.$$

En una cadena finita, irreducible y aperiódica, existe una única distribución estacionaria y

$$\lim_{n \to \infty} P(X_n = j \mid X_1 = i) = \pi_j.$$

Bajo esas condiciones, π_j describe la probabilidad a largo plazo del símbolo j dentro del modelo. Esta propiedad de la cadena estimada no identifica por sí sola tonalidad, función armónica o estilo.

2.3 De la nota observable al contexto latente

En la cadena descrita hasta ahora, cada nota es a la vez observación y estado. El modelo describe qué notas suelen sucederse, pero carece de una variable para un contexto que permanezca mientras cambian las observaciones. Una misma nota puede aparecer en regiones armónicas distintas y un mismo acorde puede admitir varias notas. La nota actual, por tanto, no determina de manera unívoca la organización que se desea estudiar Temperley (2007).

Para conservar ese contexto se separan los dos niveles. La nota pasa a ser la observación y una segunda variable representa el contexto latente que evoluciona en el tiempo. El contexto inferido puede estudiarse para determinar si corresponde a una región armónica o estructural, aunque el modelo no le asigna automáticamente una etiqueta musical. El Capítulo 3 formaliza esta idea mediante una cadena de Markov oculta y presenta los algoritmos para evaluar, aprender y decodificar el modelo.

Capítulo 3

Cadenas de Markov ocultas y modelado computacional

En la cadena de Markov del capítulo anterior, el estado era la nota observada. Así podían describirse transiciones locales, pero dos apariciones de la misma nota recibían necesariamente el mismo tratamiento. Esta identificación resulta restrictiva porque una clase de altura puede cumplir funciones distintas según la región tonal o armónica en la que aparece.

Una cadena de Markov oculta, o HMM por sus siglas en inglés, separa la nota de ese contexto. Las notas forman la secuencia observable y una segunda cadena representa un contexto que cambia a lo largo del tiempo. El contexto actual determina tanto la distribución de las notas observables como la del contexto siguiente. A partir de esta dependencia se pueden evaluar secuencias, reconstruir trayectorias latentes y aprender los parámetros del modelo Rabiner (1989); Cappé, Moulines, and Rydén (2005).

3.1 Dos procesos y una misma secuencia

Definición 3.1. *Sea* $(\Omega, \mathcal{F}, \mathbb{P})$ *un espacio de probabilidad. Una* cadena de Markov oculta *está formada por dos procesos estocásticos en tiempo discreto,*

$$(X_t)_{t\geq 1}, \qquad (Y_t)_{t\geq 1},$$

donde X_t toma valores en un espacio finito de estados ocultos

$$\mathcal{S} = \{1, \dots, N\},$$

y Y_t toma valores en un espacio discreto de observaciones

$$\mathcal{V} = \{v_1, \dots, v_M\}.$$

El proceso (X_t) satisface la propiedad de Markov y, condicionado en X_t, el valor de Y_t es independiente de los demás estados y observaciones. El modelo se especifica mediante

$$\pi_i = P(X_1 = i), \qquad a_{ij} = P(X_t = j \mid X_{t-1} = i), \quad t \geq 2, \qquad b_j(v) = P(Y_t = v \mid X_t = j), \quad t \geq 1.$$

Estas probabilidades se reúnen en

$$\lambda = (\pi, \mathbf{A}, \mathbf{B}).$$

El vector π describe el estado inicial. El renglón i de $\mathbf{A}$ distribuye la probabilidad del siguiente estado cuando el actual es i, mientras que el renglón j de $\mathbf{B}$ hace lo mismo con las observaciones que puede emitir el estado j. En cada caso las probabilidades suman uno:

$$\sum_{i=1}^{N} \pi_i = 1, \qquad \sum_{j=1}^{N} a_{ij} = 1, \qquad \sum_{v \in \mathcal{V}} b_j(v) = 1.$$

La Figura 3.1 traduce la definición a un esquema. La cadena superior describe la sucesión de contextos ocultos; cada uno de ellos genera la nota situada debajo. Las notas se observan de manera directa, mientras que la trayectoria que las relaciona debe inferirse.

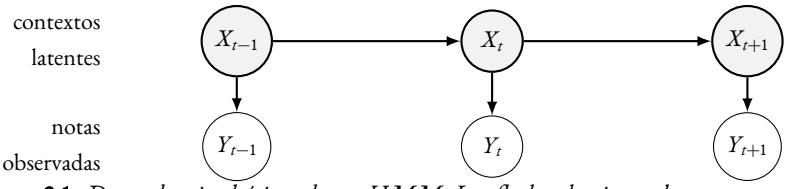


Figura 3.1: *Dependencias básicas de un HMM. Las flechas horizontales representan transiciones entre estados ocultos y las verticales, la distribución de cada observación condicionada por su estado.*

En la aplicación musical, Y_t es la clase de altura registrada y X_t es un contexto latente. Los HMM se han utilizado para segmentar música y reconocer acordes Sheh and Ellis (2003), por lo que cabe examinar si cada estado representa una región armónica, un acorde o una función. El ajuste no supervisado no proporciona esa interpretación. Los estados siguen siendo etiquetas estadísticas y su lectura musical requiere estudiar sus emisiones, sus transiciones y, cuando se dispone de ellas, anotaciones externas.

La distribución conjunta de una trayectoria $x_{1:T}$ y una secuencia observada $y_{1:T}$ se factoriza como

$$P(X_{1:T} = x_{1:T}, Y_{1:T} = y_{1:T} \mid \lambda) = \pi_{x_1} b_{x_1}(y_1) \prod_{t=2}^{T} a_{x_{t-1}x_t} b_{x_t}(y_t).$$

La expresión sigue el orden en que se genera la secuencia. Primero se elige el estado inicial y su observación; después, cada paso combina una transición latente con una nueva emisión. Gracias a esta factorización, los algoritmos de programación dinámica pueden agrupar cálculos que de otro modo se repetirían para cada trayectoria.

Aunque (X_t) sea una cadena de Markov, (Y_t) no tiene por qué satisfacer la misma propiedad. Las notas anteriores informan sobre el estado oculto actual y, por esa vía, cambian la distribución de la nota siguiente. En cambio, el par (X_t, Y_t) sí forma una cadena de Markov en el espacio producto. El Apéndice B demuestra ambos resultados y estudia el caso límite en el que la observación determina el estado oculto.

3.2 Tres problemas computacionales

El uso de un HMM plantea tres problemas distintos Rabiner (1989). Si los parámetros son conocidos, la *evaluación* calcula la probabilidad de una secuencia y la *decodifi-*

cación reconstruye una trayectoria latente compatible con ella. Cuando los parámetros también son desconocidos, el *aprendizaje* los estima a partir de las observaciones. En los experimentos, la log-verosimilitud compara ajustes, Viterbi produce trayectorias inspeccionables y Baum-Welch ajusta el HMM finito de la comparación final.

3.2.1 Evaluación mediante el algoritmo hacia adelante

Para un modelo λ y una secuencia $y_{1:T}$, la evaluación calcula

$$P(y_{1:T} \mid \lambda).$$

Una suma directa tendría una contribución por cada una de las N^T trayectorias ocultas. El algoritmo hacia adelante evita enumerarlas al reunir todas las trayectorias que terminan en un mismo estado. Para ello se define

$$\alpha_t(j) = P(Y_{1:t} = y_{1:t}, X_t = j \mid \lambda).$$

La cantidad $\alpha_t(j)$ acumula el peso de todas las explicaciones latentes que llegan al estado j después de observar los primeros t símbolos. No es la probabilidad posterior de ese estado, pues también contiene la probabilidad conjunta de las observaciones parciales.

La inicialización y la recurrencia son

$$\alpha_1(j) = \pi_j b_j(y_1),$$

$$\alpha_{t+1}(j) = b_j(y_{t+1}) \sum_{i=1}^{N} \alpha_t(i) a_{ij}.$$

Al finalizar,

$$P(y_{1:T} \mid \lambda) = \sum_{j=1}^{N} \alpha_T(j).$$

El costo es $O(TN^2)$. En secuencias largas, el producto de probabilidades pequeñas puede producir subdesbordamiento numérico. Para evitarlo, las implementaciones suelen reescalar las variables o trabajar en dominio logarítmico Rabiner (1989); Cappé, Moulines, and Rydén (2005).

3.2.2 Decodificación mediante Viterbi

La evaluación suma el peso de todas las trayectorias. La decodificación busca, en cambio, la que maximiza la probabilidad conjunta con las observaciones. Como $P(y_{1:T} \mid \lambda)$ es constante respecto de la trayectoria, este criterio también maximiza la probabilidad posterior de la trayectoria completa.

El algoritmo de Viterbi conserva, para cada estado final, sólo el mejor camino parcial. Se define

$$\delta_t(j) = \max_{x_{1:t-1}} P(X_{1:t-1} = x_{1:t-1}, X_t = j, Y_{1:t} = y_{1:t} \mid \lambda),$$

con

$$\delta_1(j) = \pi_j b_j(y_1)$$

y

$$\delta_t(j) = b_j(y_t) \max_{i \in \mathcal{S}} \delta_{t-1}(i) a_{ij}.$$

Además del valor máximo se guarda el estado que lo alcanza, lo que permite reconstruir la trayectoria mediante un recorrido hacia atrás.

Algorithm 1 Algoritmo de Viterbi

Require: Observaciones $O = (o_1, \ldots, o_T)$, estados $\mathcal{S} = \{1, \ldots, N\}$ y parámetros (π, A, B)

Ensure: Trayectoria más probable $X^* = (x_1^*, \ldots, x_T^*)$

Inicialización
for $j = 1$ **to** N **do**
    $\delta_1(j) \leftarrow \pi_j b_j(o_1)$
    $\psi_1(j) \leftarrow 0$
end for

Recursión
for $t = 2$ **to** T **do**
    for $j = 1$ **to** N **do**
        $\delta_t(j) \leftarrow \max_{1 \le i \le N} \left[\delta_{t-1}(i) a_{ij}\right] b_j(o_t)$
        $\psi_t(j) \leftarrow \arg\max_{1 \le i \le N} \left[\delta_{t-1}(i) a_{ij}\right]$
    end for
end for

Terminación y retroceso
$x_T^* \leftarrow \arg\max_{1 \le j \le N} \delta_T(j)$
for $t = T-1, T-2, \ldots, 1$ **do**
    $x_t^* \leftarrow \psi_{t+1}(x_{t+1}^*)$
end for
return X^*

Viterbi produce la trayectoria óptima según el modelo, pero ésta no es una verdad musical observada. Otras trayectorias pueden tener una probabilidad cercana y la identidad numérica de un estado no contiene una etiqueta armónica. En los capítulos experimentales, la decodificación se utiliza para contar estados ocupados y visualizar transiciones. Una interpretación estructural más fuerte requiere una referencia externa.

3.2.3 Aprendizaje mediante Baum-Welch

En una aplicación musical se conocen las notas, pero no la trayectoria que las generó. El aprendizaje debe entonces estimar λ a partir de una o varias secuencias observadas. Si los estados también se observaran, los parámetros podrían obtenerse contando inicios, transiciones y emisiones. Baum-Welch sustituye esos conteos desconocidos por sus valores esperados bajo los parámetros actuales y luego los normaliza; este procedimiento es una instancia del esquema de esperanza-maximización Rabiner (1989).

En la iteración r, el paso de esperanza calcula probabilidades posteriores de estados y transiciones mediante los recorridos hacia adelante y hacia atrás. El paso de maximización elige parámetros que maximizan la esperanza de la log-verosimilitud completa,

$$\lambda^{(r+1)} = \arg\max_{\lambda} \mathbb{E}_{X|Y,\lambda^{(r)}} \left[\log P(X, Y \mid \lambda)\right].$$

La log-verosimilitud observada no disminuye de una iteración a la siguiente. Esto no garantiza un máximo global y el resultado puede depender de la inicialización, de ahí que la comparación experimental utilice varias semillas y un conjunto de validación.

Baum-Welch estima probabilidades para un número N de estados fijado de antemano, pero no indica cuál debe ser ese número. Aumentar N amplía la capacidad del modelo y también cambia el costo, la estabilidad del ajuste y la forma en que se reutilizan los estados. El ejercicio siguiente examina una trayectoria obtenida con un vocabulario ya fijado.

3.3 Una comprobación manual sobre el Preludio en Do mayor

Sobre el *Preludio en Do mayor*, BWV 846, de J. S. Bach, se contrastó una trayectoria inferida con una lectura directa de la partitura. Primero se identificó manualmente una sucesión armónica. Después se contaron sus transiciones entre acordes y se normalizó cada renglón para obtener una matriz de probabilidades. Esta referencia depende de cómo se asignaron los acordes y no constituye una lectura única de la obra.

El HMM utilizó una distribución inicial uniforme y una matriz de transición a priori que favorece la permanencia. Para N estados se fijó

$$A_{ii} = \frac{\alpha}{\alpha + (N-1)\beta}, \qquad A_{ij} = \frac{\beta}{\alpha + (N-1)\beta}, \quad i \neq j, \tag{3.1}$$

con $\alpha = 210$, $\beta = 1$ y $\pi_i = 1/N$. Los materiales conservados no coinciden por completo: el registro textual indica $N = 24$, pero las imágenes muestran diez etiquetas armónicas. Como falta la hoja intermedia de conteos, no se sabe si el vocabulario se restringió o si sólo se eligieron diez etiquetas para la figura. El contraste se limita a esas etiquetas visibles.

Tras aplicar la decodificación de Viterbi, se contaron las transiciones de la trayectoria inferida y se aplicó la misma normalización. Las Figuras 3.2 y 3.3 muestran las matrices por separado para que las celdas puedan leerse. Ambas reproducen los valores de las imágenes originales, sin sustituir el conteo manual ni atribuirles más precisión que la registrada.

En ambas matrices predominan los valores de la diagonal: una vez asignado un acorde, la siguiente posición suele conservar la misma etiqueta. También coinciden varias transiciones fuera de la diagonal. La diferencia más visible está en `E min`. La referencia manual le asigna probabilidad 0.92 de permanencia y 0.08 de transición a `F Maj`, pero la trayectoria inferida no visita ese estado. Por eso el renglón correspondiente queda sin conteos, aunque el estado forme parte del vocabulario.

La Figura 3.4 reproduce la matriz de diferencias absolutas del ejercicio. Sus valores se transcribieron de la imagen histórica y no se calcularon de nuevo: las otras dos figuras están redondeadas y no contienen todas las diferencias de la hoja de cálculo original.

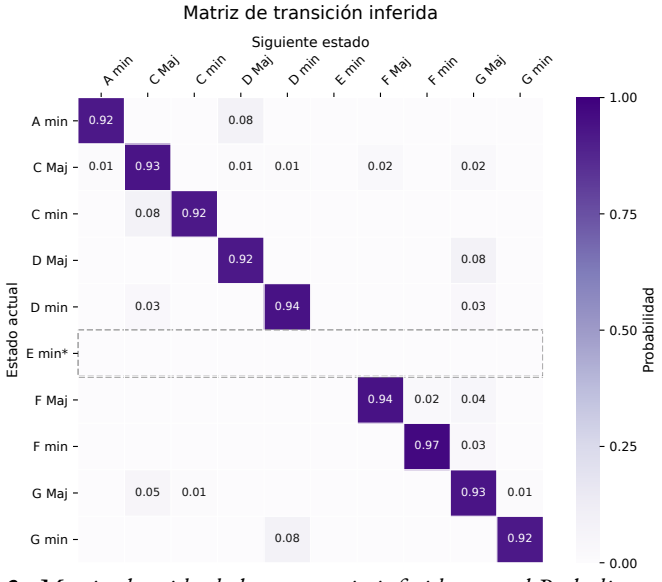


Figura 3.2: *Matriz obtenida de la trayectoria inferida para el Preludio en Do mayor. El marco discontinuo identifica el renglón de* `E min`*, para el cual no se registraron transiciones inferidas. Las celdas sin cifra representan valores registrados como cero.*

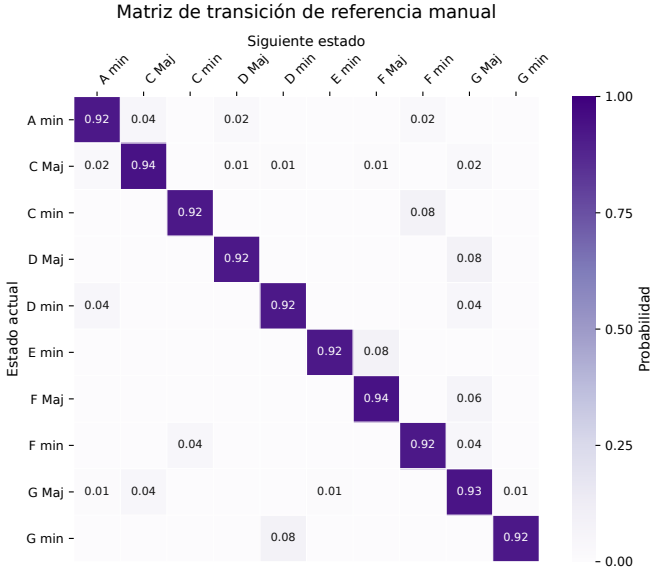


Figura 3.3: *Matriz construida mediante etiquetado y conteo manual de la partitura del Preludio en Do mayor. Las celdas sin cifra representan valores registrados como cero.*

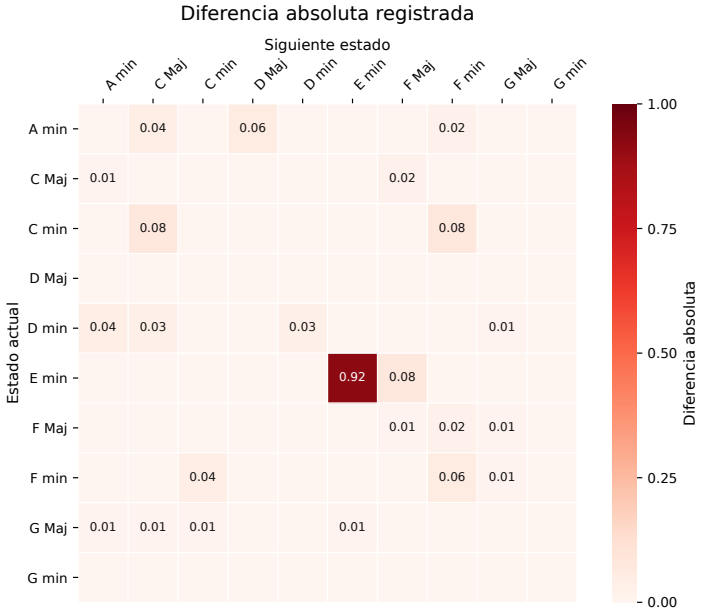


Figura 3.4: *Diferencia absoluta registrada entre la matriz inferida y la referencia manual. Las celdas sin cifra representan diferencias registradas como cero.*

El conteo manual encontró 30 cambios de acorde en la referencia y 27 en la trayectoria inferida. De estos últimos, 22 coincidieron. La razón $27/30 = 0.90$ compara cantidades de cambios, no una tasa de detección, pues cinco cambios inferidos no coincidieron. La razón $22/27 \approx 0.815$ sí expresa la proporción de coincidencias entre los cambios inferidos. En el ejercicio no participó un segundo anotador y tampoco se conserva una regla de tolerancia para coincidencias cercanas.

El HMM recupera algunas regularidades de la organización armónica propuesta y omite uno de sus estados. Al provenir de una sola obra y una sola anotación, las proporciones no pueden generalizarse ni el desacuerdo atribuirse al número de estados. El ejercicio muestra, en cambio, que el vocabulario latente tuvo que fijarse antes del ajuste.

3.4 El límite del número fijo de estados

El HMM finito separa la observación del contexto latente, pero antes de ajustarlo se debe elegir

$$\mathcal{S} = \{1, \ldots, N\}.$$

Si N es pequeño, comportamientos distintos pueden quedar reunidos en un mismo estado. Si es grande, una regularidad puede repartirse entre estados redundantes. La selección por validación compara varios valores dentro de una rejilla finita cuyo límite se decide por anticipado.

El modelo del Capítulo 4 conserva la relación entre estados y observaciones y sustituye el vocabulario fijo por una colección abierta de estados potenciales. La inferencia ocupa una parte de esa colección. Esta formulación conduce al proceso de Dirichlet jerárquico y, en el cálculo, a una aproximación truncada.

Capítulo 4
Cadenas de Markov ocultas infinitas

El capítulo anterior introdujo una cadena de Markov oculta con N estados. Las notas forman la secuencia observable y los estados representan contextos musicales que no aparecen escritos de manera directa en la partitura. Una vez fijado N, pueden estimarse transiciones, emisiones y trayectorias latentes. Falta, sin embargo, tomar una decisión previa: ¿cuántos contextos deben permitirse?

La respuesta no es evidente incluso en un ejemplo sencillo. Con pocos estados, el modelo puede reunir bajo una misma etiqueta regiones musicales que se comportan de manera distinta; con demasiados, una regularidad que debería repetirse puede quedar repartida entre estados casi redundantes. El número de estados determina así el nivel de resolución con el que se describe la obra.

La separación entre proceso latente y observación sigue siendo útil, aunque N deje de tratarse como una cantidad conocida. El modelo puede disponer de muchos estados potenciales y ocupar sólo los que necesita la secuencia. Un vocabulario finito de acordes muestra primero por qué ambas cantidades no tienen que coincidir.

Supóngase, como ejemplo conceptual, que cada estado oculto debe corresponder a un acorde. El HMM clásico exige fijar primero un conjunto finito S de acordes permitidos y después identificar el espacio de estados ocultos con

$$\mathcal{S} = \{1, 2, \ldots, N\}, \qquad N = |S|.$$

La elección de S determina la dimensión de la distribución inicial π, de la matriz de transición $\mathbf{A}$ y de la familia de emisiones $\mathbf{B}$. Una manera de construir ese vocabulario consiste en usar pares de la forma

$$(\text{fundamental, plantilla armónica}).$$

El primer componente indica la fundamental y el segundo la cualidad armónica.

Sea

$$\mathcal{R} = \{C, C^\sharp, D, E^\flat, E, F, F^\sharp, G, A^\flat, A, B^\flat, B\}$$

el conjunto de clases de altura fundamentales. Sea además

$$\mathcal{Q} = \left\{ \begin{array}{l} \text{Maj, min, dim, aug,} \\ \text{Maj7, 7, m7, m(Maj7), } \varnothing 7, \text{dim7,} \\ \text{6, m6, add9, madd9, 6/9,} \\ \text{sus2, sus4, 7sus4,} \\ \text{Maj9, 9, m9} \end{array} \right\}$$

una familia de plantillas que distingue triadas, séptimas, suspensiones y extensiones.

Se define entonces

$$S = \mathcal{R} \times \mathcal{Q}.$$

En consecuencia,

$$|S| = 12 \times 21 = 252.$$

El vocabulario resultante contiene 252 acordes posibles antes de observar una sola nota. Los experimentos no utilizan esa lista como etiquetas verdaderas: los estados latentes permanecen sin nombre y las observaciones son clases de altura. El cálculo muestra que un vocabulario musical razonable puede crecer con rapidez sin indicar cuántos estados necesita una obra concreta. Conviene entonces separar el número de estados disponibles del número que el modelo utiliza.

4.1 Del número fijo a una colección abierta de estados

Los modelos bayesianos no paramétricos formalizan esa separación. El término *no paramétrico* puede resultar engañoso: el modelo sí tiene parámetros, pero no fija

el número de componentes utilizados antes de observar los datos. En este caso se parte de una colección numerable de estados potenciales y se distribuye entre ellos la probabilidad mediante un proceso de Dirichlet Ferguson (1973); Sethuraman (1994). El Apéndice A desarrolla el paso desde una distribución de Dirichlet finita hasta esta construcción.

La estructura del HMM del capítulo anterior se conserva, pero cambia el espacio de estados. En lugar de usar $\{1, \dots, N\}$, se considera

$$\mathcal{S} = \mathbb{N}.$$

La propiedad de Markov no cambia. El siguiente estado depende del estado presente y la observación depende del estado latente actual. La diferencia es que ya no se fija de antemano un número exacto de contextos.

Definición 4.1. *Una* cadena de Markov oculta infinita *está determinada por dos procesos estocásticos en tiempo discreto*

$$(X_t)_{t\geq 1}, \qquad (Y_t)_{t\geq 1},$$

donde (X_t) toma valores en $\mathbb{N}$ y (Y_t) toma valores en un espacio de observaciones $\mathcal{V}$. Se fija una distribución inicial

$$\pi = (\pi_i)_{i\geq 1},$$

una matriz de transición infinita

$$\mathbf{A} = (a_{ij})_{i,j\geq 1},$$

y una familia de distribuciones de emisión

$$\mathbf{B} = (b_j)_{j\geq 1},$$

de modo que, para todo $i, j \geq 1$ y todo $v \in \mathcal{V}$,

$$P(X_1 = i \mid \pi) = \pi_i,$$

$$P(X_t = j \mid X_{t-1} = i, \mathbf{A}) = a_{ij}, \quad t \geq 2, \qquad P(Y_t = v \mid X_t = j, \mathbf{B}) = b_j(v), \quad t \geq 1,$$

con

$$\sum_{i=1}^{\infty} \pi_i = 1, \qquad \sum_{j=1}^{\infty} a_{ij} = 1, \qquad \sum_{v \in \mathcal{V}} b_j(v) = 1.$$

Al ampliar el espacio de estados surge una dificultad concreta. Cada renglón de $\mathbf{A}$ debe asignar probabilidad a la misma colección, de modo que el estado j conserve su significado sin importar el estado de origen. El proceso de Dirichlet jerárquico establece esa referencia común mediante una distribución global. En las cadenas ocultas, la construcción resultante se denomina HMM basado en un proceso de Dirichlet jerárquico, o HDP-HMM, y constituye una forma de cadena de Markov oculta infinita, abreviada iHMM Beal, Ghahramani, and Rasmussen (2002); Teh et al. (2006).

La distribución global puede imaginarse como una barra de longitud uno que se rompe sucesivamente. El primer fragmento recibe peso β_1; del resto se obtiene β_2, y así sucesivamente. En conjunto, los fragmentos forman una distribución de probabilidad sobre los estados potenciales. En lo que sigue, $DP(c, H)$ denota un proceso de Dirichlet con concentración c y medida base H; la abreviatura *i.i.d.* indica variables independientes con la misma distribución. Formalmente, se escribe

$$\beta = \sum_{k=1}^{\infty} \beta_k \delta_k,$$

donde

$$\beta_k = v_k \prod_{\ell=1}^{k-1} (1 - v_\ell), \qquad v_k \overset{\text{i.i.d.}}{\sim} \text{Beta}(1, \gamma), \qquad k \geq 1,$$

y se supone que

$$\pi \mid \beta \sim DP(\alpha_0, \beta), \qquad \mathcal{A}_i \mid \beta \sim DP(\alpha, \beta), \qquad i \geq 1,$$

donde $\mathcal{A}_i$ es el renglón i-ésimo de $\mathbf{A}$.

$$\mathbb{E}[a_{ij} \mid \beta] = \beta_j.$$

La distribución global β funciona como un catálogo compartido. Cada renglón A_i puede favorecer transiciones distintas, pero todos se refieren a los mismos estados y parten de los pesos β_j. En términos musicales, un contexto ya utilizado puede reaparecer en distintas regiones de la obra; un contexto nuevo tiene una probabilidad pequeña, pero positiva, de incorporarse.

El alfabeto observable no necesita crecer junto con los estados. Si $\mathcal{V}$ contiene doce clases de altura, cada contexto latente puede conservar una distribución categórica sobre esas mismas doce posibilidades. Lo desconocido es cuántos contextos hacen falta para organizar la secuencia, no cuántos símbolos pueden observarse.

El calificativo "infinito" describe la colección disponible, no el número de estados que aparecerán en una obra finita. Una trayectoria de longitud T puede visitar, como máximo, T estados y normalmente utiliza muchos menos. El modelo evita decidir esa cantidad antes del ajuste, aunque los estados obtenidos siguen siendo categorías estadísticas sin una etiqueta musical garantizada. Para interpretarlos deben examinarse sus emisiones, sus transiciones y su correspondencia con una referencia externa.

La Figura 4.1 separa las dos ideas que suele confundir el término "infinito". El modelo ideal admite una colección numerable de estados potenciales, pero una trayectoria finita sólo visita algunos. El truncamiento reemplaza esa colección por una cota K que puede almacenarse y deja que parte de esos K estados permanezca sin utilizar.

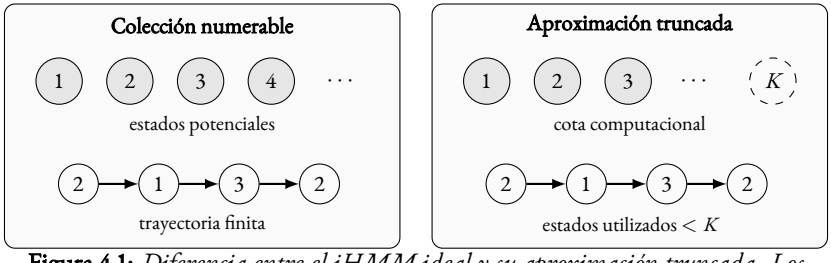


Figura 4.1: *Diferencia entre el iHMM ideal y su aproximación truncada. Los círculos superiores representan estados disponibles; la trayectoria inferior utiliza sólo una parte. En el panel derecho, el trazo discontinuo señala un estado disponible que puede quedar sin ocupar.*

Una computadora no puede almacenar una matriz con infinitos renglones y columnas. La implementación introduce entonces una cota K y aproxima la colección numerable mediante los estados $1, \dots, K$ Ishwaran and James (2001); Fox et al. (2011); Van Gael et al. (2008). El objetivo no es afirmar que la obra tiene exactamente K contextos, sino elegir una cota suficientemente alta y permitir que la inferencia deje estados sin usar.

Definición 4.2. *Fijado un entero $K \geq 2$, un* HDP-HMM truncado *con espacio observable discreto $\mathcal{V} = \{1, \dots, V\}$ queda determinado por las variables aleatorias*

$$v_k \sim \mathrm{Beta}(1, \gamma), \qquad k = 1, \dots, K-1,$$

$$\beta_k = v_k \prod_{\ell=1}^{k-1} (1 - v_\ell), \qquad k = 1, \dots, K-1,$$

$$\beta_K = \prod_{\ell=1}^{K-1} (1 - v_\ell),$$

por el vector global $\beta = (\beta_1, \dots, \beta_K)$ y por las distribuciones condicionadas

$$\pi \mid \beta \sim \mathrm{Dir}(\alpha_0 \beta_1, \dots, \alpha_0 \beta_K),$$

$$A_i \mid \beta \sim \mathrm{Dir}(\alpha\beta + \kappa e_i), \qquad i = 1, \dots, K,$$

$$\varphi_i \sim \mathrm{Dir}\left(\frac{\eta}{V}, \dots, \frac{\eta}{V}\right), \qquad i = 1, \dots, K,$$

donde e_i denota el i-ésimo vector canónico de $\mathbb{R}^K$. Si $\mathrm{Cat}(p)$ denota la distribución categórica con vector de probabilidades p, la cadena latente y las observaciones satisfacen

$$X_1 \mid \pi \sim \mathrm{Cat}(\pi), \qquad X_t \mid X_{t-1} = i, \mathbf{A} \sim \mathrm{Cat}(A_i),$$

$$Y_t \mid X_t = i, \varphi_i \sim \mathrm{Cat}(\varphi_i), \qquad t \geq 1.$$

La notación distingue la cota computacional del número de estados utilizados por la trayectoria. Dentro de esa cota, β reparte el peso global entre los K estados; γ influye en esa distribución; α_0 regula la distribución inicial y α determina cuánto puede

apartarse cada renglón de transición del patrón global. El parámetro κ puede favorecer la permanencia en el mismo estado, mientras que η controla la concentración de las emisiones sobre el alfabeto observable.

Una vez fijado K, las transiciones y emisiones vuelven a representarse mediante matrices finitas. Para una secuencia de longitud T, el costo dominante es del orden de $O(TK^2)$, pues en cada posición deben considerarse transiciones entre pares de estados. Una cota innecesariamente grande aumenta el costo de cálculo; una demasiado pequeña puede limitar el ajuste.

En los experimentos se denomina *estado efectivo* a cualquiera de los estados presentes en la trayectoria inferida. Su conteo indica qué parte de la cota disponible ocupa el modelo. No mide la calidad musical: dos estados efectivos pueden separar contextos útiles o dividir arbitrariamente una misma región, distinción que exige interpretación o anotaciones externas.

Las observaciones son clases de altura y el iHMM conserva un papel conceptual. La implementación emplea un HDP-HMM truncado, ajustado con los datos de las obras y comparado con el HMM finito. Antes de consolidar el diseño experimental se examinaron corridas disponibles sobre una pieza extensa y dos conjuntos de obras. Esas corridas describen el comportamiento de las trayectorias; la validación predictiva se realiza después con un protocolo común.

4.3 Comprobación preliminar en una obra de referencia

El caso ilustrativo es el tercer movimiento de la Sonata núm. 14 de Beethoven, una de las piezas extensas del corpus, con 4133 notas y 201 compases. Su longitud hace visibles las diferencias entre trayectorias que después se resumen. El análisis se limita a esta obra y no constituye evidencia general a favor de un modelo.

Las tablas y figuras proceden de exportaciones conservadas de corridas anteriores. El repositorio contiene el código que las generó, pero no sus CSV primarios; las cifras pueden cotejarse con las exportaciones incluidas, aunque una reproducción completa exige recuperar esos archivos.

La Tabla 4.1 compara log-verosimilitud, estados ocupados y segmentos contiguos de la trayectoria. Un segmento es una sucesión de posiciones consecutivas a las que el modelo asigna el mismo estado; un cambio de estado inicia el siguiente. Para una

misma secuencia, una log-verosimilitud mayor, es decir, menos negativa, indica que el modelo asigna más probabilidad a las observaciones. La magnitud depende de la longitud de la pieza, de modo que estos valores no deben compararse directamente entre obras de tamaños distintos.

Modelo	$\log L$	Estados	Segmentos	Long. media
HMM finito	-10242.186	88	560	7.380
HDP-HMM truncado	-7834.175	9	1075	3.845

Tabla 4.1: *Comparación entre el HMM finito y el HDP-HMM truncado en la obra de referencia: el tercer movimiento de la Sonata núm. 14 de Beethoven.*

Los dos modelos difieren tanto en el ajuste como en la ocupación de estados. El HMM finito ocupa 88 estados y obtiene log-verosimilitud -10242.186; el HDP-HMM ocupa 9 y obtiene -7834.175, una ganancia de 2408.011 unidades. Sin embargo, el modelo truncado produce 1075 segmentos, frente a 560 del HMM, y su longitud media es menor. En esta obra, reducir el vocabulario de estados no equivale a producir menos cambios: el HDP-HMM reutiliza un conjunto pequeño de etiquetas con mayor frecuencia.

La comparación se extiende primero a seis piezas breves para averiguar si el patrón se repite fuera de la sonata y, después, a un repertorio mayor.

4.4 Comprobación preliminar en el subconjunto clásico

La comparación controlada utiliza las seis piezas breves de la Tabla 4.2. Las observaciones son clases de altura. Para el HDP-HMM se fija $K = 12$, con $\alpha = 8$, $\alpha_0 = 4$, $\gamma = 2$, $\eta = 1$ y $\varkappa = 0$. Se realizan veinte iteraciones de inferencia, se descartan las diez primeras como calentamiento y se utiliza la semilla 7.

La configuración no procede de una búsqueda exhaustiva de hiperparámetros. Tampoco se conservaron trazas ni varias cadenas para evaluar la estabilidad de la inferencia. Esta sección describe, por tanto, las corridas disponibles; no aporta una comprobación de convergencia ni reemplaza los artefactos primarios faltantes.

Obra	Compositor	Notas	Compases
Cumpleaños feliz (Do mayor)	Tradicional	37	8
Oda a la alegría (variación fácil)	Desconocido	87	17
Para Elisa (versión fácil)	Beethoven	103	22
Cumpleaños feliz (arreglo)	Manjuprasad	106	19
Para Elisa (piano para principiantes)	Beethoven	149	23
Greensleeves	Desconocido	166	33

Tabla 4.2: *Subconjunto clásico limitado utilizado para la comparación documentada entre el HMM finito y el HDP-HMM truncado.*

Los resultados agregados aparecen en la Tabla 4.3. En las seis obras, el modelo truncado obtiene una log-verosimilitud mayor que el HMM finito. La ganancia media es de 92.970 unidades y la mediana de 98.739. El HDP-HMM utiliza, en promedio, 6.667 estados, frente a 10.833 del HMM finito.

Métrica	Valor
Obras comparables	6
Casos en que el HDP-HMM truncado mejora	6
Casos en que el HDP-HMM truncado empeora	0
Empates	0
Ganancia media de log-verosimilitud	92.970
Ganancia mediana de log-verosimilitud	98.739
Media de log-verosimilitud del HMM finito	-267.685
Media de log-verosimilitud del HDP-HMM truncado	-174.715
Estados activos medios del HMM finito	10.833
Estados efectivos medios del HDP-HMM truncado	6.667

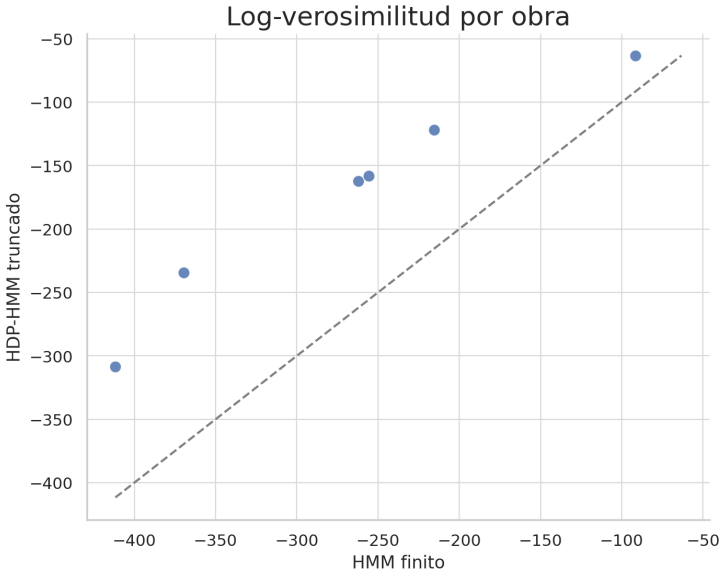
Tabla 4.3: *Resumen agregado de la comparación entre el HMM finito y el HDP-HMM truncado sobre el subconjunto clásico limitado.*

El promedio oculta cuánto cambia la ganancia entre piezas. La Tabla 4.4 presenta ese detalle: la diferencia es positiva en las seis obras, pero su magnitud no es uniforme.

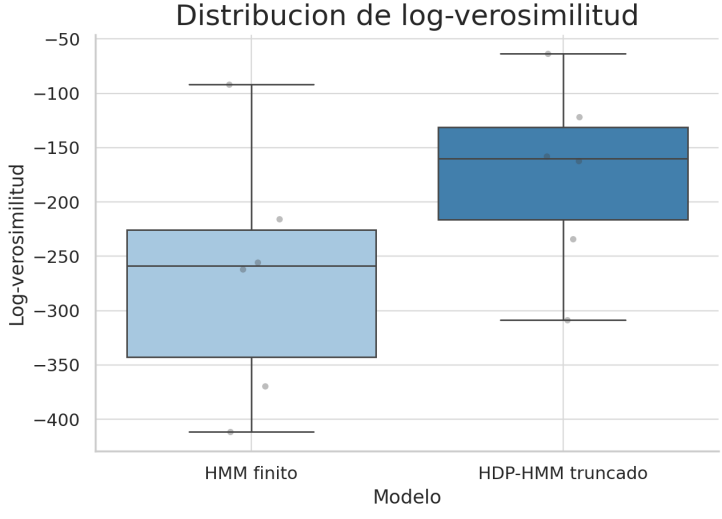
Obra	Compositor	Notas	$\log L_{fin}$	$\log L_{hdp}$	$\Delta \log L$
Cumpleaños feliz (Do mayor)	Tradicional	37	-91.575	-63.314	28.261
Oda a la alegría (variación fácil)	Desconocido	87	-215.515	-121.835	93.680
Para Elisa (versión fácil)	Beethoven	103	-255.714	-158.149	97.565
Cumpleaños feliz (arreglo)	Manjuprasad	106	-262.027	-162.114	99.914
Greensleeves	Desconocido	166	-411.682	-308.600	103.083
Para Elisa (piano para principiantes)	Beethoven	149	-369.596	-234.276	135.321

Tabla 4.4: *Comparación por obra en las seis piezas del subconjunto clásico. La ganancia se calcula como la diferencia HDP-HMM truncado − HMM finito.*

La Figura 4.2 muestra los valores que dan lugar al resumen anterior. El panel superior compara cada obra y el inferior presenta la distribución agregada; así puede distinguirse un patrón común de una diferencia debida a una sola pieza.



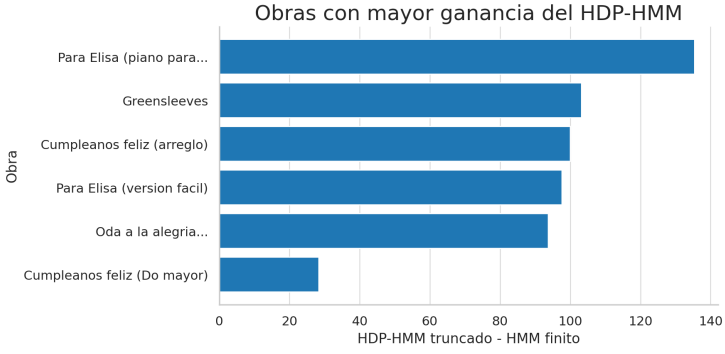
(a) *Comparación de log-verosimilitud por obra.*



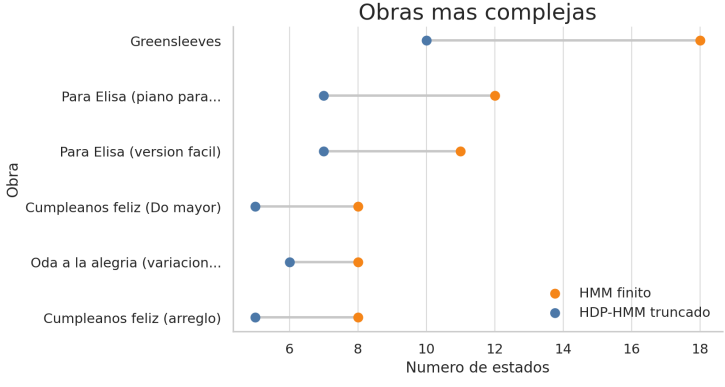
(b) *Distribución agregada de log-verosimilitud por modelo.*

Figura 4.2: *Ajuste probabilístico en el subconjunto clásico. Los paneles presentan los mismos seis casos por obra y de manera agregada.*

La Figura 4.3 relaciona ajuste y ocupación. En estas corridas, el HDP-HMM obtiene mayor log-verosimilitud con menos estados. La ocupación es más compacta; la calidad musical de la trayectoria requiere otro tipo de evidencia.



(a) *Ganancia de log-verosimilitud por obra.*



(b) *Comparación del número de estados por obra.*

Figura 4.3: *Ganancia de log-verosimilitud y ocupación latente en el subconjunto clásico. El panel superior muestra la diferencia de ajuste y el inferior el número de estados ocupados.*

La observación se limita a seis piezas. Ni la log-verosimilitud ni el número de estados indican que las fronteras latentes correspondan a frases, acordes o secciones. La evaluación siguiente amplía el repertorio a dos fuentes musicales.

El corpus extendido incorpora obras más largas y una tradición musical distinta. Reúne repertorio occidental identificado como `MuseTrainer` y material de tradición makam procedente de `SymbTr`; la Tabla 4.5 resume su composición. En el análisis se conserva la procedencia de cada obra. Incluir ambos repertorios en una misma evaluación no supone que compartan la misma teoría armónica.

Fuente	Descripción del material	Obras
MuséTrainer	Repertorio tonal occidental de orientación pedagógica y clásica, con piezas breves y medianas en formato MusicXML.	69
SymbTr	Repertorio de música artística turca; el adaptador conserva metadatos de *makam*, *usul* y forma para preservar la procedencia modal.	100
Total	Corpus extendido utilizado en la comparación descriptiva.	169

Tabla 4.5: *Composición del corpus extendido utilizado en la comparación multicorpus.*

De las 169 obras catalogadas, 168 pudieron procesarse y 167 produjeron resultados comparables entre ambos modelos. Una obra de Mozart no quedó incluida en el lote final y una pieza de Brahms produjo un error de ejecución. Estos casos quedan fuera del denominador de la Tabla 4.6, que resume las 167 comparaciones válidas. En todas ellas, el HDP-HMM obtiene una log-verosimilitud mayor. La ganancia media es de 452.751 unidades y la mediana de 377.039; el HDP-HMM ocupa en promedio 8.222 estados, frente a 32.162 del HMM finito.

Fuente	Obras	$\overline{\Delta \log L}$	$\widetilde{\Delta \log L}$	$\overline{\log L}_{fin}$	$\overline{\log L}_{hdp}$	$\overline{K}_{fin}$	$\overline{K}_{hdp}$
Global	167	452.751	377.039	-1598.180	-1145.429	32.162	8.222
MuséTrainer	67	585.443	467.011	-2667.850	-2082.406	46.418	8.731
SymbTr	100	363.848	336.438	-881.502	-517.654	22.610	7.880

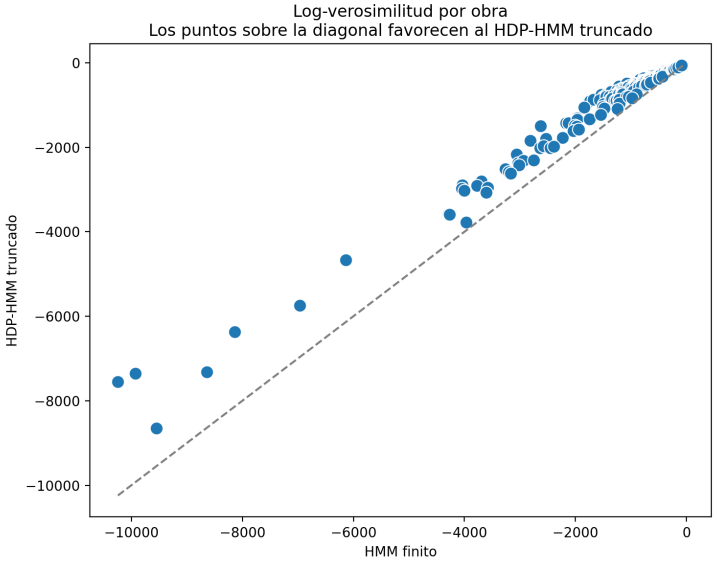
Tabla 4.6: *Resumen agregado de la comparación entre el HMM finito y el HDP-HMM truncado sobre el corpus extendido. La mejora se calcula como HDP-HMM truncado − HMM finito.*

Para no interrumpir la lectura con una tabla de 167 obras, la Tabla 4.7 presenta ocho ejemplos: cuatro de cada fuente y con longitudes distintas. La selección es ilustrativa. Los promedios y denominadores de la Tabla 4.6 proceden del conjunto completo de casos válidos.

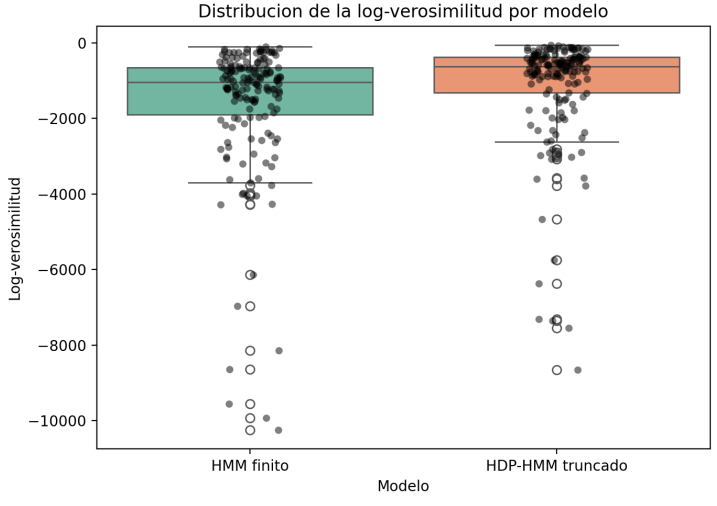
Fuente	Obra	Notas	$\log L_{fin}$	$\log L_{hdp}$	$\Delta \log L$
MuseTrainer	Cumpleaños feliz (Do mayor)	37	-91.575	-62.059	29.516
MuseTrainer	Danse Villageoise	519	-1286.408	-887.259	399.149
MuseTrainer	Clair de Lune	1220	-3020.550	-2421.226	599.324
MuseTrainer	Sonata núm. 14, tercer movimiento	4133	-10242.186	-7549.906	2692.280
SymbTr	Acemkürdî Aranağme (Düyek)	58	-144.102	-66.151	77.951
SymbTr	Aldanma Dünya Varına	266	-660.614	-349.715	310.898
SymbTr	Yıllar Sonra Rastladım...	417	-1035.314	-546.391	488.922
SymbTr	Âşık-I Ger	1135	-2815.965	-1841.559	974.407

Tabla 4.7: *Ejemplos de resultados por obra en el corpus extendido. Se incluyen cuatro piezas de* `MuseTrainer` *y cuatro de* `SymbTr` *con distintas longitudes.*

Las 167 comparaciones aparecen en la Figura 4.4. El primer diagrama muestra el signo de cada diferencia por obra; el segundo resume la distribución de log-verosimilitud dentro de cada modelo.



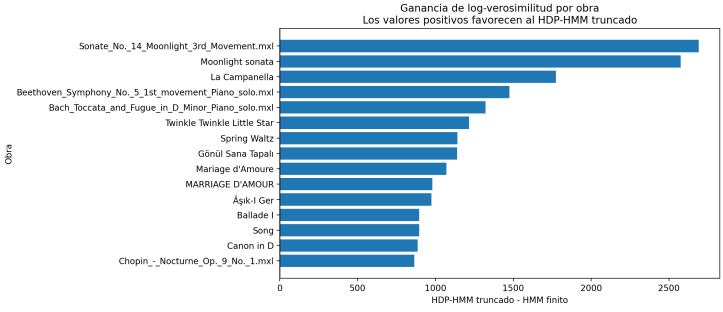
(a) *Comparación de log-verosimilitud por obra en el corpus extendido.*



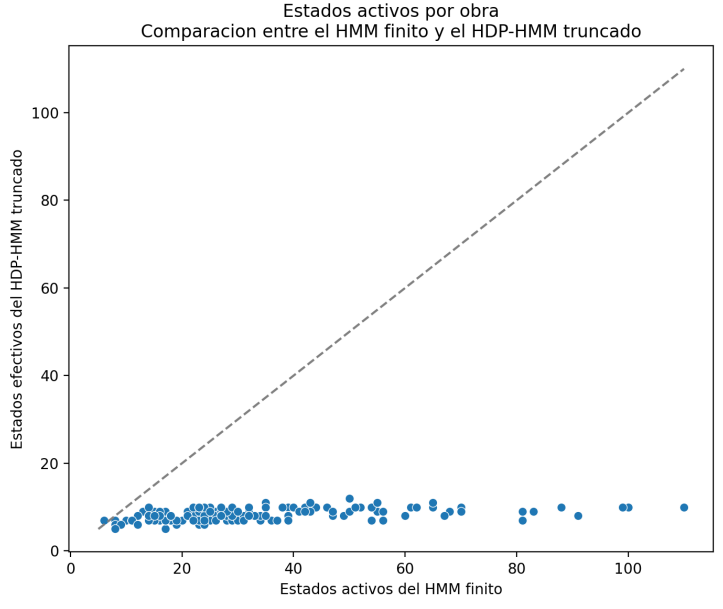
(b) *Distribución agregada de log-verosimilitud por modelo.*

Figura 4.4: *Log-verosimilitud por obra y distribución agregada en el corpus extendido. Las comparaciones se limitan a los* 167 *casos válidos para ambos modelos.*

La Figura 4.5 reúne las quince mayores ganancias de log-verosimilitud en el panel superior y compara el número de estados en el inferior. El signo de las 167 diferencias se encuentra en la Figura 4.4 y en la Tabla 4.6.



(a) *Quince obras con mayor ganancia de log-verosimilitud.*



(b) *Comparación del número de estados utilizados por ambos modelos.*

Figura 4.5: *Mayores ganancias de log-verosimilitud y ocupación latente en el corpus extendido. El panel superior muestra una selección de quince obras; el inferior incluye los casos para los que se dispone de ambos conteos.*

En el subconjunto clásico y en las 167 obras comparables del corpus extendido, el HDP-HMM alcanza una log-verosimilitud mayor y utiliza menos estados. El patrón describe el ajuste de secuencias de clases de altura. No se contrastó con anotaciones estructurales ni determina si los estados recuperan categorías de la teoría makam. La comparación final sitúa los cuatro modelos en una tarea predictiva común fuera de muestra.

Capítulo 5
Diseño de la solución y metodología experimental

Para comparar los cuatro modelos fue necesario fijar una representación, una tarea y un protocolo de evaluación comunes. Este capítulo reúne esas decisiones y describe cómo se incorporaron al sistema experimental.

5.1 Proceso de diseño de la solución

Se fijaron cuatro requisitos comprobables: compartir la representación y las particiones por obra, reservar la prueba para la evaluación final, mantener denominadores comunes y registrar la procedencia y el costo de cada corrida. Con ellos se consideraron cuatro alternativas. El HMM finito y el HDP-HMM incorporan contexto mediante estados latentes; el VOMM y el transformador lo hacen a partir de la secuencia observable. La solución debía contrastarlos con los mismos criterios y separar las salidas que no tuvieran un equivalente entre familias.

Los criterios se tradujeron en una especificación concreta: clases de altura como observaciones, particiones por obra canónica, selección de configuraciones mediante validación, predicción del siguiente evento como tarea común y NLL por evento como métrica principal. La especificación se versionó antes de la corrida principal. A partir de ella se implementaron la preparación, el ajuste, la reanudación, la evaluación y la auditoría.

La *verificación* contrasta la implementación con la especificación: comprueba que las variantes de una obra permanezcan en la misma partición, que la prueba no intervenga en la selección y que los cuatro modelos puntúen los mismos eventos. La *validación* se apoya en la comparación experimental, el análisis pareado y las sensibilidades para determinar si el sistema responde la pregunta predictiva. La recuperación de estructura musical requiere evidencia distinta.

La Figura 5.1 resume el proceso. El retorno representa las revisiones posteriores a la corrida principal: solapamiento de ventanas, capacidad del HMM finito, particiones por obra y presupuesto de inferencia.

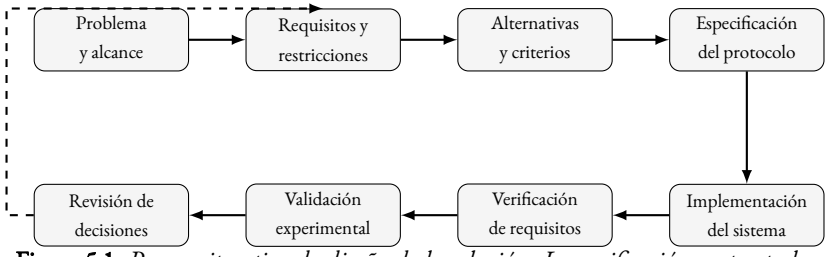


Figura 5.1: *Proceso iterativo de diseño de la solución. La verificación contrasta los requisitos con la implementación y la validación examina la evidencia experimental. El retorno corresponde a revisiones posteriores a la corrida principal.*

La tabla de trazabilidad relaciona cada requisito con una decisión y con la evidencia disponible. Los requisitos con evidencia incompleta se conservan como parciales.

5.2 De la partitura a una comparación común

Una partitura contiene alturas, duraciones, voces, compases y otras indicaciones, mientras que los modelos estudiados necesitan una secuencia discreta. La tarea común conserva únicamente las clases de altura, de modo que el HMM finito, el HDP-HMM, el VOMM y el transformador causal compartan el mismo alfabeto. La representación excluye el registro, la duración y parte de la organización métrica.

La representación sólo es común si también lo son las condiciones de evaluación. Colocar un arreglo en entrenamiento y una versión casi idéntica de la misma obra en prueba podría sobrestimar la generalización. Por ello, las particiones mantienen juntas las variantes de cada obra canónica. La auditoría comprueba además que todos los modelos puntúen los mismos eventos y que el símbolo de inicio funcione como

contexto, no como una nota adicional.

El HMM finito y el HDP-HMM producen estados latentes; el VOMM y el transformador no ofrecen una trayectoria equivalente. La log-verosimilitud negativa por evento, o NLL, compara la predicción. No evalúa si un estado coincide con una frase, un acorde o una sección. El análisis estructural se mantiene separado y exige anotaciones externas antes de atribuir significado musical a los estados inferidos.

La Figura 5.2 resume las decisiones que enlazan la partitura con la comparación: fijar la observación, agrupar las variantes de una obra y ajustar los cuatro modelos sobre una base común.

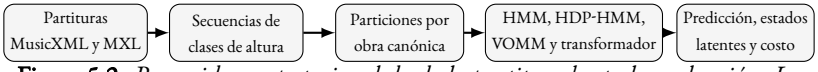


Figura 5.2: *Recorrido computacional desde la partitura hasta la evaluación. La representación y las particiones se fijan antes del ajuste para que los cuatro modelos resuelvan la misma tarea.*

El preprocesamiento lee archivos MusicXML y MXL, normaliza su contenido y genera secuencias de clases de altura W3C Music Notation Community Group (2021). Las cuatro familias utilizan las mismas particiones por obra y seleccionan su configuración con el conjunto de validación. Cada corrida registra resultados agregados y por pieza, dispositivo, tiempos, complejidad y cobertura de los eventos evaluados.

Reconstruir una corrida requiere conservar su configuración, semillas, exclusiones y asignaciones de obras. Los puntos de reanudación evitan repetir celdas terminadas, y las tablas del manuscrito se generan a partir de artefactos versionados o estructurados.

La ocupación latente, la calidad predictiva y la correspondencia con anotaciones son medidas distintas. En la corrida final se evaluó la predicción y se registraron las trayectorias; la ocupación del HDP-HMM no acreditó estabilidad. La correspondencia estructural quedó sin evaluar porque faltaron una referencia anotada y salidas comparables de los cuatro modelos.

5.3 Condiciones y límites del experimento

El diseño descansa en cuatro supuestos. Primero, las clases de altura conservan información suficiente para formular una tarea predictiva común. Segundo, agrupar

por identificador canónico reduce la transferencia de variantes entre particiones. Tercero, la NLL por evento compara la capacidad predictiva entre familias. Cuarto, los tiempos observados describen la ejecución realizada, aunque dependan del hardware. Estos supuestos acotan la pregunta predictiva y no convierten su respuesta en una medida de estructura musical.

La comparación final partió de una muestra de 3000 archivos de PDMX Long et al. (2025); después del preprocesamiento quedaron 2933 piezas. La muestra permitió construir curvas de aprendizaje, pero no representa la colección completa.

El transformador se ajustó en una unidad de procesamiento gráfico (GPU); HMM, HDP-HMM y VOMM se ejecutaron en unidades centrales de procesamiento (CPU). El tiempo de los modelos clásicos incluye la selección entre varias configuraciones, mientras que el transformador conserva una arquitectura y selecciona la época mediante detención temprana. Los tiempos mezclan así hardware y presupuestos de selección distintos: describen la corrida, no son comparaciones aisladas de los algoritmos ni de un único ajuste final.

La pregunta estructural quedó sin datos. Aunque el repositorio implementa métricas para fronteras y particiones, la corrida no contó con anotaciones musicales de referencia ni con segmentaciones comparables de los cuatro modelos. La evaluación se limita al desempeño predictivo y al costo observado.

El uso de formatos simbólicos interoperables permite rastrear la procedencia de cada secuencia sin depender de una codificación particular. MusicXML es un formato abierto para el intercambio de partituras entre aplicaciones, y MXL conserva el mismo contenido en un contenedor comprimido W3C Music Notation Community Group (2021). Al distribuir los datos y los artefactos también deben respetarse las condiciones de licenciamiento del corpus y de las bibliotecas utilizadas.

Reconstruir una corrida requiere el código, el *commit*, la configuración, las semillas, el corpus efectivo y las exclusiones. La corrida principal y las cuatro sensibilidades se auditaron en la máquina de ejecución. El repositorio conserva informes y figuras finales, pero no todos los CSV y JSON primarios; por ello, una clonación limpia todavía no regenera cada cifra.

La especificación del protocolo quedó registrada el 20 de agosto de 2026, en el *com-*

mit `d3c26b0`, antes de la corrida principal del 23 de agosto.[1] Esta precedencia distingue los criterios fijados de antemano de las sensibilidades añadidas tras observar la corrida. El estudio sigue siendo exploratorio porque incorporó decisiones posteriores.

La Tabla 5.1 relaciona requisitos, decisiones y evidencia. "Cumplido" exige una prueba o auditoría compatible; "parcial" indica que hay evidencia local sin un paquete público completo; "no evaluado" señala la ausencia de insumos. Son criterios de ingeniería del sistema, no una declaración de conformidad con una norma externa.

[1] Repositorio *Melodies*, especificación de evaluación multidimensional, *commit* `d3c26b0`.

Tabla 5.1: *Trazabilidad entre los requisitos del sistema, las decisiones de diseño y la evidencia de verificación.*

ID	Criterio	Decisión de diseño	Verificación	Estado
R1	Comparar sobre los mismos datos observables	Clases de altura y particiones agrupadas por obra canónica	Manifiestos de corpus y particiones; auditoría de denominadores	Cumplido
R2	Evaluar los mismos eventos	El inicio aporta contexto, no cuenta como nota; cada evento de validación y prueba se puntúa una vez	Auditoría de cobertura e índices por pieza en las cinco corridas	Cumplido
R3	Evitar información de prueba durante la selección	Las configuraciones y la época se eligen sólo con validación; el conjunto de prueba no participa en esa decisión	Pruebas de selección y configuraciones registradas en los artefactos auditados	Cumplido
R4	Poder reconstruir la procedencia de una corrida	Configuración, semillas, exclusiones, particiones, *commit* y puntos de reanudación	Informes y figuras versionados; no todos los CSV y JSON primarios están publicados	Parcial
R5	Registrar costo sin mezclar unidades incompatibles	El ajuste final se repite con configuraciones fijadas; tiempo, memoria, dispositivo y tarifa se conservan por separado	Medición auditada, manifiesto de hardware y escenarios monetarios fechados; la RAM compartida se declara como límite	Cumplido
R6	No atribuir estructura musical sin referencia	La evaluación estructural requiere anotaciones y salidas comparables de todos los modelos	El artefacto estructural declara que el eje no fue evaluado y especifica los insumos ausentes	No evaluado
R7	Verificar el protocolo antes de usar resultados	Pruebas de colas, inicio, separación entre obras, selección, retroceso del VOMM y análisis pareado	Antes de las sensibilidades pasaron 142 pruebas generales y 24 del experimento predictivo	Cumplido

5.4 Alternativas consideradas y arquitectura de la comparación

Las cadenas de Markov describen la sucesión local y los HMM introducen un contexto latente inferible mediante algoritmos establecidos Rabiner (1989); Cappé, Moulines, and Rydén (2005); en música se han empleado, entre otras tareas, para segmentación y reconocimiento de acordes Sheh and Ellis (2003). Los modelos bayesianos no paramétricos extienden esa idea sin fijar de antemano el número de estados utilizados Teh et al. (2006); Fox et al. (2011). La flexibilidad atiende una limitación del HMM finito, aunque la interpretación de los estados sigue requiriendo evidencia externa.

Otra línea amplía el contexto observable. Los modelos de Markov de orden variable conservan conteos explícitos y ajustan la longitud del contexto Begleiter, El-Yaniv, and Yona (2004). Los transformadores causales aprenden relaciones dentro de una ventana mediante atención Vaswani et al. (2017); la arquitectura también se ha aplicado a secuencias musicales simbólicas Huang et al. (2019). En el experimento, las cuatro familias comparten únicamente la tarea predictiva. Las trayectorias latentes se analizan aparte.

La Tabla 5.2 reúne los antecedentes que sustentan las cuatro alternativas. En cada caso se indica qué elemento se incorpora al diseño y qué límite permanece abierto en esta comparación.

El HMM finito y el HDP-HMM truncado introducen estados latentes y producen una trayectoria inspeccionable. El primero fija su número antes del ajuste; el segundo puede ocupar sólo una parte de la cota computacional. Una ocupación más compacta no implica mejor predicción ni una interpretación musical de los estados.

El VOMM y el transformador amplían el contexto observable. El VOMM Begleiter, El-Yaniv, and Yona (2004) utiliza conteos de longitud variable; el transformador causal Vaswani et al. (2017); Huang et al. (2019) distribuye la atención sobre el contexto anterior. Ambos asignan probabilidades al siguiente evento y carecen de una trayectoria discreta directamente comparable con la de los HMM.

Tabla 5.2: *Síntesis de los antecedentes que sustentan las alternativas consideradas. El límite indicado corresponde a la comparación de esta tesis, no a una valoración general de cada familia.*

Línea de trabajo	Recurso principal	Aporte al diseño	Límite que permanece
HMM finito Rabiner (1989); Cappé, Moulines, and Rydén (2005); Sheh and Ellis (2003)	Estados latentes y algoritmos establecidos de inferencia	Ofrece una trayectoria discreta y una referencia con capacidad controlada	El número de estados se fija antes del ajuste y su significado musical requiere evidencia externa
HDP-HMM Teh et al. (2006); Fox et al. (2011)	Inventario latente flexible dentro de una cota computacional	Permite estudiar cuántos estados ocupa el modelo sin imponer que todos se utilicen	La ocupación no equivale a estructura musical y debe acompañarse de diagnósticos de inferencia
VOMM Begleiter, El-Yaniv, and Yona (2004)	Conteos observables con longitud de contexto variable	Proporciona una referencia predictiva explícita y de ajuste directo	No produce una trayectoria latente comparable con la de los HMM
Transformador causal Vaswani et al. (2017); Huang et al. (2019)	Atención sobre los eventos anteriores dentro de una ventana	Incorpora un contexto observable amplio en la tarea de siguiente evento	La atención no constituye por sí sola una segmentación ni una explicación musical

A partir de estos antecedentes, el problema de diseño se plantea como una comparación entre propiedades que suelen examinarse por separado. La predicción del siguiente evento proporciona la tarea común; las trayectorias latentes y el costo se conservan como dimensiones adicionales.

La elección no se fijó mediante una puntuación compuesta. Las alternativas se conservaron porque representan compromisos distintos entre contexto, inspección y costo. La Tabla 5.3 hace explícitos esos compromisos sin introducir pesos que no formaron parte del protocolo.

Tabla 5.3: *Matriz cualitativa de las alternativas de diseño. La decisión final depende del propósito de uso y de los resultados del protocolo común; no se asignaron pesos retrospectivos.*

Alternativa	Forma de incorporar contexto	Salida que puede inspeccionarse	Restricción relevante	Papel en la comparación
HMM finito	Transiciones entre un número fijo de estados latentes	Trayectoria de estados y probabilidades de transición	La capacidad depende de la rejilla elegida y el costo crece al ampliar el número de estados	Referencia latente de capacidad controlada
HDP-HMM truncado	Inventario jerárquico de estados, limitado por una cota de cómputo	Trayectoria y número efectivo de estados ocupados	Requiere revisar convergencia, deriva y efecto de la truncación	Alternativa latente flexible
VOMM	Contextos observables de longitud variable	Conteos y probabilidades por contexto	La longitud máxima se selecciona en validación y no hay estados latentes	Referencia predictiva explícita
Transformador causal	Atención sobre una ventana de eventos anteriores	Distribución predictiva del siguiente evento	Exige más parámetros y su atención no equivale a una trayectoria discreta	Alternativa de mayor capacidad contextual

En la tarea predictiva, la decisión se apoya en la NLL y en su variación por obra. La trayectoria discreta y el tiempo de ajuste responden a necesidades distintas, por lo que se informan sin mezclarlos con la métrica predictiva.

La implementación separa la preparación de datos, el modelado y la evaluación. Primero lee las partituras, extrae las clases de altura y registra las exclusiones. Después agrupa las variantes por obra canónica y construye las particiones de entrenamiento, validación y prueba. El componente de evaluación reúne métricas, tiempos, cobertura y comparaciones por obra. Los puntos de reanudación conservan las celdas terminadas, no los pesos de los cuatro modelos.

Durante la corrida larga, la caché evitó procesar otra vez los 3000 archivos y el archivo de reanudación recuperó las celdas terminadas después de una interrupción preventiva por temperatura. La auditoría confirmó que los modelos puntuaron los mismos eventos.

La tarea común es predecir el siguiente evento a partir de secuencias de clases de altura, con las mismas particiones por obra y los mismos reinicios de contexto. La métrica principal es la NLL por evento; su transformación exponencial es la *perplexity*. Los tiempos y las medidas de complejidad se presentan por separado.

Considérese un segmento de prueba $y_1, \ldots, y_T$. En cada posición t, el modelo observa el contexto permitido c_t y asigna una probabilidad al símbolo que realmente sigue. La NLL por evento mide la sorpresa promedio del modelo:

$$\text{NLL} = -\frac{1}{T}\sum_{t=1}^{T} \log P(y_t \mid c_t), \qquad \text{perplexity} = \exp(\text{NLL}).$$

La penalización disminuye cuando el modelo asigna mayor probabilidad a los eventos observados. Por tanto, valores menores indican mejor predicción. Como imagen aproximada, una *perplexity* igual a q equivale a dudar entre q alternativas igualmente probables en cada paso. La distribución real no tiene que ser uniforme. NLL y *perplexity* expresan la misma información en escalas distintas.

Cada *token* puntuado corresponde a un evento musical; "NLL por *token*" y "NLL por evento" tienen el mismo denominador.

La NLL mide la calidad predictiva, el análisis pareado muestra si la diferencia se repite entre obras y los tiempos describen el costo observado. La Tabla 5.4 reúne estas tres lecturas.

Medida	Lectura intuitiva y criterio
NLL por evento	Penalización media por asignar poca probabilidad a la nota observada. Una NLL menor indica mejor predicción.
Perplexity	Expresa la misma penalización como un número efectivo de alternativas. Un valor menor indica mejor predicción.
Diferencia pareada de NLL	Resta la NLL de dos modelos sobre la misma obra, para que cada pieza aporte una comparación. Si $\Delta = \mathrm{NLL}_A - \mathrm{NLL}_B$, un signo negativo favorece a A.
Intervalo y prueba pareada	El intervalo *bootstrap* marginal cuantifica la precisión de la diferencia media. Wilcoxon examina los rangos de las diferencias y Holm ajusta la familia de valores p; no estiman la misma cantidad que el intervalo ni miden la magnitud.
Tiempo y tamaño	Describen el costo observado de seleccionar, ajustar y evaluar cada implementación. Se leen aparte porque el hardware y el número de configuraciones no fueron los mismos.

Tabla 5.4: *Lectura de las métricas utilizadas en la comparación. Las medidas de predicción determinan qué modelo asigna más probabilidad a las notas de prueba; las de costo se interpretan por separado.*

La equivalencia exige que los modelos puntúen exactamente los mismos eventos. El símbolo de inicio funciona como contexto y no cuenta como una nota adicional; el relleno del transformador también queda fuera. Validación y prueba se dividen en segmentos no superpuestos de hasta 128 eventos, incluida la cola final. Cada nota de prueba se puntúa una vez, con los mismos reinicios de contexto en las cuatro familias.

El entrenamiento no es idéntico. El transformador utiliza ventanas de hasta 128 eventos con desplazamiento de 64, de modo que algunos objetivos aparecen más de una vez; los modelos clásicos recorren cada secuencia sin solapamiento. Además de la arquitectura, cambia así el número efectivo de exposiciones. La Sección 6.3 examina el resultado con desplazamiento de 128.

La clase de altura conserva la identidad de la nota módulo octava y omite duración, registro, dinámica y buena parte de la organización métrica. El experimento estudia regularidades secuenciales en ese alfabeto compartido.

5.6 Construcción del protocolo comparativo

La obra canónica es la unidad de partición. Su identificador normaliza compositor y título; los archivos con el mismo identificador permanecen en un solo conjunto. La regla depende de los metadatos y puede omitir variantes no reconocidas. Con semilla 7, se reserva el 15% de las obras para prueba y el 10% para validación; el resto se utiliza para entrenamiento.

Sobre esa partición se construyen subconjuntos anidados con el 10%, 25%, 50%, 75% y 100% del acervo de entrenamiento. Cada fracción amplía la anterior para una misma semilla, en lugar de reemplazarla por un conjunto distinto. Esto permite observar cómo cambia el desempeño de cada modelo al aumentar los datos disponibles. Las semillas de datos 1, 2 y 3 cambian el orden de incorporación de las obras, mientras que las semillas de modelo 1 y 2 modifican la inicialización.

En la fracción completa, cambiar la semilla de datos ya no cambia el subconjunto. Las tres filas correspondientes contienen el mismo acervo y no son tres muestras independientes. La repetición no altera la comparación pareada por obra, pero la dispersión del último punto de la curva debe leerse con cautela.

Las configuraciones se seleccionan únicamente con validación. Para el HMM finito se comparan 12, 24 y 48 estados, mientras que para el HDP-HMM se fija una cota de 24 estados latentes y se contrastan tres combinaciones de hiperparámetros. El transformador conserva una arquitectura pequeña de tres capas y dimensión interna 128. Para el VOMM se comparan los órdenes 1, 2, 4 y 8. La Tabla 5.5 reúne la configuración de la corrida.

Tabla 5.5: *Protocolo ejecutado para la comparación predictiva*

Componente	Configuración ejecutada
Tarea	Predicción autorregresiva de la siguiente clase de altura
Representación	`pitch_class`; sin silencios, sin transposición y con preferencia por la voz aguda
Partición primaria	75% entrenamiento, 10% validación y 15% prueba; agrupación por obra canónica; semilla 7
Corpus	Muestra de 3000 archivos de PDMX; semilla de muestreo 7; 2933 piezas utilizables tras el preprocesamiento
Curva de aprendizaje	Fracciones 0.10, 0.25, 0.50, 0.75 y 1.00; semillas de datos 1, 2 y 3; subconjuntos anidados por obra
Repeticiones	Semillas de modelo 1 y 2; en la fracción completa las semillas de datos repiten el mismo subconjunto y no constituyen réplicas independientes
HMM finito	Selección entre 12, 24 y 48 estados; máximo de 100 iteraciones
HDP-HMM truncado	Cota $K = 24$; 120 iteraciones; calentamiento de 60; tres configuraciones de hiperparámetros
Transformador	Tres capas; dimensión 128; cuatro cabezas; dimensión intermedia 256; hasta 25 épocas con detención temprana
Ventanas del transformador	Entrenamiento con longitud máxima 128 y desplazamiento 64; validación y prueba sin solapamiento, con desplazamiento 128
VOMM	Control diagnóstico; selección por validación entre órdenes 1, 2, 4 y 8
Métrica primaria	NLL de prueba por token; se comprobó que la cobertura fuera idéntica entre modelos
Medidas complementarias	*perplexity*, tiempo, parámetros, seis diferencias pareadas, intervalo *bootstrap* marginal y valores p de Wilcoxon ajustados mediante Holm

El análisis principal incluye las cinco fracciones de entrenamiento. Después se ejecutaron cuatro comprobaciones en la fracción completa, cada una con una modificación: ventanas sin solapamiento para el transformador (desplazamiento 128), una

rejilla más amplia para el HMM finito ($K \in \{48, 96, 144, 192\}$) y dos semillas alternativas de partición, 17 y 29. Estas corridas examinan por separado la exposición durante el entrenamiento, la capacidad del HMM y la composición de los conjuntos; no se incorporan a la curva como réplicas. El informe de auditoría las registra como completas.

El análisis final toma la obra como unidad de comparación. Primero se promedian las variantes y repeticiones de una misma obra. Después se calcula, para cada par de modelos, la diferencia de NLL sobre las mismas piezas. De este modo, cada obra aporta un punto y una pieza larga no se convierte, por su número de notas, en centenares de observaciones independientes.

Para la diferencia media se obtiene un intervalo *bootstrap* marginal del 95% mediante 10 000 remuestreos de las obras. La prueba de rangos con signo de Wilcoxon examina por separado el signo y el orden de las diferencias pareadas, y el ajuste de Holm controla la familia de seis valores p Wilcoxon (1945); Holm (1979); Efron (1979); Demšar (2006). El intervalo se refiere a la media, mientras que la prueba atiende a la distribución de las diferencias. Ambos análisis están condicionados a la muestra, la partición y las configuraciones utilizadas; no incorporan variación entre particiones alternativas.

La auditoría exige igualdad entre los eventos esperados y los evaluados en cada obra. El símbolo de inicio del VOMM funciona como contexto y el relleno del transformador queda fuera de la puntuación. Una omisión, duplicación o alteración del orden invalida la corrida.

Durante cada celda, el programa conserva en memoria el modelo elegido por validación. El archivo de reanudación guarda filas y predicciones terminadas y tolera una última línea incompleta; no conserva pesos para continuar un ajuste a mitad de una celda. La caché evita repetir el preprocesamiento. Pruebas de regresión contrastan los cálculos reescalados y vectorizados de ambos HMM con las versiones en dominio logarítmico. Estas comprobaciones son computacionales, no musicales.

Con este protocolo, la corrida `tesis_3000_gpu_20260823_1941` terminó el 23 de agosto de 2026. Se muestrearon 3000 archivos del corpus PDMX con semilla 7 Long et al. (2025). El preprocesamiento dejó 2933 piezas utilizables y excluyó 67, para un

total de 693 754 eventos. El conjunto de prueba reunió 424 piezas. En la fracción completa, el entrenamiento utilizó 2173 piezas y 500 959 eventos.

Las tres semillas de datos y las cinco fracciones de entrenamiento forman quince celdas. En cada una se ajustaron dos inicializaciones del HMM finito, del HDP-HMM y del transformador, junto con un VOMM determinista. El diseño produjo 105 filas. El transformador se ajustó en GPU mediante CUDA; los tres modelos restantes se ejecutaron en CPU con doce procesos. Los tiempos observados corresponden, por tanto, a dispositivos distintos.

La ejecución se interrumpió como medida preventiva ante la temperatura del equipo. Al reanudarla, la caché recuperó los 3000 archivos y el programa omitió las celdas terminadas. La interrupción distinguió en la práctica el registro de resultados del estado interno de cada modelo y motivó el control separado de las cargas de CPU y GPU.

Capítulo 6

Resultados de la comparación predictiva y evaluación de viabilidad

La predicción del siguiente evento constituye la base común de los cuatro modelos. Dada una sucesión de clases de altura, se mide la probabilidad que cada uno asigna a la nota que aparece después. La evaluación estructural permanece separada.

El HMM finito y el HDP-HMM representan el contexto mediante una trayectoria de estados. El transformador causal utiliza atención sobre los eventos anteriores Vaswani et al. (2017); Huang et al. (2019); una cabeza de atención no equivale a un estado latente. La tarea predictiva evita esa equivalencia artificial. Una trayectoria inspeccionable tampoco constituye por sí misma una interpretación musical validada.

El modelo de Markov de orden variable, o VOMM, consulta varios eventos observados del pasado mediante tablas explícitas de conteos Begleiter, El-Yaniv, and Yona (2004). Ofrece así una referencia de memoria local frente a la arquitectura neuronal.

La diferencia puede verse en la Figura 6.1. El VOMM mantiene conteos para contextos observados de distintas longitudes y da más peso a los contextos largos cuando cuentan con evidencia suficiente. Si un contexto largo aparece pocas veces, la estimación se apoya más en contextos breves. El transformador, en cambio, representa cada evento y combina mediante atención causal la información de las posiciones anteriores antes de producir la distribución de la siguiente nota.

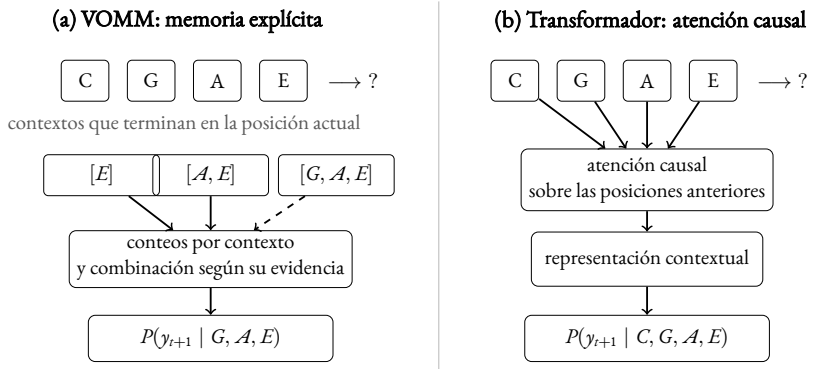


Figura 6.1: *Dos maneras de utilizar el contexto observable. El VOMM conserva conteos para contextos de diferentes longitudes y combina su evidencia; cuando los contextos largos aparecen pocas veces, se apoya más en los cortos. El transformador combina representaciones de las posiciones anteriores mediante atención causal. Ambos producen una distribución para la nota siguiente, pero sus mecanismos internos no son equivalentes.*

Ambos amplían la memoria observable de manera distinta: el VOMM conserva tablas inspeccionables por contexto y el transformador aprende representaciones distribuidas. El dibujo resume el flujo de información sin identificar sus componentes internos con estados musicales.

La Figura 6.2 muestra la relación entre las dos preguntas. Los cuatro modelos reciben la misma representación y predicen el siguiente evento. El HMM finito y el HDP-HMM producen, además, trayectorias latentes que podrían utilizarse en un análisis estructural. A partir de ellas puede proponerse una segmentación, pero no constituyen segmentaciones de referencia.

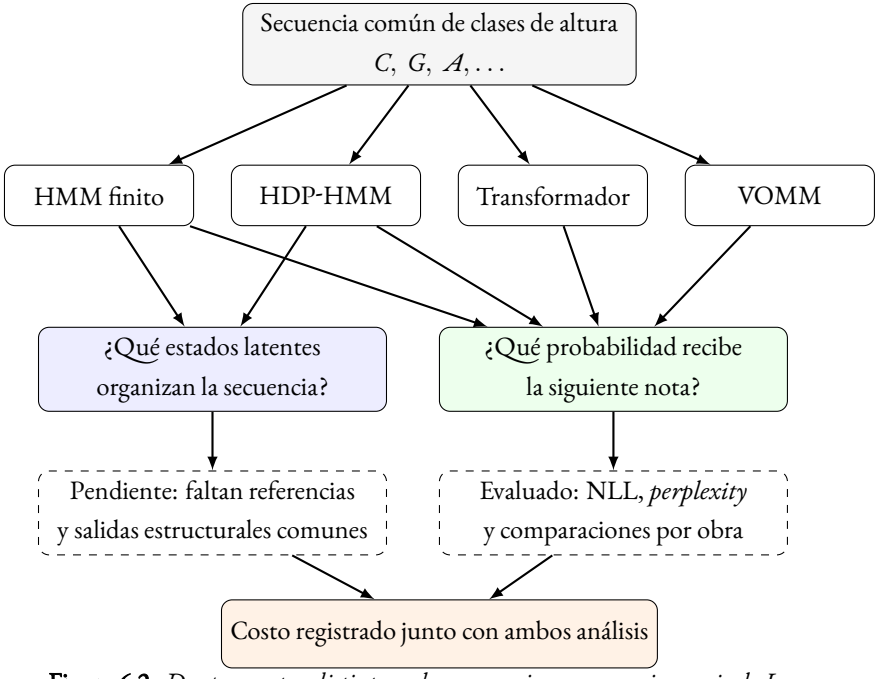


Figura 6.2: *Dos preguntas distintas sobre una misma secuencia musical. La predicción pudo compararse entre las cuatro familias; la descripción estructural requiere todavía anotaciones de referencia y salidas comparables de los modelos.*

6.1 Qué cambia cuando aumenta el corpus

La *perplexity* media de prueba aparece en la Tabla 6.1. En la primera fracción, con alrededor de 55 000 eventos de entrenamiento, el transformador obtiene 7.640 y el HMM finito 7.655. Estas medias puntuales difieren apenas en 0.015. No se estimó un intervalo pareado para ese punto de la curva, de modo que la diferencia no se interpreta como una ventaja clara de ninguno de los dos.

Tabla 6.1: Perplexity *media de prueba por fracción de entrenamiento. Menor es mejor; la última columna compara cada modelo consigo mismo entre los extremos de la curva.*

Modelo	0.10	0.25	0.50	0.75	1.00	Cambio 0.10 → 1.00
Transformador	7.640	7.287	6.878	6.259	5.823	-23.8%
HMM finito	7.655	7.447	7.403	7.363	7.356	-3.9%
HDP-HMM truncado	8.223	8.033	8.018	7.956	7.968	-3.1%
VOMM	8.756	8.496	8.376	8.195	8.022	-8.4%

La Figura 6.3 muestra la forma de la curva y la tabla conserva los valores exactos. Las barras representan la dispersión entre semillas dentro de la partición principal; no incluyen otras particiones del corpus.

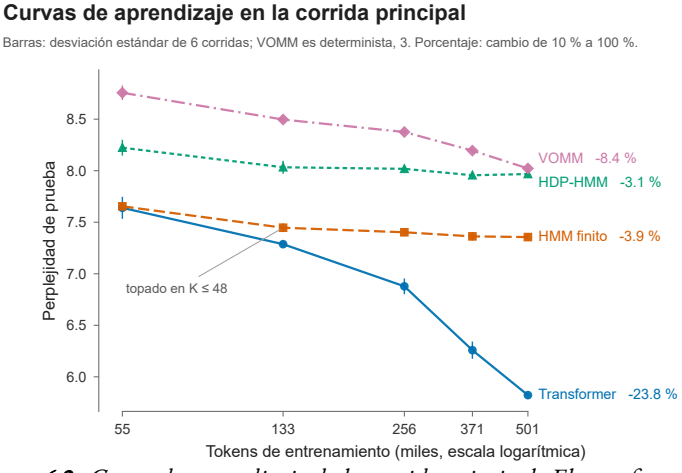


Figura 6.3: *Curva de aprendizaje de la corrida principal. El transformador presenta la mayor reducción de* perplexity *al pasar del* 10% *al* 100% *de los datos; los otros modelos también mejoran, pero menos dentro de sus configuraciones evaluadas. Las barras muestran la desviación estándar de seis ajustes, salvo el VOMM determinista, con tres. En la fracción completa, las tres semillas de incorporación utilizan el mismo conjunto y no constituyen réplicas independientes.*

Las curvas se separan al añadir obras. El transformador reduce su *perplexity* de 7.640 a 5.823, un cambio de 23.8%. El HMM finito pasa de 7.655 a 7.356 y el HDP-HMM de 8.223 a 7.968, con reducciones de 3.9% y 3.1%, respectivamente. El VOMM queda en una posición intermedia y reduce su valor en 8.4%. Dentro del intervalo estudiado, el transformador sigue beneficiándose del aumento del corpus; las config-

uraciones evaluadas de los otros modelos muestran reducciones menores.

En la fracción completa, el orden por evento es transformador, HMM finito, HDP-HMM y VOMM, con *perplexity* 5.823, 7.356, 7.968 y 8.022, respectivamente. La comparación pareada muestra a continuación cómo se distribuyen las diferencias entre obras.

6.2 Comparación obra por obra

Los promedios sobre todos los eventos pueden quedar dominados por unas cuantas piezas largas. Para saber cómo se distribuye la diferencia, se compara la NLL obra por obra. La partición principal contiene 424 archivos de prueba; al reunir las variantes por identificador canónico quedan 414 obras comunes. La auditoría verificó que la diferencia se debe por completo a la agrupación de variantes por obra canónica y no a descartes por métricas no finitas.[1] La Tabla 6.2 presenta los seis contrastes; un signo negativo favorece al primer modelo nombrado.

Tabla 6.2: *Comparaciones pareadas de NLL por obra en la fracción completa. Los intervalos* bootstrap *marginales corresponden a la diferencia media; los valores p de Wilcoxon se ajustaron conjuntamente mediante Holm.*

Comparación	Diferencia media	IC del 95%	p ajustado
HMM finito − HDP-HMM	-0.1071	$[-0.1184, -0.0959]$	2.5×10^{-52}
HMM finito − transformador	$+0.2505$	$[+0.2367, +0.2641]$	7.1×10^{-68}
HMM finito − VOMM	-0.0734	$[-0.0855, -0.0613]$	9.6×10^{-27}
HDP-HMM − transformador	$+0.3576$	$[+0.3401, +0.3750]$	4.2×10^{-68}
HDP-HMM − VOMM	$+0.0336$	$[+0.0164, +0.0513]$	3.5×10^{-4}
Transformador − VOMM	-0.3240	$[-0.3382, -0.3100]$	1.1×10^{-68}

La diferencia media entre el HMM finito y el transformador es de 0.2505 nats por evento, con intervalo marginal $[0.2367, 0.2641]$, a favor del transformador. El nat es la unidad que resulta de utilizar el logaritmo natural en la NLL. Frente al HDP-HMM, la diferencia es de 0.3576 nats. Ninguno de los seis intervalos marginales incluye el cero y todos los valores p de Wilcoxon permanecen por debajo de 0.05 después del ajuste de Holm.

Con este número de obras, la magnitud de las diferencias y sus intervalos son más informativos que un valor p aislado. Los valores p aportan una comprobación distinta

[1] Permanece una salvedad en el identificador del grupo `after mr`. Si se corrige, el denominador pasa a 415.

y no deben leerse como otra medida del tamaño de la mejora.

La comparación entre HDP-HMM y VOMM cambia con la unidad de análisis. Al sumar todos los eventos, las obras largas reciben mayor peso y el promedio favorece al HDP-HMM por 0.0076 nats. Cuando cada obra pesa lo mismo, el contraste favorece al VOMM por 0.0336 nats. El análisis principal utiliza la obra como unidad; la ponderación por eventos queda como lectura secundaria.

La Figura 6.4 localiza el cambio. Los dos cuartiles intermedios favorecen al VOMM; los intervalos de los cuartiles extremos cruzan el cero. En una media cada obra pesa lo mismo; en la otra, las obras largas aportan más eventos.

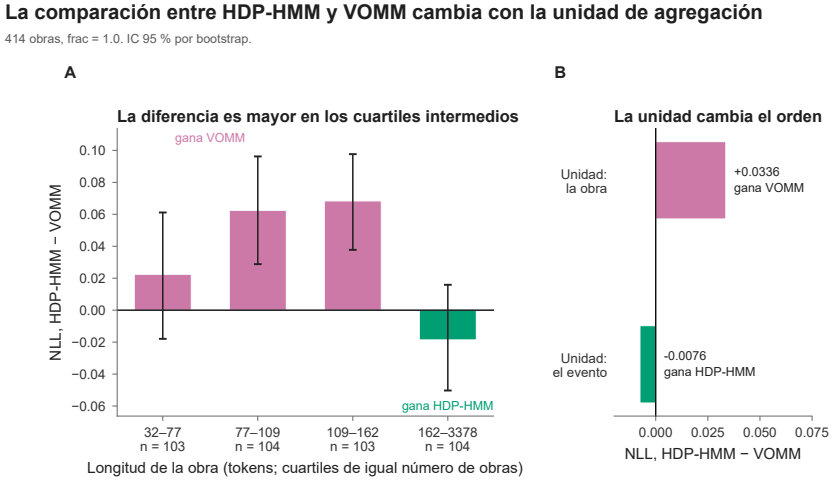


Figura 6.4: *Efecto de la unidad de análisis en la comparación entre HDP-HMM y VOMM. El panel A agrupa las* 414 *obras por longitud; los intervalos* bootstrap *de los cuartiles primero y cuarto incluyen el cero. El panel B contrasta la media por obra con la media ponderada por eventos.*

6.3 Sensibilidad de la comparación

Cuatro corridas de sensibilidad modifican un factor a la vez: el solapamiento de las ventanas del transformador, la capacidad del HMM finito y la partición de los datos. Este diseño aísla cada cambio, sin estimar sus interacciones.

La Figura 6.6 reúne los tres cambios: exposición del transformador en el panel A, capacidad del HMM finito en el B y particiones alternativas en el C.

Al aumentar el desplazamiento del transformador de 64 a 128, cada evento aparece una sola vez como objetivo por época. Su *perplexity* pasa de 5.8225 a 6.4394, un aumento del 10.6%; los modelos clásicos no cambian porque no utilizan esas ventanas. La ventaja sobre el HMM finito se reduce de 0.2505 a 0.1521 nats, un 39%. El orden se conserva, aunque una parte de la magnitud depende del régimen de exposición.

La ampliación independiente de la rejilla modifica el desempeño del HMM finito: su *perplexity* baja 0.37 puntos, de 7.3560 a 6.9835. Aun con esa mejora, el transformador mantiene una *perplexity* de 5.8225 y una ventaja pareada de 0.1894 nats. No se ejecutó una corrida que combinara la rejilla ampliada y las ventanas sin solapamiento, por lo que estas dos reducciones no deben sumarse ni tratarse como un mismo contraste.

Las treinta selecciones de la corrida principal eligieron 48 estados, el máximo disponible. Con una búsqueda hasta 192, la validación volvió a escoger valores del extremo superior (144 o 192). El HMM mejoró, pero el óptimo no quedó localizado.

El diagnóstico de la Figura 6.5 extiende una sola configuración hasta $K = 384$ y llega a la misma conclusión. La *perplexity* de validación continúa descendiendo, mientras que el costo por ajuste crece con rapidez. El punto de $K = 384$ requirió 11 019 segundos, aproximadamente 3.1 horas, y una curva completa exige treinta ajustes. La línea cuadrática del panel derecho es una referencia anclada, no un ajuste de ley de escala. Por tanto, la afirmación defendible es que el HMM finito no alcanzó saturación dentro del presupuesto computacional disponible, no que carezca de un óptimo ni que su costo siga exactamente una ley cuadrática.

Las semillas de partición 17 y 29 cambian el nivel de los cuatro modelos. La variación entre particiones supera la dispersión entre semillas dentro de la principal. También cambian los tamaños de entrenamiento (500 959, 529 127 y 548 526 eventos), y los HMM finitos alternativos conservan el tope de 48 estados; las columnas no estiman un efecto puro de la semilla. Dentro de cada partición se conserva el orden pareado: transformador, HMM finito, VOMM y HDP-HMM.

El HDP-HMM obtiene mayor *perplexity* que el HMM finito en las cinco fracciones. En este corpus y esta tarea, la cardinalidad latente flexible no dio una ventaja predic-

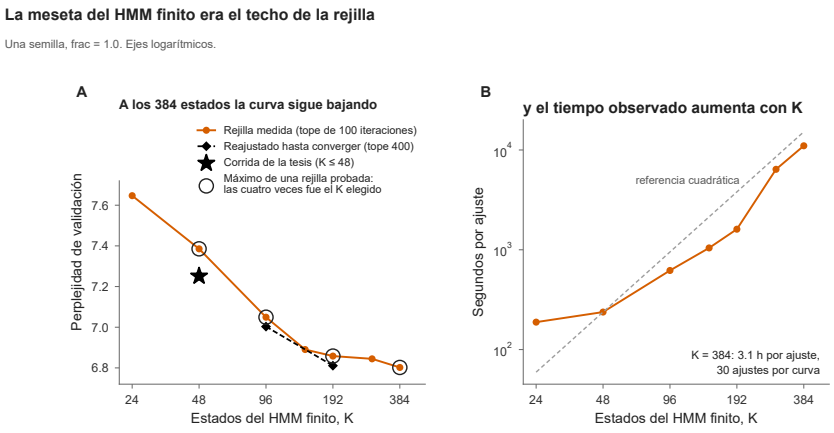


Figura 6.5: *Diagnóstico de capacidad del HMM finito en la fracción completa y con una semilla. El panel izquierdo utiliza* perplexity *de validación y muestra que la selección continuó tocando el mayor K disponible. El panel derecho registra el tiempo de ajustes individuales; la guía discontinua sirve sólo como referencia cuadrática. Este diagnóstico identifica un límite de cómputo, pero no localiza el óptimo de la familia.*

tiva. Las cadenas de las cuatro sensibilidades mostraron deriva y desacuerdo en el número de estados activos pese a alcanzar verosimilitudes semejantes; esa cardinalidad no es una estimación estable. El Capítulo 4 evalúa ajuste y complejidad latente en otros corpus; esta sección evalúa predicción fuera de muestra sobre PDMX.

La Figura 6.7 reúne treinta comparaciones: los seis contrastes originales y sus cuatro sensibilidades. Ningún intervalo del 95% cruza el cero y el mayor valor p ajustado es 0.0035. Cambiar por separado la exposición, la rejilla o la partición no invierte el orden pareado; las interacciones siguen sin medirse.

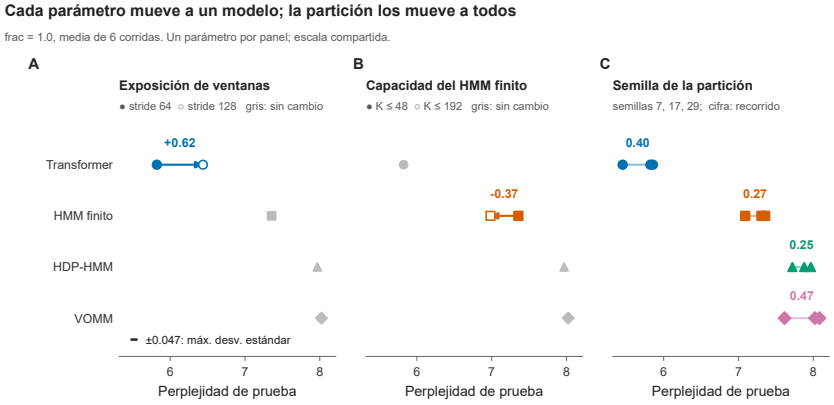


Figura 6.6: *Sensibilidad de la* perplexity *en la fracción completa. Los paneles A y B modifican por separado la exposición del transformador y la rejilla del HMM finito; el panel C muestra la variación entre tres particiones de la misma muestra. El segmento de* ± 0.047 *sirve como referencia de la mayor desviación estándar observada entre semillas, no como intervalo de incertidumbre común a todos los modelos.*

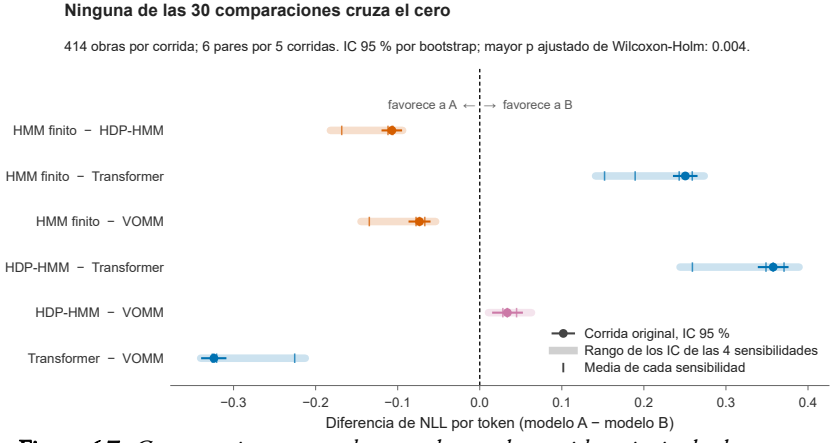


Figura 6.7: *Comparaciones pareadas por obra en la corrida principal y las cuatro sensibilidades. La diferencia se define como NLL del modelo A menos NLL del modelo B; el lado del cero indica cuál queda favorecido. El punto y el intervalo estrecho corresponden a la corrida principal, y la banda clara abarca los intervalos obtenidos en las sensibilidades.*

La Tabla 6.3 presenta el tiempo de selección y ajuste, el tiempo de evaluación y el tamaño del modelo. Las tres medidas permanecen separadas porque sus unidades no son intercambiables.

Tabla 6.3: *Costo medio observado en la fracción completa. La selección y el ajuste abarcan presupuestos distintos entre familias y se midieron en dispositivos diferentes; no constituyen una comparación neutral del hardware ni del ajuste final aislado.*

Modelo	Parámetros	Selección y ajuste (s)	Evaluación (s)	NLL
Transformador	415 872	169	2.6	1.762
HDP-HMM truncado	863	578	0.5	2.075
HMM finito	2 879	628	0.6	1.996
VOMM	101 201[a]	41	8.4	2.082

[a] Para VOMM, la cifra corresponde al tamaño de la tabla de conteos y no a parámetros continuos entrenables.

El transformador registró 169 segundos, frente a 578 del HDP-HMM y 628 del HMM finito. Ambos HMM seleccionan entre tres candidatos, el VOMM entre cuatro órdenes y el transformador entre épocas de una arquitectura. Además, el transformador se ejecutó en una GPU RTX 4060 y los otros modelos en CPU. Son tiempos de este protocolo y esta máquina, no *benchmarks* neutrales de un ajuste aislado.

El VOMM tiene el menor tiempo de selección y ajuste, 41 segundos, pero tarda más en evaluar y obtiene peor NLL que el transformador y el HMM finito. Si se consideran únicamente la NLL de prueba y el tiempo de selección y ajuste, como en la Figura 6.8, el VOMM y el transformador forman la frontera de Pareto, y el transformador domina a ambos HMM Miettinen (1999). Si se añade el tiempo de evaluación como tercer indicador, ninguna implementación domina a las demás. Estas fronteras describen el protocolo y el hardware utilizados, no una propiedad intrínseca de las familias. También son parciales porque aún falta medir la calidad estructural.

Ampliar la rejilla del HMM finito muestra además que el costo no es estable frente a la capacidad buscada. En la sensibilidad con $K \leq 192$, el tiempo medio de selección y ajuste pasó de 628 a 3843 segundos, un factor de 6.1, a cambio de reducir la *perplexity* en 0.37. Los tiempos de la partición con semilla 29 no se utilizan para este análisis porque esa corrida compartió la CPU con el diagnóstico de capacidad; la con-

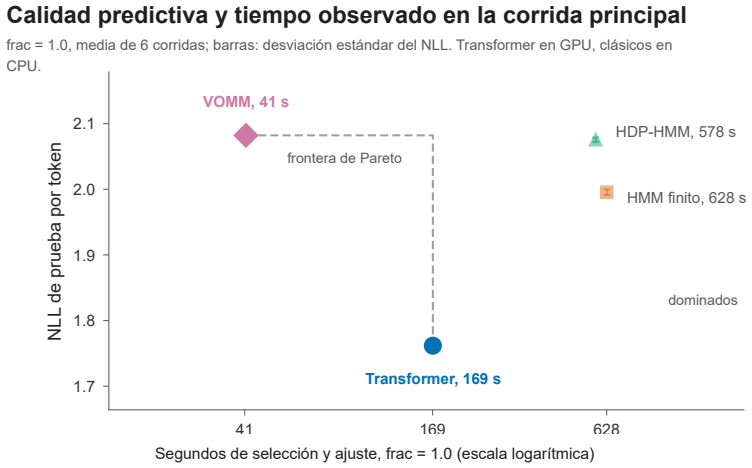


Figura 6.8: *Proyección de calidad predictiva y costo observado en la corrida principal. Menor es mejor en ambos ejes. El VOMM es el más rápido y el transformador obtiene la menor NLL; este último domina a los dos HMM en esta proyección. La comparación mezcla GPU para el transformador y CPU para los modelos clásicos.*

tención de CPU eleva los tiempos observados, aunque no modifica las predicciones determinadas por las semillas.

La comparación anterior describe el costo completo del protocolo, incluida la elección de configuraciones. Para separar ese costo del ajuste final, se ejecutó un segundo experimento con las configuraciones ya fijadas por la corrida principal. Se conservaron la partición con semilla 7, la fracción completa y la semilla de modelo 1. Cada familia se repitió tres veces bajo la misma carga de datos y sin otros trabajos intensivos. Son repeticiones técnicas para medir tiempo y memoria; no añaden tres observaciones independientes al análisis predictivo.

La Tabla 6.4 presenta la mediana y el intervalo observado entre el mínimo y el máximo. Los costos se calcularon con la media de los tiempos y dos tarifas de referencia registradas el 3 de septiembre de 2026 para la región `us-central1`: USD 0.071696 por hora para una instancia `n2-highcpu-2` y USD 0.421696 por hora para esa instancia con una GPU NVIDIA T4 Google Cloud (2026*a*,*b*). Se trata de un escenario de servicio remoto, no del gasto de la estación de trabajo.

Tabla 6.4: *Medición de recursos con configuraciones fijadas. Los tiempos muestran mediana [mínimo, máximo] de tres repeticiones. El primer costo incluye un ajuste; el segundo, el ajuste y cien evaluaciones. Los costos proceden de las medias de tiempo y de las tarifas documentadas en el escenario.*

Modelo	Ajuste (s)	Evaluación (s)	Ajuste (USD)	100 eval. (USD)
Transformador	186.0 [175.6, 191.3]	2.66 [2.65, 2.72]	0.0216	0.0530
HMM finito	255.1 [254.1, 255.4]	0.63 [0.59, 0.63]	0.0051	0.0063
HDP-HMM truncado	199.7 [199.4, 200.2]	0.60 [0.56, 0.63]	0.0040	0.0052
VOMM	1.80 [1.73, 1.84]	9.91 [9.64, 9.99]	0.000036	0.0196

En este ensayo, el ajuste del transformador tomó una mediana de 186.0 segundos, frente a 255.1 del HMM finito y 199.7 del HDP-HMM. El VOMM necesitó 1.80 segundos. La evaluación invierte parte de ese orden: los dos HMM tardaron alrededor de 0.6 segundos, el transformador 2.66 y el VOMM 9.91. El valor de NLL fue idéntico en las tres repeticiones de cada modelo, como corresponde a configuraciones y semillas fijas. Por ello, este ensayo confirma la estabilidad técnica del procedimiento, pero no reemplaza los resultados predictivos obtenidos con varias obras y semillas.

La menor duración del transformador frente a los HMM no se tradujo en menor costo dentro del escenario elegido. La tarifa horaria de GPU fue 5.88 veces la de CPU: un ajuste del transformador se estimó en USD 0.0216, frente a USD 0.0051 para el HMM finito y USD 0.0040 para el HDP-HMM. Con cien evaluaciones, las estimaciones fueron USD 0.0530, USD 0.0063 y USD 0.0052, respectivamente. El VOMM mantuvo el menor costo en ambos escenarios, aunque su evaluación fue la más lenta.

Los puntos de equilibrio permiten separar el resultado de una tarifa particular. Para que el ajuste del transformador costara menos que el del HMM finito, la razón $c_{\mathrm{GPU}}/c_{\mathrm{CPU}}$ tendría que ser inferior a 1.38; frente al HDP-HMM, inferior a 1.08. El escenario documentado queda por encima de ambos valores. Estos cálculos no incluyen almacenamiento, desarrollo, mantenimiento ni amortización fuera de lo que ya esté comprendido en la tarifa.

La memoria exige una lectura más cauta. Para el transformador se midió un máximo de 175 349 760 bytes asignados y 205 520 896 bytes reservados por CUDA durante el ajuste, aproximadamente 167 y 196 MiB. En cambio, la RAM se registró como el máximo absoluto del proceso y sus hijos. Los cuatro modelos se ejecutaron en

secuencia dentro del mismo proceso; después de cargar PyTorch, parte de esa memoria permaneció reservada. El valor del VOMM, ejecutado al final, incluye por tanto memoria retenida por etapas anteriores. Esos máximos sirven para describir la envolvente de la ejecución completa, pero no para ordenar el consumo propio de RAM de cada familia.

6.5 Viabilidad de la solución y responsabilidad profesional

El sistema ejecutó de extremo a extremo la preparación de datos, la selección, el ajuste, la evaluación y la reanudación. Esta evidencia sustenta la viabilidad tecnológica del prototipo. La evaluación económica se apoya en tiempos medidos y escenarios de tarifas; no representa un gasto efectuado. La dimensión social se limita a condiciones de uso, pues no se realizó un estudio con usuarios.

Las cinco corridas auditadas se completaron en una estación de trabajo con CPU y GPU.

Hubo una interrupción preventiva por temperatura, no existe reanudación dentro de cada ajuste y los artefactos primarios de la comparación predictiva no están en el repositorio público. Además, la búsqueda del HMM finito alcanzó el extremo superior de la rejilla. La medición posterior separa el ajuste final y documenta el entorno, pero conserva dispositivos distintos para CPU y GPU y no atribuye la RAM de forma independiente. La evidencia corresponde a un prototipo de investigación con recursos semejantes a los utilizados, no a un servicio de producción ni a una herramienta estructural validada.

El prototipo puede servir a quienes investigan modelos secuenciales o desarrollan herramientas de análisis musical, siempre que la tarea sea predecir clases de altura y se acepten las omisiones de duración, registro, dinámica y métrica. No se evaluó su utilidad con usuarios, la representatividad de la muestra por tradición, época o procedencia, ni un beneficio educativo, creativo o cultural. Cualquier distribución debe conservar la procedencia y respetar las licencias del corpus, de las obras y de las bibliotecas.

Una NLL menor significa que el modelo asignó mayor probabilidad a los eventos de prueba. No implica comprensión musical, una mejor explicación de la obra ni recuperación de su estructura.

Antes de utilizar las trayectorias o la atención para sustentar decisiones musicológicas, pedagógicas o creativas, harían falta referencias externas y una validación específica. Un despliegue responsable también requeriría documentar versiones, configuraciones, cobertura del corpus, recursos necesarios y condiciones de licencia, además de mantener la revisión humana cuando la salida se interprete musicalmente. La ventaja predictiva del transformador puede justificar su complejidad en aplicaciones que valoren esa mejora, pero no cuando se priorizan el costo mínimo, la inspección directa o la interpretación estructural.

6.6 Lo que la predicción todavía no responde

Para saber si una trayectoria latente coincide con una organización musical reconocible hacen falta fronteras o etiquetas anotadas de manera independiente en las mismas obras. Con esa referencia podrían compararse puntos de cambio y particiones mediante F_1 de fronteras, información mutua normalizada e índice de Rand ajustado.

La corrida no dispuso de anotaciones de referencia ni produjo segmentaciones comparables para los cuatro modelos; el artefacto estructural registró `not_evaluated`. No se calcularon esas métricas. La atención del transformador y los estados de los HMM siguen siendo hipótesis de organización.

La comparación predictiva también tiene límites concretos. Las sensibilidades resolvieron las dudas inmediatas sobre exposición, una primera ampliación de capacidad y dos particiones adicionales, pero no sus interacciones. El óptimo del HMM finito no quedó localizado dentro de la rejilla explorada y los diagnósticos del HDP-HMM no acreditan una cardinalidad latente estable. La medición de recursos igualó el número de repeticiones y separó el ajuste final, pero mantuvo el transformador en GPU y los demás modelos en CPU. Las corridas fueron auditadas en la máquina de ejecución y sus figuras finales quedaron versionadas; sin embargo, los CSV y JSON primarios de la comparación predictiva no están incluidos en el repositorio público, por lo que una clonación limpia no basta para regenerar todos los resultados.

En la corrida principal, el transformador obtiene la menor *perplexity* desde la fracción 0.25, y su diferencia frente a los otros modelos aumenta al incorporar más obras. En la fracción completa conserva el primer lugar en cada sensibilidad por separado: tanto en la corrida con la rejilla ampliada del HMM como, de manera independiente,

en la corrida con ventanas sin solapamiento. El VOMM ofrece la selección y el ajuste más breves, pero no la mejor predicción. La estabilidad se refiere a tres particiones de una misma muestra y a cambios aislados del protocolo; no permite ordenar los modelos por su capacidad para representar la organización musical hasta que se incorpore la referencia estructural faltante.

Capítulo 7
Conclusiones

En la tarea y la escala estudiadas, el transformador produjo la mejor predicción de la siguiente clase de altura. La ventaja se mantuvo ante los cambios aislados de exposición, capacidad del HMM y partición. Con la configuración ya fijada, su ajuste tardó menos que el de ambos HMM y más que el del VOMM; bajo el escenario de tarifas considerado, sin embargo, fue la alternativa más cara. La evidencia responde así la pregunta predictiva; la calidad estructural y la viabilidad social quedaron sin medir.

7.1 Respuesta a la pregunta de investigación

Con la fracción completa de entrenamiento, el transformador obtuvo una *perplexity* de 5.823, frente a 7.356 del HMM finito, 7.968 del HDP-HMM truncado y 8.022 del VOMM. La reducción respecto del HMM limitado a $K \leq 48$ es de aproximadamente 20.8%. La rejilla inicial resultó insuficiente: al ampliarla hasta $K = 192$, el HMM mejoró a 6.984. Aun frente a esta configuración, la reducción del transformador alcanza aproximadamente 16.6%.

En la lectura intuitiva de la métrica, el número efectivo de alternativas por evento pasa de cerca de 7.0 a 5.8. No se fijó de antemano un umbral de utilidad musical o práctica.

Los seis contrastes pareados de cada corrida se calcularon sobre 414 obras canónicas. Ninguno de los treinta intervalos *bootstrap* del 95% cruza el cero. El transformador conserva el primer lugar con ventanas sin solapamiento, con la rejilla ampliada del

HMM y en las dos particiones alternativas. Las sensibilidades modifican la magnitud, no el signo de la ventaja.

Con ventanas sin solapamiento, la *perplexity* del transformador aumenta de 5.8225 a 6.4394 y su ventaja pareada frente al HMM finito se reduce un 39%. Al ampliar la capacidad del HMM, su *perplexity* disminuye 0.37 puntos. Ambas modificaciones se evaluaron por separado y sus efectos no pueden sumarse. La magnitud de la ventaja depende del protocolo.

El análisis estructural no ofrece un ganador. En los experimentos del Capítulo 4, el HDP-HMM obtuvo mayor log-verosimilitud de ajuste y utilizó menos estados que el HMM finito sobre otros corpus. En la comparación final, sus cadenas mostraron deriva y no establecieron un número estable de estados activos. No hubo anotaciones para contrastar frases, acordes o secciones, ni una salida estructural equivalente para el transformador. La ventaja demostrada es predictiva.

7.2 Balance entre mejora, complejidad y viabilidad

La ventaja predictiva depende de la escala. En las medias de la curva principal aparece desde la fracción 0.25 y crece al incorporar obras. En la fracción 0.10, el transformador y el HMM finito obtuvieron 7.640 y 7.655: una diferencia de 0.015 sin intervalo pareado. Las particiones alternativas sólo se ejecutaron con la fracción completa, de modo que no localizan el punto de separación con pocos datos.

La configuración principal registró 415 872 parámetros para el transformador, 2 879 para el HMM finito con $K = 48$ y 863 para el HDP-HMM truncado. Los conteos no son directamente comparables, pero muestran la diferencia de escala. En la corrida principal, los tiempos de selección y ajuste fueron 169, 628, 578 y 41 segundos para transformador, HMM finito, HDP-HMM y VOMM, respectivamente. Esas cifras incluyen presupuestos de selección distintos.

La medición posterior eliminó esa diferencia de búsqueda al repetir tres veces cada configuración fijada. La mediana de ajuste fue de 186.0 segundos para el transformador, 255.1 para el HMM finito, 199.7 para el HDP-HMM y 1.80 para el VOMM. El transformador continuó en GPU y los demás modelos en CPU. Por tanto, los tiempos representan el uso previsto en la estación de trabajo, no una comparación de algoritmos sobre un mismo dispositivo.

Al ampliar la capacidad del HMM, el tiempo medio aumentó de 628 a 3843 segundos, un factor de 6.1, y la *perplexity* bajó de 7.3560 a 6.9835. El óptimo quedó fuera de la rejilla explorada. Una comparación más estrecha requeriría mayor presupuesto o una implementación más eficiente.

El HMM finito y el HDP-HMM producen una trayectoria discreta que puede inspeccionarse. Esa inspectabilidad no equivale a interpretabilidad musical. El transformador carece de un objeto directamente equivalente y su atención no se validó como explicación estructural. La complejidad adicional mejoró la predicción, no la comprensión demostrada de la melodía.

Las cinco corridas predictivas y la medición de recursos fueron auditadas. Sus informes y figuras finales quedaron versionados, pero los CSV y JSON primarios de la comparación predictiva no están en el repositorio público. La procedencia puede rastrearse; una clonación limpia todavía no regenera todos los resultados.

La solución fue tecnológicamente viable como prototipo en el entorno utilizado. La preparación, el ajuste de las cuatro familias, la evaluación y las auditorías se ejecutaron como un sistema integrado. Una interrupción preventiva por temperatura mostró la necesidad de controlar la carga y conservar puntos de reanudación. El resultado no se extrapola a otro equipo ni a una escala mayor.

El escenario económico utilizó tarifas documentadas de USD 0.071696 por hora de CPU y USD 0.421696 por hora de GPU. A partir de los tiempos medios de la medición, un ajuste se estimó en USD 0.0216 para el transformador, USD 0.0051 para el HMM finito, USD 0.0040 para el HDP-HMM y USD 0.000036 para el VOMM. Al añadir cien evaluaciones, el orden no cambió. La duración por sí sola habría favorecido al transformador frente a los HMM; la tarifa de GPU, 5.88 veces la de CPU, invirtió esa conclusión económica.

El resultado no es universal. Para que el ajuste del transformador costara menos que el del HMM finito, la razón entre las tarifas de GPU y CPU tendría que ser menor que 1.38; frente al HDP-HMM, menor que 1.08. El cálculo no incluye almacenamiento, desarrollo, mantenimiento ni amortización fuera de la tarifa. Tampoco ofrece una comparación limpia de RAM por modelo: la ejecución compartió un proceso y retuvo memoria entre etapas. La memoria CUDA del transformador sí quedó

registrada por separado.

La viabilidad social no fue evaluada. No se definió una población usuaria ni se midieron utilidad, accesibilidad, efectos de uso o representatividad musical. Una aplicación real tendría que establecer para quién se diseña, qué necesidad atiende y bajo qué condiciones de procedencia y licencia utiliza sus datos y resultados.

Para predecir la siguiente clase de altura con un corpus de esta escala, la complejidad del transformador produjo una mejora sostenida. Esa mejora justifica elegirlo cuando la calidad predictiva tiene prioridad y se dispone de GPU. No basta para afirmar que sea la opción más conveniente en general: el escenario económico favoreció a los modelos de CPU y no se midió un beneficio equivalente para explicar la organización musical. La viabilidad social tampoco quedó establecida.

7.3 Alcance y propuestas de continuación

La representación excluyó duración, registro, dinámica y buena parte de la organización métrica. Para saber si la ventaja se conserva al incorporar esas dimensiones, sería necesario repetir la comparación con una representación más amplia.

La evaluación estructural requiere anotaciones independientes en las mismas obras y fronteras o segmentaciones comparables de cada modelo. Con esos insumos podrían evaluarse las fronteras mediante F_1 y las particiones mediante información mutua normalizada e índice de Rand ajustado. Hasta entonces, los estados latentes y los patrones de atención son hipótesis de organización.

Para afinar la comparación predictiva se propone un diseño factorial pequeño que combine ventanas sin solapamiento con una rejilla ampliada del HMM. Localizar el óptimo del HMM requeriría una implementación más eficiente al crecer K o una búsqueda de capacidad más económica. Las particiones alternativas, el desplazamiento 128 y la primera ampliación de la rejilla ya fueron ejecutados.

La prueba de recursos ya separa la búsqueda de configuraciones del ajuste final. Una medición posterior podría ejecutar cada modelo en un proceso nuevo para atribuirle su máximo de RAM y repetir las familias compatibles sobre un mismo tipo de hardware. Esa extensión aclararía el costo computacional; no modificaría por sí misma la comparación predictiva.

El análisis económico puede ampliarse con escenarios de propiedad del equipo, frecuencia de uso y trabajo de operación y mantenimiento. Así se distinguiría el costo de desarrollo del costo de una predicción. La evaluación social tendría que partir de una aplicación y una población usuaria concretas, para después contrastar con ellas la utilidad y las restricciones del sistema.

Dentro de la tarea y la escala estudiadas, la complejidad adicional del transformador sí produjo una mejora predictiva reproducible frente a las configuraciones comparadas. No fue, sin embargo, una mejora gratuita: exigió GPU, elevó el costo estimado bajo las tarifas elegidas y no aportó una interpretación estructural validada. El VOMM conserva interés cuando se prioriza un ajuste breve, y los modelos latentes cuando se necesita una trayectoria explícita para contrastarla con anotaciones. La elección depende, por tanto, de cuánto se valore la reducción de incertidumbre frente al costo, la inspección del modelo y la finalidad concreta del sistema.

Capítulo A

De la distribución de Dirichlet al proceso jerárquico

A.1 Sobre el proceso de Dirichlet y los modelos jerárquicos

El HDP-HMM relaciona varias distribuciones de transición sin fijar de antemano el número de estados latentes. Para entender esa construcción conviene partir de un problema más sencillo: representar probabilidades sobre un conjunto finito de símbolos y expresar la incertidumbre acerca de ellas. El primer paso utiliza una distribución de Dirichlet; cuando existen varios contextos, sus distribuciones se vinculan mediante una jerarquía. El proceso de Dirichlet extiende esta idea sin prefijar el número de categorías latentes Murphy (2012); Ferguson (1973); Teh et al. (2006).

Sea $\mathcal{V} = \{1, \ldots, K\}$ un conjunto finito. Una variable aleatoria Y con valores en $\mathcal{V}$ sigue una distribución categórica si existe un vector de probabilidades

$$\mathbf{p} = (p_1, \ldots, p_K), \qquad p_k \geq 0, \qquad \sum_{k=1}^{K} p_k = 1,$$

tal que

$$P(Y = k \mid \mathbf{p}) = p_k.$$

El vector $\mathbf{p}$ pertenece al simplex de dimensión $K - 1$ y contiene el peso asignado a cada categoría posible. Al observar muchas realizaciones para inferir $\mathbf{p}$, los conteos

indican qué categorías aparecieron con mayor frecuencia, pero no expresan por sí solos la incertidumbre de la estimación.

La distribución de Dirichlet cumple esa función. Se escribe

$$\mathbf{p} \sim \text{Dirichlet}(a_1, \ldots, a_K),$$

y define una distribución de probabilidad sobre el conjunto de todos los vectores $\mathbf{p}$ admisibles. Los parámetros $(a_1, \ldots, a_K)$ controlan la concentración de masa en el simplex: si todos son grandes, la distribución se concentra más; si son pequeños, permite configuraciones más extremas. En términos intuitivos, la distribución de Dirichlet actúa como una distribución a priori sobre probabilidades categóricas.

Su importancia práctica proviene de la conjugación. Si se observa una muestra de variables categóricas con conteos

$$(n_1, \ldots, n_K),$$

entonces la distribución posterior de $\mathbf{p}$ vuelve a ser Dirichlet:

$$\mathbf{p} \mid \text{datos} \sim \text{Dirichlet}(a_1 + n_1, \ldots, a_K + n_K).$$

La actualización bayesiana tiene entonces una forma directa. Cada conteo observado corrige el peso previo asociado a su categoría, y el resultado sigue perteneciendo a la misma familia de distribuciones. La Dirichlet puede entenderse así como una forma de regularizar probabilidades discretas sin perder su interpretación probabilística.

Una sola distribución deja de bastar cuando cada contexto de una secuencia tiene su propio vector de probabilidades. Estimar estos vectores de manera independiente produce estimaciones inestables en los contextos con pocos datos y desaprovecha las similitudes entre las distribuciones locales.

Un modelo jerárquico introduce entonces un nivel superior que gobierna los parámetros locales, tratados a su vez como variables aleatorias. Las distribuciones dejan así de estimarse como piezas aisladas: pueden apartarse unas de otras, pero permanecen vinculadas por una organización global.

En el caso finito, esta idea puede escribirse así. Se introduce primero una distribución global

$$\mathbf{p}^{(0)} \sim \text{Dirichlet}(b_1, \ldots, b_K),$$

y después se definen distribuciones locales

$$\mathbf{p}^{(j)} \mid \mathbf{p}^{(0)} \sim \text{Dirichlet}(\lambda p_1^{(0)}, \ldots, \lambda p_K^{(0)}), \qquad j = 1, \ldots, m.$$

Aquí $\mathbf{p}^{(0)}$ fija un perfil global, mientras que cada $\mathbf{p}^{(j)}$ representa una distribución local que puede apartarse de él, aunque no de manera arbitraria. El parámetro λ regula el grado de similitud con el nivel global. Cuando λ es grande, las distribuciones locales tienden a parecerse más entre sí; cuando es pequeño, tienen mayor libertad para divergir.

En un HMM hay una distribución inicial, varios renglones de una matriz de transición y, según la formulación, varias distribuciones de emisión. Cada una describe un comportamiento local, aunque todas remiten al mismo repertorio latente. Una estructura jerárquica permite compartir información entre ellas y estabilizar las estimaciones cuando hay pocos datos. En la literatura bayesiana este compromiso se conoce como agrupamiento parcial: los contextos no se estiman de manera independiente, pero tampoco se obliga a que compartan una sola distribución Murphy (2012).

La construcción anterior todavía supone que el número de categorías K es finito y conocido. La distribución de Dirichlet representa la incertidumbre sobre un vector cuya dimensión ya está fijada; si el número de componentes latentes no se conoce de antemano, hace falta pasar de una distribución sobre vectores finitos a una distribución sobre medidas de probabilidad.

El proceso de Dirichlet da este paso Ferguson (1973). En lugar de asignar una distribución a priori a un vector finito $\mathbf{p}$, la asigna a una medida aleatoria G. Se mantiene la intuición del caso finito: todavía se representa incertidumbre sobre pesos probabilísticos, pero el repertorio de átomos potenciales ya no tiene que fijarse mediante un entero K. El espacio latente puede incorporar tantos componentes como requieran los datos.

Aunque la medida base no sea discreta, las realizaciones del proceso de Dirichlet lo

son casi seguramente. Por ello, G puede entenderse como una medida de probabilidad formada por una familia numerable de átomos con pesos aleatorios. La representación de *stick-breaking* introducida por Sethuraman hace explícita esta construcción Sethuraman (1994): la masa total se reparte sucesivamente en una colección numerable de porciones y produce una medida discreta aleatoria.

La jerarquía se conserva en el caso no paramétrico: una medida global sirve de referencia para varias medidas locales, del mismo modo que la distribución global organizaba las distribuciones locales en el caso finito. Con ello se obtiene una familia de distribuciones de transición relacionadas que comparten un repertorio potencialmente infinito de estados latentes Teh et al. (2006).

Cuando no se conoce de antemano la complejidad latente, la jerarquía bayesiana hace que varias distribuciones compartan un repertorio sin imponerles un único comportamiento local. Esta construcción da lugar al HDP-HMM y a su aproximación truncada.

Capítulo B

Propiedades del proceso observable en un HMM

En un HMM, la propiedad de Markov pertenece a la dinámica oculta y no se transfiere, en general, a las observaciones. El par formado por el estado y la observación sí conserva esa propiedad. El siguiente contraejemplo precisa la diferencia.

B.1 Las observaciones pueden conservar memoria

Proposición B.1. *El proceso observable $(Y_t)_{t\geq 1}$ de una cadena de Markov oculta no es, en general, una cadena de Markov de primer orden.*

Proof. Considérese $\mathcal{S} = \{1, 2\}$, $\mathcal{V} = \{0, 1\}$ y

$$A = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, \qquad P(X_1 = 1) = P(X_1 = 2) = \tfrac{1}{2}.$$

El estado inicial permanece fijo durante toda la trayectoria. Condicionadas a $X_1 = 1$, las observaciones son Bernoulli independientes con parámetro p; condicionadas a $X_1 = 2$, lo son con parámetro q, donde $p, q \in (0, 1)$ y $p \neq q$.

Por la ley de la probabilidad total,

$$P(Y_3 = 1 \mid Y_2 = 1, Y_1 = 1) = \frac{p^3 + q^3}{p^2 + q^2},$$

mientras que

$$P(Y_3 = 1 \mid Y_2 = 1) = \frac{p^2 + q^2}{p + q}.$$

Ambas cantidades son distintas, pues

$$(p^3 + q^3)(p + q) - (p^2 + q^2)^2 = pq(p - q)^2 > 0.$$

Por tanto, conocer Y_1 además de Y_2 cambia la distribución de Y_3 y el proceso observable no satisface la propiedad de Markov de primer orden. □

La razón del resultado es más sencilla que el cálculo. Cada observación aporta evidencia sobre cuál de los dos regímenes ocultos está activo. Dos observaciones contienen más información sobre ese régimen que una sola y, por ello, pueden cambiar la predicción del siguiente símbolo.

B.2 El proceso conjunto sí es markoviano

Proposición B.2. *Sea $Z_t = (X_t, Y_t)$. Entonces $(Z_t)_{t\geq 1}$ es una cadena de Markov en $\mathcal{S} \times \mathcal{V}$.*

Proof. Sean $(i, v), (j, w) \in \mathcal{S} \times \mathcal{V}$. Por la propiedad de Markov de (X_t) y la independencia condicional de las emisiones,

$$\begin{aligned} &P(Z_{t+1} = (j, w) \mid Z_t = (i, v), Z_{t-1}, \ldots, Z_1) \\ &\quad = P(X_{t+1} = j \mid X_t = i) P(Y_{t+1} = w \mid X_{t+1} = j) \\ &\quad = a_{ij} b_j(w). \end{aligned}$$

La expresión depende del presente sólo a través de Z_t, por lo que el proceso conjunto satisface la propiedad de Markov. □

B.3 Un caso límite

La memoria adicional desaparece si la observación revela por completo el estado oculto.

Proposición B.3. *Supóngase que existe una función $f\colon \mathcal{V} \to \mathcal{S}$ tal que*

$$X_t = f(Y_t) \quad \textit{casi seguramente para todo } t \geq 1.$$

Entonces $(Y_t)_{t\geq 1}$ es una cadena de Markov de primer orden.

Proof. Para cualquier historial $y_{1:t}$ con probabilidad positiva, conocer $Y_t = y_t$ determina $X_t = f(y_t)$. La distribución de la siguiente observación es entonces

$$\begin{aligned} &P(Y_{t+1} = v \mid Y_t = y_t, \ldots, Y_1 = y_1) \\ &\quad = \sum_{j \in \mathcal{S}} P(Y_{t+1} = v \mid X_{t+1} = j) P(X_{t+1} = j \mid X_t = f(y_t)) \\ &\quad = \sum_{j \in \mathcal{S}} b_j(v) a_{f(y_t)j}. \end{aligned}$$

El último término depende únicamente de y_t. Por tanto,

$$P(Y_{t+1} = v \mid Y_t = y_t, \ldots, Y_1 = y_1) = P(Y_{t+1} = v \mid Y_t = y_t),$$

y el proceso observable es markoviano. □

La condición anterior es excepcional en la interpretación musical de la tesis. Una clase de altura aislada no suele identificar un único contexto armónico. Por eso el historial de observaciones puede aportar información sobre el estado latente incluso cuando la dinámica oculta es de primer orden Cappé, Moulines, and Rydén (2005).

Bibliografía

Beal, Matthew J., Zoubin Ghahramani, and Carl Edward Rasmussen. 2002. "The Infinite Hidden Markov Model." Paper presented at the Advances in Neural Information Processing Systems 14, Cambridge, MA.

Begleiter, Ron, Ran El-Yaniv, and Golan Yona. 2004. "On Prediction Using Variable Order Markov Models." *Journal of Artificial Intelligence Research* 22: 385–421.

Cappé, Olivier, Eric Moulines, and Tobias Rydén. 2005. *Inference in Hidden Markov Models*. New York: Springer.

Demšar, Janez. 2006. "Statistical Comparisons of Classifiers over Multiple Data Sets." *Journal of Machine Learning Research* 7: 1–30.

Efron, Bradley. 1979. "Bootstrap Methods: Another Look at the Jackknife." *The Annals of Statistics* 7(1): 1–26.

Ferguson, Thomas S. 1973. "A Bayesian Analysis of Some Nonparametric Problems." *The Annals of Statistics* 1(2): 209–230.

Fox, Emily B., Erik B. Sudderth, Michael I. Jordan, and Alan S. Willsky. 2011. "A Sticky HDP-HMM with Application to Speaker Diarization." *The Annals of Applied Statistics* 5(2A): 1020–1056.

Google Cloud. 2026*a*. General-purpose machine family pricing. Documentación de precios Google Cloud. Consultado el 3 de septiembre de 2026. https://cloud.google.com/products/compute/pricing/general-purpose

Google Cloud. 2026*b*. GPU pricing. Documentación de precios Google Cloud. Consultado el 3 de septiembre de 2026. https://cloud.google.com/products/compute/gpus-pricing

Holm, Sture. 1979. "A Simple Sequentially Rejective Multiple Test Procedure." *Scandinavian Journal of Statistics* 6(2): 65–70.

Huang, Cheng-Zhi Anna, Ashish Vaswani, Jakob Uszkoreit, Noam Shazeer, Ian Simon, Curtis Hawthorne, Andrew M. Dai, Matthew D. Hoffman, Monica Dinculescu, and Douglas Eck. 2019. "Music Transformer: Generating Music with Long-Term Structure." Paper presented at the International Conference on Learning Representations (ICLR),.

Ishwaran, Hemant, and Lancelot F. James. 2001. "Gibbs Sampling Methods for Stick-Breaking Priors." *Journal of the American Statistical Association* 96(453): 161–173.

Long, Phillip, Zachary Novack, Taylor Berg-Kirkpatrick, and Julian McAuley. 2025. "PDMX: A Large-Scale Public Domain MusicXML Dataset for Symbolic Music Processing." Paper presented at the ICASSP 2025 – 2025 IEEE International Conference on Acoustics, Speech and Signal Processing,.

Miettinen, Kaisa. 1999. *Nonlinear Multiobjective Optimization*. Boston: Kluwer Academic Publishers.

Murphy, Kevin P. 2012. *Machine Learning: A Probabilistic Perspective*. Cambridge, MA: MIT Press.

Pearce, Marcus T., and Geraint A. Wiggins. 2012. "Auditory Expectation: The Information Dynamics of Music Perception and Cognition." *Topics in Cognitive Science* 4(4): 625–652.

Rabiner, Lawrence R. 1989. "A tutorial on hidden Markov models and selected applications in speech recognition." *Proceedings of the IEEE* 77(2): 257–286.

Ross, Sheldon M. 2014. *Introduction to Probability Models*. 10 ed. Amsterdam: Academic Press.

Sethuraman, Jayaram. 1994. "A Constructive Definition of Dirichlet Priors." *Statistica Sinica* 4(2): 639–650.

Sheh, Alexander, and Daniel P. W. Ellis. 2003. "Chord Segmentation and Recognition Using EM-Trained Hidden Markov Models." Paper presented at the Proceedings of the 4th International Conference on Music Information Retrieval,.

Teh, Yee Whye, Michael I. Jordan, Matthew J. Beal, and David M. Blei. 2006. "Hierarchical Dirichlet Processes." *Journal of the American Statistical Association* 101(476): 1566–1581.

Temperley, David. 2007. *Music and Probability*. Cambridge, MA: MIT Press.

Van Gael, Jurgen, Yunus Saatci, Yee Whye Teh, and Zoubin Ghahramani. 2008. "Beam Sampling for the Infinite Hidden Markov Model." Paper presented at the Proceedings of the 25th International Conference on Machine Learning,.

Vaswani, Ashish, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. 2017. "Attention Is All You Need." Paper presented at the Advances in Neural Information Processing Systems 30 (NeurIPS 2017),.

W3C Music Notation Community Group. 2021. MusicXML 4.0. Final community group report World Wide Web Consortium. Editado por Michael Good. https://www.w3.org/2021/06/musicxml40/

Wilcoxon, Frank. 1945. "Individual Comparisons by Ranking Methods." *Biometrics Bulletin* 1(6): 80–83.

Modelado probabilístico de melodías: cadenas de Markov ocultas y comparación predictiva , de Adrián Janus Gonzalez Adamuz, se preparó en Ciudad de México en 2026.